随机微分方程导论

许俊强

Chapter 1

从确定性到随机性的思维转换

1.1 ODE 与 SDE：确定性与随机性的对话

随机微分方程 (SDE) 理论并非凭空产生，而是经典常微分方程 (ODE) 理论在随机扰动下的自然推广。理解这种推广的内在逻辑，是掌握随机分析的关键第一步。

1.1.1 确定性世界的微积分

让我们从熟悉的 ODE 开始：

定义 1.1 (常微分方程). *设 $\mu : [0,T] \times \mathbb{R}^d \to \mathbb{R}^d$ 为给定函数。形如*

$$\frac{dX(t)}{dt} = \mu(t, X(t)), \quad X(0) = x_0$$

的方程称为常微分方程（ODE）。

在良好条件下（如 μ Lipschitz 连续），ODE 有唯一解，且解具有确定性的演化轨迹。这是经典牛顿力学的数学表述：给定初始状态，未来完全确定。

然而，现实世界中许多物理现象都受到无法精确建模的随机扰动。例如，悬浮在液体中的花粉颗粒受到无数水分子的碰撞，其运动轨迹虽然宏观上有趋势，但微观上呈现随机性。

1.1.2 随机扰动的引入：从 ODE 到 SDE

为建模这种" 趋势加随机波动" 的现象，我们在 ODE 中引入布朗运动 W_t：

定义 1.2 (随机微分方程). 设 $\mu : [0,T] \times \mathbb{R}^d \to \mathbb{R}^d$（漂移系数），$\sigma : [0,T] \times \mathbb{R}^d \to \mathbb{R}^{d\times m}$（扩散系数）。形如

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t, \quad X_0 = x_0$$

的方程称为随机微分方程（*SDE*）。

这里出现了两个关键符号：

- dt：确定性时间微分，对应经典 ODE 中的时间演化
- dW_t：布朗运动的微分，建模随机扰动

1.1.3 积分形式的等价表述

与 ODE 类似，SDE 也有等价的积分形式：

$$X_t = x_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

这个形式揭示了我们将在本章重点讨论的 ** 三种基本操作 **：

1. $\int_0^t \mu(s, X_s)ds$：对时间 t 的积分（确定性部分）
2. $\int_0^t \sigma(s, X_s)dW_s$：对布朗运动 W_t 的积分（随机部分）
3. 隐含的：对样本 ω 的积分（期望运算）

这三种操作的交织使用构成了随机分析的核心范式。

1.2 适应过程与信息流的数学表述

在确定性 ODE 中，我们关心的是函数 $X(t)$ 在时刻 t 的值。在随机世界，我们不仅关心 X_t 的值，还关心它如何依赖于已知信息。

1.2.1 过滤：信息随时间累积的模型

定义 1.3 (过滤). 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。一族递增的 σ-代数 $\{\mathcal{F}_t\}_{t\geq 0}$（即 $\mathcal{F}_s \subseteq \mathcal{F}_t$ 对 $s \leq t$）称为过滤（*filtration*）。

$\mathcal{F}_t$ 表示到时刻 t 为止已获得的信息。在布朗运动背景下，自然过滤定义为：

$$\mathcal{F}_t^W = \sigma(W_s : 0 \leq s \leq t)$$

定义 1.4 (适应过程). 随机过程 $\{X_t\}$ 称为适应于过滤 $\{\mathcal{F}_t\}$，如果对每个 t，X_t 是 $\mathcal{F}_t$-可测的。

适应性的直观解释：X_t 的值在时刻 t 应该只依赖于到 t 为止的信息，不能”预知未来”。

1.2.2 布朗运动的自然过滤：信息的逐步揭示

考虑布朗运动 W_t，其自然过滤 $\mathcal{F}_t^W$ 包含了所有到时间 t 为止的布朗运动轨迹信息。这个过滤具有以下重要性质：

命题 1.5 (布朗运动过滤的性质). 设 $\{W_t\}$ 为布朗运动，$\mathcal{F}_t^W$ 为其自然过滤。则：

1. W_t 是 $\mathcal{F}_t^W$-可测的（适应性）
2. 对 $s < t$，增量 $W_t - W_s$ 独立于 $\mathcal{F}_s^W$（独立增量性）
3. $W_t - W_s$ 服从 $N(0, t-s)$ 分布（正态增量）

这些性质使得布朗运动成为构建随机分析的理想噪声源。

1.3 布朗运动：随机分析的理想噪声

布朗运动不仅是物理学现象，更是随机分析中基本的数学对象。我们需要从多个角度理解它。

1.3.1 布朗运动的等价定义

定义 1.6 (布朗运动（标准定义）). 随机过程 $\{W_t\}_{t\geq 0}$ 称为布朗运动（维纳过程），如果：

1. $W_0 = 0$ *a.s.*
2. 对 $0 \leq s < t$，增量 $W_t - W_s \sim N(0, t-s)$
3. 对 $0 \leq t_1 < t_2 < \cdots < t_n$，增量 $W_{t_2} - W_{t_1}, \ldots, W_{t_n} - W_{t_{n-1}}$ 相互独立
4. 样本路径 $t \mapsto W_t(\omega)$ 连续 *a.s.*

这个定义强调了布朗运动的统计特性，但未深入其样本路径的结构性质。

1.3.2 样本路径的粗糙性：几乎处处不可微

定理 1.7 (布朗运动的 Hölder 连续性). 布朗运动几乎所有的样本路径是局部 α-*Hölder* 连续的，对任意 $\alpha < 1/2$。即：对几乎每个 ω，存在 $C(\omega) > 0$ 使得

$$|W_t(\omega) - W_s(\omega)| \leq C(\omega)|t-s|^\alpha, \quad \forall s, t \in [0, T]$$

但另一方面：

定理 1.8 (几乎处处不可微). 布朗运动几乎所有的样本路径在任意点都不可微。

这种”连续但高度振荡”的特性意味着：布朗运动路径的变差是无穷的，这使得经典黎曼-斯蒂尔切斯积分无法直接定义 $\int f(t)dW_t$。

1.3.3 二次变差：随机积分的基石

定义 1.9 (二次变差). 设 $\{W_t\}$ 为布朗运动，$\Pi_n = \{0 = t_0^n < t_1^n < \cdots < t_{k_n}^n = T\}$ 为 $[0, T]$ 的分划序列，满足 $\|\Pi_n\| = \max_i |t_i^n - t_{i-1}^n| \to 0$。则

$$\sum_{i=1}^{k_n} (W_{t_i^n} - W_{t_{i-1}^n})^2 \xrightarrow[n\to\infty]{L^2} T$$

我们记 $(dW_t)^2 = dt$ 或 $d[W]_t = dt$。

二次变差非零是布朗运动与光滑函数的本质区别。在经典微积分中，$(dt)^2$ 是 dt 的高阶无穷小，可以忽略。但在随机微积分中，$(dW_t)^2$ 与 dt 同阶，必须保留。这一事实将导致 Itô 公式中著名的二阶修正项。

1.4 三种基本操作：随机分析的语法

随机分析可以看作三种基本操作的组合与迭代。理解这三种操作及其相互关系是掌握随机分析的关键。

1.4.1 操作一：对时间积分（确定性累积）

对给定适应过程 $\{f_t\}$，我们定义：

$$I_t^1(\omega) = \int_0^t f_s(\omega)ds$$

这是对每个样本路径 ω 的普通勒贝格积分。从乘积空间视角看：

$$I^1 : \Omega \times [0,T] \to \mathbb{R}, \quad (\omega, t) \mapsto \int_0^t f(\omega, s)ds$$

对固定的 ω，这是关于 t 的连续函数；对固定的 t，这是随机变量。

1.4.2 操作二：对样本积分（期望运算）

对随机变量 $X : \Omega \to \mathbb{R}$，我们定义：

$$\mathbb{E}[X] = \int_\Omega X(\omega)\mathbb{P}(d\omega)$$

从乘积空间视角看，对二元函数 $g(\omega, t)$，固定 t 对 ω 积分得到确定性函数：

$$t \mapsto \mathbb{E}[g(\cdot, t)] = \int_\Omega g(\omega, t)\mathbb{P}(d\omega)$$

这是从随机性中提取确定性信息的核心操作。

1.4.3 操作三：Itô 积分（随机累积）

Itô 积分 $\int_0^t f_s dW_s$ 是全新的构造。它不能像操作一那样逐路径定义（因为 W_t 路径无限变差），也不能像操作二那样只涉及期望。其定义需要三步：

1. 对简单过程 $f_t = \sum_{i=0}^{n-1} \xi_i \mathbf{1}_{[t_i,t_{i+1})}(t)$，其中 ξ_i 为 $\mathcal{F}_{t_i}$-可测，定义：

$$\int_0^T f_t dW_t = \sum_{i=0}^{n-1} \xi_i (W_{t_{i+1}} - W_{t_i})$$

2. 证明对适应平方可积过程，存在简单过程逼近

3. 在 $L^2(\Omega)$ 中取极限定义一般情形的积分

1.4.4 三种操作的关系与 Fubini 定理

一个重要问题是：这三种操作能否交换次序？

命题 1.10 (确定性部分的 Fubini)**.** *若 $f : \Omega \times [0,T] \to \mathbb{R}$ 为乘积可测且可积，则*

$$\mathbb{E}\left[\int_0^T f(t)dt\right] = \int_0^T \mathbb{E}[f(t)]dt$$

即操作一与操作二可交换。

但对于 Itô 积分，情况不同：

命题 1.11 (Itô 积分的期望为零)**.** *若 f 适应且平方可积，则*

$$\mathbb{E}\left[\int_0^T f_t dW_t\right] = 0$$

这意味着：先做 Itô 积分（操作三）再取期望（操作二）得到零。但若先固定 ω，Itô 积分本身甚至无法逐路径良好定义。

1.5 从 ODE 到 SDE：解概念的推广

1.5.1 ODE 解的存在唯一性回顾

考虑 ODE：

$$\frac{dX}{dt} = \mu(t, X), \quad X(0) = x_0$$

在 μ 满足 Lipschitz 条件下，Picard 迭代证明存在唯一解：

$$\begin{aligned} X^{(0)}(t) &= x_0 \\ X^{(n+1)}(t) &= x_0 + \int_0^t \mu(s, X^{(n)}(s))ds \end{aligned}$$

在函数空间 $C[0,T]$ 中，迭代映射是压缩的，由 Banach 不动点定理得解。

1.5.2 SDE 解的存在唯一性框架

对于 SDE：

$$X_t = x_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

我们同样尝试 Picard 迭代：

$$\begin{aligned} X_t^{(0)} &= x_0 \\ X_t^{(n+1)} &= x_0 + \int_0^t \mu(s, X_s^{(n)})ds + \int_0^t \sigma(s, X_s^{(n)})dW_s \end{aligned}$$

但此时我们需要：

1. 选取适当的函数空间：不再是确定性函数空间 $C[0,T]$，而是随机过程空间，如
$$\mathcal{H}^2 = \{X : \text{适应连续}, \mathbb{E}[\sup_{0\le t\le T} |X_t|^2] < \infty\}$$
2. 证明迭代映射的压缩性：这需要 Itô 积分的估计（BDG 不等式）
3. 验证解的良好性质：适应性、连续性、平方可积性

1.5.3 矩方程：确定性部分的期望演化

对 SDE 取期望，利用 Itô 积分期望为零的性质：

$$\begin{aligned}\mathbb{E}[X_t] &= \mathbb{E}\left[x_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s\right] \\ &= x_0 + \mathbb{E}\left[\int_0^t \mu(s, X_s)ds\right] \\ &= x_0 + \int_0^t \mathbb{E}[\mu(s, X_s)]ds \quad \text{(Fubini)}\end{aligned}$$

于是得到 $\mathbb{E}[X_t]$ 满足的积分方程。特别地，若 μ 是线性的，即 $\mu(t,x) = a(t)x + b(t)$，则

$$\frac{d}{dt}\mathbb{E}[X_t] = a(t)\mathbb{E}[X_t] + b(t)$$

这是关于 $\mathbb{E}[X_t]$ 的线性 ODE，可显式求解。

1.6 几何布朗运动：SDE 的经典范例

1.6.1 模型与直观

几何布朗运动是金融数学中最基本的模型：

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

其中 μ 为期望收益率，σ 为波动率。直观上：

- $\mu S_t dt$：确定性趋势，按比例增长
- $\sigma S_t dW_t$：随机波动，波动幅度与当前价格成正比

1.6.2 求解：Itô 公式的首次应用

形式上，方程可写为：

$$\frac{dS_t}{S_t} = \mu dt + \sigma dW_t$$

这启发我们考虑 $\log S_t$。应用 Itô 公式（我们将在下一章系统学习）：

$$\begin{aligned} d(\log S_t) &= \frac{1}{S_t}dS_t - \frac{1}{2S_t^2}(dS_t)^2 \\ &= \mu dt + \sigma dW_t - \frac{1}{2}\sigma^2 dt \\ &= (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW_t \end{aligned}$$

这里出现了关键的二阶修正项 $-\frac{1}{2}\sigma^2 dt$，它来自 $(dW_t)^2 = dt$。积分得：

$$\log S_t = \log S_0 + (\mu - \frac{1}{2}\sigma^2)t + \sigma W_t$$

从而

$$S_t = S_0 \exp\left((\mu - \frac{1}{2}\sigma^2)t + \sigma W_t\right)$$

1.6.3 统计性质分析

1. **期望**：$\mathbb{E}[S_t] = S_0 e^{\mu t}$
2. **方差**：$\mathrm{Var}(S_t) = S_0^2 e^{2\mu t}(e^{\sigma^2 t} - 1)$
3. **分布**：$\log S_t$ 服从正态分布，故 S_t 服从对数正态分布

注意期望增长率是 μ，但样本路径的平均增长率是 $\mu - \frac{1}{2}\sigma^2$，这体现了随机扰动对长期增长的负面影响。

1.7 Ornstein-Uhlenbeck 过程：均值回归的范例

1.7.1 物理背景与方程

Ornstein-Uhlenbeck 过程建模具有均值回归特性的现象：

$$dX_t = \theta(\mu - X_t)dt + \sigma dW_t$$

其中：

- μ：长期均值

- $\theta > 0$：回归速度
- σ：波动率

当 $X_t > \mu$ 时，漂移项为负，将过程拉向均值；当 $X_t < \mu$ 时，漂移项为正，同样将过程拉向均值。

1.7.2 求解：线性 SDE 的典范

将方程改写为：

$$dX_t + \theta X_t dt = \theta\mu dt + \sigma dW_t$$

两边乘以积分因子 $e^{\theta t}$：

$$d(e^{\theta t}X_t) = \theta\mu e^{\theta t}dt + \sigma e^{\theta t}dW_t$$

积分得：

$$X_t = e^{-\theta t}X_0 + \mu(1 - e^{-\theta t}) + \sigma e^{-\theta t}\int_0^t e^{\theta s}dW_s$$

1.7.3 平稳分布与遍历性

1. **期望**：$\mathbb{E}[X_t] = e^{-\theta t}X_0 + \mu(1 - e^{-\theta t}) \to \mu$
2. **方差**：$\mathrm{Var}(X_t) = \frac{\sigma^2}{2\theta}(1 - e^{-2\theta t}) \to \frac{\sigma^2}{2\theta}$
3. **平稳分布**：$X_t \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{2\theta}\right)$

OU 过程是遍历的：时间平均收敛于空间平均。

本章总结

本章完成了从确定性 ODE 到随机 SDE 的思维转换，要点包括：

1. SDE 在 ODE 基础上增加随机扰动项 σdW_t
2. 布朗运动作为理想噪声源：连续但不可微，具有非零二次变差

3. 三种基本操作的引入与区分：时间积分、样本积分、Itô 积分
4. 适应过程与过滤：信息随时间的累积
5. SDE 解的存在唯一性框架与 ODE 的类比
6. 两个经典例子：几何布朗运动（指数增长 + 波动）、Ornstein-Uhlenbeck 过程（均值回归）

这些概念为后续深入学习 Itô 积分构造、Itô 公式、SDE 解理论奠定了坚实基础。特别重要的是，我们建立了”三种操作”的视角，这将成为贯穿整个随机分析学习的核心线索。

在下一章，我们将系统构造 Itô 积分，详细研究其性质，并最终建立随机微积分的基本定理——Itô 公式。

历史注记

布朗运动的数学理论由爱因斯坦（1905）和斯莫卢霍夫斯基（1906）从物理角度建立，维纳（1923）给出严格的数学构造。Itô 在 1940 年代系统发展了随机积分和 SDE 理论，标志着现代随机分析的诞生。几何布朗运动由萨缪尔森（1965）引入金融学，成为布莱克-舒尔斯期权定价模型的基础。Ornstein-Uhlenbeck 过程源于朗之万方程的研究，是统计力学和金融学中均值回归现象的基本模型。

Chapter 2

Itô 积分的构造哲学

2.1 为什么需要新的积分理论？

在第 1 章中，我们引入了随机微分方程的基本形式：

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t$$

并强调了理解 $\int_0^t \sigma(s, X_s)dW_s$ 这一项的重要性。然而，布朗运动 W_t 的样本路径几乎是处处不可微且具有无限变差的，这使得经典微积分中的积分理论无法直接应用。

2.1.1 经典积分理论的失效

黎曼-斯蒂尔切斯积分的局限性

对于有界变差函数 $A : [0, T] \to \mathbb{R}$，我们可以定义黎曼-斯蒂尔切斯积分：

$$\int_0^T f(t)dA(t) = \lim_{\|\Pi\| \to 0} \sum_{i=0}^{n-1} f(\xi_i)[A(t_{i+1}) - A(t_i)]$$

其中 $\xi_i \in [t_i, t_{i+1}]$，极限与 ξ_i 的选取无关。

但布朗运动 W_t 的变差几乎是无穷的：

定理 2.1 (布朗运动的一阶变差). *设 $\{W_t\}$ 为布朗运动，Π_n 为 $[0, T]$ 的分*

划序列，满足 $\|\Pi_n\| \to 0$。则

$$\sum_{i=1}^{k_n} |W_{t_i} - W_{t_{i-1}}| \xrightarrow{a.s.} \infty$$

这意味着我们无法通过路径 wise 的黎曼-斯蒂尔切斯积分来定义 $\int f dW$。

样本路径视角的困难

对于固定的样本 $\omega \in \Omega$，考虑映射：

$$t \mapsto \int_0^t f(s) dW_s(\omega)$$

我们希望这是一个关于 t 的函数。但由于 $W_t(\omega)$ 几乎处处不可微，我们甚至无法定义逐样本路径的积分。

注 2.2 (确定性方法的失败). 一些数学家曾尝试定义逐路径的积分，如 *Young* 积分（要求被积函数和积分器有互补的正则性，p-变差理论），但布朗运动的 p-变差只在 $p > 2$ 时有限，而 *Young* 积分要求 $1/p + 1/q > 1$。对布朗运动，这要求被积函数具有有限 q-变差且 $q < 2$，条件过于严格。

2.1.2 Itô 的洞察：概率平均代替路径 wise 定义

Itô 的伟大贡献在于认识到：与其追求逐路径的积分定义，不如在 L^2 空间中进行定义，利用概率收敛的概念。其核心思想是：

1. 先对简单过程（类似阶梯函数）明确定义积分
2. 证明更一般的过程可以用简单过程逼近
3. 在 $L^2(\Omega)$ 中取极限定义一般情形的积分

这种定义方式放弃了”对每个 ω 都有良好定义”的要求，转而要求”在平均意义下良好定义”。

2.2 简单过程的 Itô 积分

2.2.1 简单过程的定义

定义 2.3 (简单适应过程). 随机过程 $\{f_t\}_{0\le t\le T}$ 称为简单适应过程，如果存在分划 $0=t_0<t_1<\cdots<t_n=T$ 和一族随机变量 $\{\xi_i\}_{i=0}^{n-1}$ 满足：

1. ξ_i 是 $\mathcal{F}_{t_i}$-可测的（适应性）
2. $\mathbb{E}[\xi_i^2]<\infty$（平方可积）
3. $f_t=\xi_0\mathbf{1}_{\{0\}}(t)+\sum_{i=0}^{n-1}\xi_i\mathbf{1}_{(t_i,t_{i+1}]}(t)$

简单过程在每个区间 $(t_i,t_{i+1}]$ 上取常数值 ξ_i，且该值在区间左端点 t_i 处已知（适应性要求）。

2.2.2 简单过程积分的自然定义

对于简单过程 f_t，我们自然定义：

$$I_T(f)=\int_0^T f_t dW_t=\sum_{i=0}^{n-1}\xi_i(W_{t_{i+1}}-W_{t_i})$$

这个定义具有直观的解释：在每个区间 $(t_i,t_{i+1}]$ 上，我们用已知信息 ξ_i（在 t_i 时已知）乘以未来的布朗运动增量 $W_{t_{i+1}}-W_{t_i}$。

2.2.3 简单过程积分的性质

定理 2.4 (简单过程 Itô 积分的性质). 设 f,g 为简单适应过程，$\alpha,\beta\in\mathbb{R}$。则：

1. **线性性**：$I_T(\alpha f+\beta g)=\alpha I_T(f)+\beta I_T(g)$
2. **适应性**：$I_t(f)=\int_0^t f_s dW_s$ 是 $\mathcal{F}_t$-可测的
3. **连续性**：$t\mapsto I_t(f)$ 几乎必然连续
4. **鞅性**：$\{I_t(f)\}_{t\ge 0}$ 是鞅，即对 $s<t$，$\mathbb{E}[I_t(f)|\mathcal{F}_s]=I_s(f)$

5. **零期望**：$\mathbb{E}[I_T(f)] = 0$

鞅性的证明. 设 $s \in [t_k, t_{k+1})$，则：

$$\begin{aligned}\mathbb{E}[I_t(f)|\mathcal{F}_s] &= \mathbb{E}\left[\sum_{i=0}^{k-1}\xi_i\Delta W_i + \xi_k(W_{t_{k+1}} - W_s) + \sum_{i=k+1}^{n-1}\xi_i\Delta W_i\middle|\mathcal{F}_s\right] \\ &= \sum_{i=0}^{k-1}\xi_i\Delta W_i + \xi_k\mathbb{E}[W_{t_{k+1}} - W_s|\mathcal{F}_s] + \sum_{i=k+1}^{n-1}\mathbb{E}[\xi_i\Delta W_i|\mathcal{F}_s]\end{aligned}$$

由于 $W_{t_{k+1}} - W_s$ 与 $\mathcal{F}_s$ 独立且期望为零，$\mathbb{E}[W_{t_{k+1}} - W_s|\mathcal{F}_s] = 0$。对于 $i > k$，ξ_i 是 $\mathcal{F}_{t_i}$-可测的，ΔW_i 与 $\mathcal{F}_{t_i}$ 独立，故 $\mathbb{E}[\xi_i\Delta W_i|\mathcal{F}_s] = 0$。因此 $\mathbb{E}[I_t(f)|\mathcal{F}_s] = I_s(f)$。 □

2.2.4 Itô 等距：简单情形

定理 2.5 (Itô 等距：简单过程). 对简单适应过程 f，

$$\mathbb{E}\left[\left(\int_0^T f_t dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T f_t^2 dt\right]$$

证明. 设 $f_t = \sum_{i=0}^{n-1}\xi_i\mathbf{1}_{(t_i,t_{i+1}]}(t)$，则：

$$\begin{aligned}\mathbb{E}\left[\left(\int_0^T f_t dW_t\right)^2\right] &= \mathbb{E}\left[\left(\sum_{i=0}^{n-1}\xi_i\Delta W_i\right)^2\right] \\ &= \sum_{i=0}^{n-1}\mathbb{E}[\xi_i^2(\Delta W_i)^2] + 2\sum_{i<j}\mathbb{E}[\xi_i\xi_j\Delta W_i\Delta W_j]\end{aligned}$$

对于 $i < j$，$\xi_i\xi_j\Delta W_i$ 是 $\mathcal{F}_{t_j}$-可测的，ΔW_j 与 $\mathcal{F}_{t_j}$ 独立，故 $\mathbb{E}[\xi_i\xi_j\Delta W_i\Delta W_j] = \mathbb{E}[\xi_i\xi_j\Delta W_i]\mathbb{E}[\Delta W_j] = 0$。

对于对角线项，由于 ξ_i 与 ΔW_i 独立，$\mathbb{E}[\xi_i^2(\Delta W_i)^2] = \mathbb{E}[\xi_i^2]\mathbb{E}[(\Delta W_i)^2] = \mathbb{E}[\xi_i^2](t_{i+1} - t_i)$。因此：

$$\mathbb{E}\left[\left(\int_0^T f_t dW_t\right)^2\right] = \sum_{i=0}^{n-1}\mathbb{E}[\xi_i^2](t_{i+1} - t_i) = \mathbb{E}\left[\int_0^T f_t^2 dt\right]$$

□

Itô 等距的意义在于：它将随机积分的 L^2 范数与确定性积分的 L^2 范数联系起来，为 L^2 收敛提供了基础。

2.3 一般适应过程的逼近与极限

2.3.1 可积函数空间

定义 2.6 ($\mathcal{H}^2$ 空间). 定义

$$\mathcal{H}^2 = \mathcal{H}^2([0,T]) = \left\{ f : [0,T] \times \Omega \to \mathbb{R} \middle| \begin{array}{l} f\text{适应于}\{\mathcal{F}_t\}, \\ \mathbb{E}\left[\int_0^T f_t^2 dt\right] < \infty \end{array} \right\}$$

在范数 $\|f\|_{\mathcal{H}^2} = \left(\mathbb{E}\int_0^T f_t^2 dt\right)^{1/2}$ 下，$\mathcal{H}^2$ 是 *Hilbert* 空间。

命题 2.7 (简单过程在 $\mathcal{H}^2$ 中稠密). 简单适应过程集合 $\mathcal{S}$ 在 $\mathcal{H}^2$ 中稠密。即对任意 $f \in \mathcal{H}^2$，存在简单过程序列 $\{f^{(n)}\} \subseteq \mathcal{S}$ 使得

$$\lim_{n\to\infty} \mathbb{E}\left[\int_0^T |f_t - f_t^{(n)}|^2 dt\right] = 0$$

证明思路. 分三步逼近:

1. **有界化**: 对任意 $f \in \mathcal{H}^2$，定义 $f_t^{(M)} = f_t \mathbf{1}_{\{|f_t| \le M\}}$。由控制收敛定理，当 $M \to \infty$ 时，$\|f - f^{(M)}\|_{\mathcal{H}^2} \to 0$。

2. **连续化**: 对有界适应过程 f，考虑卷积光滑化:

$$f_t^{(n)} = n \int_{(t-1/n)\vee 0}^t f_s ds$$

   则 $f^{(n)}$ 适应连续，且 $\|f - f^{(n)}\|_{\mathcal{H}^2} \to 0$。

3. **离散化**: 对适应连续过程 f，定义简单过程:

$$f_t^{(n)} = \sum_{k=0}^{2^n-1} f(kT/2^n) \mathbf{1}_{(kT/2^n,(k+1)T/2^n]}(t)$$

   由连续性，$\|f - f^{(n)}\|_{\mathcal{H}^2} \to 0$。

□

2.3.2 Itô 积分的定义

定义 2.8 (Itô 积分). 设 $f \in \mathcal{H}^2, \{f^{(n)}\}$ 为简单过程序列,满足 $\|f - f^{(n)}\|_{\mathcal{H}^2} \to 0$。定义

$$\int_0^T f_t dW_t = \lim_{n\to\infty} \int_0^T f_t^{(n)} dW_t$$

其中极限在 $L^2(\Omega)$ 中取。

我们需要验证定义的良定性:

引理 2.9 (良定性). 上述定义与逼近序列的选取无关。即若 $f^{(n)}, g^{(n)}$ 均为简单过程序列且都收敛到 f，则

$$\lim_{n\to\infty} \int_0^T f_t^{(n)} dW_t = \lim_{n\to\infty} \int_0^T g_t^{(n)} dW_t \quad 在 L^2(\Omega) 中$$

证明. 由 Itô 等距，对简单过程 h 有 $\|\int h dW\|_{L^2} = \|h\|_{\mathcal{H}^2}$。因此:

$$\left\| \int f^{(n)} dW - \int g^{(n)} dW \right\|_{L^2} = \left\| \int (f^{(n)} - g^{(n)}) dW \right\|_{L^2} = \|f^{(n)} - g^{(n)}\|_{\mathcal{H}^2}$$

由于 $f^{(n)}$ 和 $g^{(n)}$ 都收敛到 f，$\|f^{(n)} - g^{(n)}\|_{\mathcal{H}^2} \to 0$。 □

2.3.3 作为过程的 Itô 积分

定义不仅给出了 $\int_0^T f_t dW_t$ 这个随机变量,还给出了整个过程 $\{I_t(f)\}_{0\le t\le T}$，其中 $I_t(f) = \int_0^t f_s dW_s$。

命题 2.10 (积分过程的连续性). 对 $f \in \mathcal{H}^2$，存在 $\{I_t(f)\}$ 的连续修正。即存在连续鞅 $\{\tilde{I}_t(f)\}$ 使得对每个 t，$\mathbb{P}(I_t(f) = \tilde{I}_t(f)) = 1$。

这意味着我们可以（且通常）假定 Itô 积分过程是连续的。

2.4 Itô 积分的性质

2.4.1 基本性质

定理 2.11 (Itô 积分的基本性质). 设 $f, g \in \mathcal{H}^2$，$\alpha, \beta \in \mathbb{R}$。则:

1. **线性性**：$\int_0^T(\alpha f_t+\beta g_t)dW_t=\alpha\int_0^T f_t dW_t+\beta\int_0^T g_t dW_t$

2. **适应性**：对每个 t，$I_t(f)$ 是 $\mathcal{F}_t$-可测的

3. **连续性**：存在连续版本，即我们可以选择 $\{I_t(f)\}$ 为连续过程

4. **鞅性**：$\{I_t(f)\}$ 是连续平方可积鞅

5. **零期望**：$\mathbb{E}\left[\int_0^T f_t dW_t\right]=0$

6. ***Itô* 等距**：$\mathbb{E}\left[\left(\int_0^T f_t dW_t\right)^2\right]=\mathbb{E}\left[\int_0^T f_t^2 dt\right]$

2.4.2 鞅性的深入理解

鞅性质 $\mathbb{E}[I_t(f)|\mathcal{F}_s]=I_s(f)$ 具有深刻的金融解释：Itô 积分表示一个公平博弈的累积收益。在时刻 s 之后，无论采取什么适应策略 f，基于已有信息的期望收益为零。

注 2.12 (鞅表示定理的预示)**.** *布朗运动滤波下的平方可积鞅都可以表示为 Itô 积分。这是鞅表示定理的内容，我们将在后续章节学习。它意味着：在布朗运动驱动的世界中，所有"公平博弈"都来自于对布朗运动的适当积分。*

2.4.3 乘积空间视角下的 Itô 积分

回顾第 0 章的 Currying 观点：随机过程是 $\Omega\times[0,T]\to\mathbb{R}$ 的可测映射。Itô 积分 $I_T:\mathcal{H}^2\to L^2(\Omega)$ 是一个线性算子。从乘积空间角度看：

$$I_T(f)(\omega)=\left(\int_0^T f(\cdot,s)dW_s\right)(\omega)$$

注意：这里对每个 ω，右边并不能逐点定义，而是整体在 L^2 意义下定义。

对比确定性积分 $J_T(f)(\omega)=\int_0^T f(\omega,s)ds$，它对每个 ω 都有良好定义。这是确定性积分与随机积分的根本区别。

2.5 作为随机测度的 Itô 积分

2.5.1 随机测度的概念

在经典测度论中，积分是相对于一个固定测度的。但 Itô 积分中的" 测度"dW_t 本身是随机的。更准确地说，对于每个 ω，我们希望定义：

$$M_\omega(A) = \int_A f(t,\omega)dW_t(\omega), \quad A \subseteq [0,T]$$

但正如我们强调的，这无法逐 ω 定义。

2.5.2 正交鞅测度的构造

正确的观点是：Itô 积分定义了一个 ** 正交鞅测度 **。对每个 Borel 集 $A \subseteq [0,T]$，定义：

$$M(A) = \int_0^T \mathbf{1}_A(t)dW_t$$

则 M 满足：

1. 对不相交的 A, B，$M(A \cup B) = M(A) + M(B)$（可加性）
2. $\mathbb{E}[M(A)] = 0$
3. 若 A, B 不相交，则 $\mathbb{E}[M(A)M(B)] = 0$（正交性）
4. $\mathbb{E}[M(A)^2] = \lambda(A)$，其中 λ 为勒贝格测度

更一般地，对 $f \in \mathcal{H}^2$，我们可以定义：

$$M_f(A) = \int_A f_t dW_t$$

这给出了一个从 $\mathcal{H}^2$ 到 $L^2(\Omega)$ 的等距映射。

2.5.3 与经典测度论的对比

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间，$([0,T], \mathcal{B}, dt)$ 为时间区间。经典测度论考虑乘积空间 $\Omega \times [0,T]$ 上的测度 $\mathbb{P} \otimes dt$，积分是：

$$\int_{\Omega \times [0,T]} f(\omega,t)(\mathbb{P} \otimes dt)(d\omega, dt)$$

可以 Fubini 交换次序。

对于 Itô 积分，我们有" 随机测度"$dW_t(\omega)$，它不能分解为 $\mathbb{P}$ 和某个固定测度的乘积。因此，我们不能简单地应用 Fubini 定理交换对 ω 和对 t 的积分次序。

2.6 扩展与推广

2.6.1 局部鞅与局部化技术

$\mathcal{H}^2$ 要求 $\mathbb{E}\int_0^T f_t^2 dt < \infty$，这对许多应用过于严格。我们可以通过局部化扩展定义。

定义 2.13 (停时序列的局部化). *设 $\{\tau_n\}$ 为一列停时，满足 $\tau_n \uparrow T$ a.s.。如果对每个 n，$f_t \mathbf{1}_{t\le\tau_n} \in \mathcal{H}^2$，则称 f 局部属于 $\mathcal{H}^2$。*

对这样的 f，我们可以定义：

$$\int_0^t f_s dW_s = \lim_{n\to\infty} \int_0^{t\wedge\tau_n} f_s dW_s$$

得到的 $\{I_t(f)\}$ 是局部鞅。

2.6.2 从 L^2 到 L^1 的推广

可以进一步放宽条件到：

$$\mathbb{P}\left(\int_0^T f_t^2 dt < \infty\right) = 1$$

此时可以定义 Itô 积分为局部鞅。但此时 Itô 等距不一定成立，鞅性也可能只是局部鞅性。

2.6.3 多维布朗运动

设 $W_t = (W_t^1, \ldots, W_t^m)$ 为 m 维布朗运动，$f_t = (f_t^1, \ldots, f_t^m)$ 为适应过程。定义：

$$\int_0^T f_t \cdot dW_t = \sum_{j=1}^m \int_0^T f_t^j dW_t^j$$

性质类似，Itô 等距变为：

$$\mathbb{E}\left[\left(\int_0^T f_t \cdot dW_t\right)^2\right] = \mathbb{E}\left[\int_0^T \|f_t\|^2 dt\right]$$

其中 $\|f_t\|^2 = \sum_{j=1}^m (f_t^j)^2$。

2.7 应用：Itô 积分的计算实例

2.7.1 例子 1：$\int_0^T W_t dW_t$

这是最基本的非平凡 Itô 积分。考虑逼近：取分划 $t_i^n = iT/n$，简单过程：

$$f_t^{(n)} = \sum_{i=0}^{n-1} W_{t_i^n} \mathbf{1}_{(t_i^n, t_{i+1}^n]}(t)$$

则：

$$\int_0^T f_t^{(n)} dW_t = \sum_{i=0}^{n-1} W_{t_i^n}(W_{t_{i+1}^n} - W_{t_i^n})$$

利用恒等式 $W_{t_i^n}\Delta W_i = \frac{1}{2}(W_{t_{i+1}^n}^2 - W_{t_i^n}^2 - (\Delta W_i)^2)$，得：

$$\int_0^T f_t^{(n)} dW_t = \frac{1}{2}W_T^2 - \frac{1}{2}\sum_{i=0}^{n-1}(\Delta W_i)^2$$

取极限，由二次变差 $\sum(\Delta W_i)^2 \to T$，得：

$$\int_0^T W_t dW_t = \frac{1}{2}W_T^2 - \frac{1}{2}T$$

注意：这与经典微积分的结果 $\int x dx = \frac{1}{2}x^2$ 相差一项 $-\frac{1}{2}T$，这正是 Itô 积分的特征。

2.7.2 例子 2：$\int_0^T t dW_t$

这里被积函数是确定性的。可以直接计算：

$$\mathbb{E}\left[\left(\int_0^T t dW_t\right)^2\right] = \int_0^T t^2 dt = \frac{T^3}{3}$$

实际上，$\int_0^T t dW_t \sim N(0, \frac{T^3}{3})$。

2.7.3 例子 3：$\int_0^T e^{W_t} dW_t$

我们将在下一章学习 Itô 公式后轻松计算这个积分。届时将看到：

$$\int_0^T e^{W_t} dW_t = e^{W_T} - 1 - \frac{1}{2}\int_0^T e^{W_t} dt$$

这再次显示了 Itô 积分与经典积分的差异。

本章总结

本章系统构造了 Itô 积分，要点如下：

1. **构造哲学**：放弃逐路径定义，采用 L^2 极限方法

2. **三步构造**：简单过程明确定义 → 一般过程用简单过程逼近 → L^2 极限

3. **核心性质**：线性性、适应性、连续性、鞅性、零期望、Itô 等距

4. **随机测度视角**：Itô 积分定义了正交鞅测度，不能分解为概率测度与固定测度的乘积

5. **与经典积分的对比**：关键在于 dW_t 不是通常的测度，而是”随机测度”

6. **计算实例**：展示了基本计算方法，预示了 Itô 公式的必要性

Itô 积分是随机分析的基石。在下一章，我们将学习 Itô 公式——随机微积分的基本定理，它将告诉我们如何对随机过程的函数进行微分，从而为求解随机微分方程提供系统工具。

特别重要的是理解：Itô 积分不是对每个样本路径单独定义的积分，而是整体在 L^2 意义下定义的线性算子。这种定义方式体现了概率论的本质特征——我们关心的是随机对象的统计性质，而非每个具体实现。

历史注记

Itô 积分的概念由日本数学家伊藤清（Kiyosi Itô）在 1940 年代系统提出。他的原始论文发表在 1944 年的《日本帝国学院院报》上。Itô 的突破在于放弃了样本路径的观点，转而采用均方收敛的极限方法。这一理论在 1960 年代由 Meyer、Kunita、Watanabe 等进一步发展，并与鞅论结合。Itô 积分现已成为金融数学、随机控制、物理等多个领域的标准工具。2006 年，伊藤清因其贡献获得高斯奖，这是随机分析领域的最高荣誉之一。

Chapter 3

Itô 公式：随机微积分的基本定理

3.1 引言：从经典微积分到随机微积分

在经典微积分中，链式法则是基本工具：若 $f \in C^1$ 且 X_t 可微，则

$$\frac{d}{dt}f(X_t) = f'(X_t)\frac{dX_t}{dt}$$

或等价地

$$df(X_t) = f'(X_t)dX_t$$

然而在随机世界，布朗运动 W_t 几乎处处不可微，其微分 dW_t 在经典意义下无定义。更根本地，布朗运动具有非零的二次变差 $(dW_t)^2 = dt$，这使得泰勒展开中的二阶项不再可以忽略。Itô 公式正是经典链式法则在随机环境下的修正版本。

3.1.1 三种操作的打包视角

回顾前两章引入的三种基本操作：

1. 对时间 t 的积分（确定性累积）
2. 对样本 ω 的积分（期望运算）
3. Itô 积分（随机累积）

Itô 公式的精妙之处在于：它将处理随机微分所需的所有操作 ** 打包 ** 成一个统一的公式。应用 Itô 公式时，我们实际上同时在处理这三种操作，只是被组织在一个简洁的框架中。

3.2 一维 Itô 公式

3.2.1 基本形式

定理 3.1 (一维 Itô 公式). *设 $f \in C^2(\mathbb{R})$，$\{X_t\}$ 为 Itô 过程：*

$$dX_t = \mu_t dt + \sigma_t dW_t$$

其中 μ_t, σ_t 适应且满足适当可积条件。则对任意 $t \geq 0$，

$$df(X_t) = f'(X_t)dX_t + \frac{1}{2}f''(X_t)(dX_t)^2$$

其中 $(dX_t)^2$ 按以下乘法表计算：

$$\begin{aligned} dt \cdot dt &= 0, \\ dt \cdot dW_t &= 0, \\ dW_t \cdot dW_t &= dt \end{aligned}$$

证明思路. 取分划 $0 = t_0 < t_1 < \cdots < t_n = t$，泰勒展开：

$$f(X_{t_{i+1}}) - f(X_{t_i}) = f'(X_{t_i})\Delta X_i + \frac{1}{2}f''(\xi_i)(\Delta X_i)^2$$

其中 $\xi_i \in [X_{t_i}, X_{t_{i+1}}]$。代入 $\Delta X_i = \mu_i \Delta t_i + \sigma_i \Delta W_i$，得：

$$(\Delta X_i)^2 = \sigma_i^2(\Delta W_i)^2 + 2\mu_i\sigma_i\Delta t_i\Delta W_i + \mu_i^2(\Delta t_i)^2$$

求和并取极限：

- $\sum f'(X_{t_i})\mu_i\Delta t_i \to \int_0^t f'(X_s)\mu_s ds$（黎曼积分）
- $\sum f'(X_{t_i})\sigma_i\Delta W_i \to \int_0^t f'(X_s)\sigma_s dW_s$（Itô 积分）
- $\sum \frac{1}{2}f''(X_{t_i})\sigma_i^2(\Delta W_i)^2 \to \frac{1}{2}\int_0^t f''(X_s)\sigma_s^2 ds$（二次变差）
- 交叉项和高阶项收敛到零

□

3.2.2 乘法表的解释

Itô 公式中的乘法表反映了不同微分的阶数：

$$
\begin{aligned}
dt \cdot dt &= 0 && \text{（二阶小量，可忽略）} \\
dt \cdot dW_t &= 0 && \text{（}dt^{1/2}\text{ 阶，可忽略）} \\
dW_t \cdot dW_t &= dt && \text{（一阶小量，必须保留）}
\end{aligned}
$$

这种”阶数计算”是理解 Itô 公式的关键。在经典微积分中，$dx \cdot dx$ 是二阶小量；但在随机微积分中，$dW_t \cdot dW_t$ 与 dt 同阶。

3.2.3 展开形式

将 $dX_t = \mu_t dt + \sigma_t dW_t$ 代入 Itô 公式，得到展开形式：

$$df(X_t) = \left[f'(X_t)\mu_t + \frac{1}{2} f''(X_t)\sigma_t^2 \right] dt + f'(X_t)\sigma_t dW_t$$

这个形式清晰地展示了 Itô 公式如何打包三种操作：

- dt 项：包含经典项 $f'(X_t)\mu_t dt$ 和 Itô 修正项 $\frac{1}{2} f''(X_t)\sigma_t^2 dt$
- dW_t 项：$f'(X_t)\sigma_t dW_t$，这是一个 Itô 积分

如果我们取期望（对 ω 积分），dW_t 项消失（期望为零），得到：

$$d\mathbb{E}[f(X_t)] = \mathbb{E}\left[f'(X_t)\mu_t + \frac{1}{2} f''(X_t)\sigma_t^2 \right] dt$$

这又是一个对时间 t 的积分。可见三种操作自然地交织在一起。

3.3 经典例子的重新审视

3.3.1 几何布朗运动的推导

在第 1 章，我们通过启发式推导得到了几何布朗运动 S_t 的解。现在用 Itô 公式严格推导。

设 S_t 满足：

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

取 $f(x) = \log x$，则 $f'(x) = 1/x$，$f''(x) = -1/x^2$。由 Itô 公式：

$$\begin{aligned} d(\log S_t) &= \frac{1}{S_t} dS_t + \frac{1}{2}\left(-\frac{1}{S_t^2}\right)(dS_t)^2 \\ &= \frac{1}{S_t}(\mu S_t dt + \sigma S_t dW_t) - \frac{1}{2S_t^2}(\sigma^2 S_t^2 dt) \\ &= \mu dt + \sigma dW_t - \frac{1}{2}\sigma^2 dt \\ &= (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW_t \end{aligned}$$

这里 $(dS_t)^2 = \sigma^2 S_t^2 dt$，因为 $dt \cdot dW_t$ 和 $dt \cdot dt$ 项为零。

积分得：

$$\log S_t = \log S_0 + (\mu - \frac{1}{2}\sigma^2)t + \sigma W_t$$

即

$$S_t = S_0 \exp\left((\mu - \frac{1}{2}\sigma^2)t + \sigma W_t\right)$$

3.3.2 Itô 积分的函数：$\int_0^t W_s dW_s$

在第 2 章我们计算过 $\int_0^t W_s dW_s = \frac{1}{2}W_t^2 - \frac{1}{2}t$。现在用 Itô 公式验证。

设 $f(x) = \frac{1}{2}x^2$，则 $f'(x) = x$，$f''(x) = 1$。取 $X_t = W_t$，则 $dX_t = dW_t$ $(\mu = 0, \sigma = 1)$。由 Itô 公式：

$$d\left(\frac{1}{2}W_t^2\right) = W_t dW_t + \frac{1}{2} \cdot 1 \cdot dt$$

即

$$\frac{1}{2}W_t^2 = \int_0^t W_s dW_s + \frac{1}{2}t$$

整理得：

$$\int_0^t W_s dW_s = \frac{1}{2}W_t^2 - \frac{1}{2}t$$

注意：若用经典微积分，我们会得到 $\frac{1}{2}W_t^2$，缺少 $-\frac{1}{2}t$ 项。这项正是 Itô 修正。

3.3.3 指数鞅（Doléans-Dade 指数）

设 $X_t = \sigma W_t - \frac{1}{2}\sigma^2 t$，考虑 $f(x) = e^x$。则 $f'(x) = f''(x) = e^x$。由 Itô 公式：

$$\begin{aligned} d(e^{X_t}) &= e^{X_t} dX_t + \frac{1}{2} e^{X_t} (dX_t)^2 \\ &= e^{X_t}(\sigma dW_t - \frac{1}{2}\sigma^2 dt) + \frac{1}{2} e^{X_t} \sigma^2 dt \\ &= \sigma e^{X_t} dW_t \end{aligned}$$

因此 $M_t = e^{\sigma W_t - \frac{1}{2}\sigma^2 t}$ 满足 $dM_t = \sigma M_t dW_t$，这是一个鞅（无漂移项），称为指数鞅。

3.4 多维 Itô 公式

3.4.1 向量形式

设 $\mathbf{W}_t = (W_t^1, \ldots, W_t^m)$ 为 m 维布朗运动，$\mathbf{X}_t = (X_t^1, \ldots, X_t^d)$ 满足：

$$d\mathbf{X}_t = \boldsymbol{\mu}_t dt + \boldsymbol{\sigma}_t d\mathbf{W}_t$$

其中 $\boldsymbol{\mu}_t \in \mathbb{R}^d$，$\boldsymbol{\sigma}_t \in \mathbb{R}^{d\times m}$。

定理 3.2 (多维 Itô 公式)**.** 设 $f \in C^{1,2}([0,\infty) \times \mathbb{R}^d)$，即 $f(t,x)$ 关于 t 一次连续可微，关于 x 二次连续可微。则

$$df(t, \mathbf{X}_t) = \frac{\partial f}{\partial t} dt + \sum_{i=1}^{d} \frac{\partial f}{\partial x_i} dX_t^i + \frac{1}{2} \sum_{i,j=1}^{d} \frac{\partial^2 f}{\partial x_i \partial x_j} dX_t^i dX_t^j$$

其中微分乘积按以下规则计算：

$$\begin{aligned} dt \cdot dt &= 0, \\ dt \cdot dW_t^i &= 0, \\ dW_t^i \cdot dW_t^j &= \delta_{ij} dt \end{aligned}$$

其中 δ_{ij} 为 *Kronecker delta* 符号。

3.4.2 矩阵形式

记梯度 $\nabla f = \left(\frac{\partial f}{\partial x_1}, \ldots, \frac{\partial f}{\partial x_d}\right)^T$，Hessian 矩阵 $Hf = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}\right)_{d\times d}$。则 Itô 公式可写为：

$$df = \frac{\partial f}{\partial t}dt + (\nabla f)^T d\mathbf{X}_t + \frac{1}{2}\operatorname{tr}\left(Hf \cdot d\mathbf{X}_t d\mathbf{X}_t^T\right)$$

其中 $d\mathbf{X}_t d\mathbf{X}_t^T = \boldsymbol{\sigma}_t \boldsymbol{\sigma}_t^T dt$。

3.4.3 乘积法则

作为多维公式的特例，考虑两个 Itô 过程的乘积。

设 X_t, Y_t 满足：

$$\begin{aligned} dX_t &= \mu_t^X dt + \sigma_t^X dW_t \\ dY_t &= \mu_t^Y dt + \sigma_t^Y dW_t \end{aligned}$$

取 $f(x,y) = xy$，则 $\frac{\partial f}{\partial x} = y$，$\frac{\partial f}{\partial y} = x$，$\frac{\partial^2 f}{\partial x^2} = \frac{\partial^2 f}{\partial y^2} = 0$，$\frac{\partial^2 f}{\partial x \partial y} = 1$。

由 Itô 公式：

$$\begin{aligned} d(X_t Y_t) &= Y_t dX_t + X_t dY_t + dX_t dY_t \\ &= Y_t dX_t + X_t dY_t + \sigma_t^X \sigma_t^Y dt \end{aligned}$$

这就是随机微积分中的乘积法则。注意多了交叉项 $\sigma_t^X \sigma_t^Y dt$。

3.5 Itô 公式的证明细节

3.5.1 简单情形的严格证明

为展示证明的本质，考虑最简单情形：$f \in C^2$ 且 $X_t = W_t$。

$f(W_t)$ 的 Itô 公式证明. 设 $\Pi_n : 0 = t_0 < t_1 < \cdots < t_n = t$ 为分划，$\|\Pi_n\| = \max_i |t_i - t_{i-1}| \to 0$。泰勒展开：

$$f(W_t) - f(W_0) = \sum_{i=1}^{n} \left[f'(W_{t_{i-1}})\Delta W_i + \frac{1}{2} f''(W_{t_{i-1}})(\Delta W_i)^2 + R_i \right]$$

其中余项 $R_i = \frac{1}{2}[f''(\xi_i) - f''(W_{t_{i-1}})](\Delta W_i)^2$，$\xi_i$ 介于 $W_{t_{i-1}}$ 和 W_{t_i} 之间。

三项分别处理：

1. $\sum f'(W_{t_{i-1}})\Delta W_i \to \int_0^t f'(W_s)dW_s$（Itô 积分定义）

2. $\sum \frac{1}{2} f''(W_{t_{i-1}})(\Delta W_i)^2 \to \frac{1}{2}\int_0^t f''(W_s)ds$

   这是因为：$(\Delta W_i)^2 = \Delta t_i + (\Delta W_i)^2 - \Delta t_i$，而

$$\sum f''(W_{t_{i-1}})\Delta t_i \to \int_0^t f''(W_s)ds$$

   $$\mathbb{E}\left[\left(\sum f''(W_{t_{i-1}})[(\Delta W_i)^2 - \Delta t_i]\right)^2\right] = \sum \mathbb{E}[(f''(W_{t_{i-1}}))^2]\mathrm{Var}((\Delta W_i)^2) \to 0$$

   其中 $\mathrm{Var}((\Delta W_i)^2) = 2(\Delta t_i)^2$。

3. 余项 R_i：由 f'' 的一致连续性，对任意 $\epsilon > 0$，当 $\|\Pi_n\|$ 足够小时，$|f''(\xi_i) - f''(W_{t_{i-1}})| < \epsilon$。故

$$\left|\sum R_i\right| \le \frac{\epsilon}{2}\sum(\Delta W_i)^2 \to \frac{\epsilon}{2}t$$

   由 ϵ 任意性，余项收敛到零。

□

3.5.2 一般情形的证明策略

对一般 Itô 过程 $X_t = \int_0^t \mu_s ds + \int_0^t \sigma_s dW_s$，证明策略为：

1. 先证 f 为多项式的特殊情况

2. 用多项式逼近一般 C^2 函数

3. 验证逼近的收敛性

这种方法体现了现代分析中”先处理代数上简单的对象，再用逼近处理一般对象”的思想。

3.6 Itô 公式的应用：随机微分方程求解

3.6.1 线性 SDE 的通解

考虑一般线性 SDE：

$$dX_t = (a_t X_t + b_t)dt + (c_t X_t + d_t)dW_t$$

这类方程可用 Itô 公式求解。先考虑齐次情形（$b_t = d_t = 0$）：

$$dX_t = a_t X_t dt + c_t X_t dW_t$$

猜测解形式为 $X_t = \Phi_t Y_t$，其中 Φ_t 满足：

$$d\Phi_t = a_t \Phi_t dt + c_t \Phi_t dW_t, \quad \Phi_0 = 1$$

由指数鞅的推广可得：

$$\Phi_t = \exp\left(\int_0^t (a_s - \frac{1}{2}c_s^2)ds + \int_0^t c_s dW_s\right)$$

再令 $Y_t = \Phi_t^{-1} X_t$，用 Itô 乘积法则可得 dY_t 的方程，最终解得通解。

3.6.2 Ornstein-Uhlenbeck 过程的再推导

在第 1 章，我们通过积分因子法求解了 OU 过程：

$$dX_t = \theta(\mu - X_t)dt + \sigma dW_t$$

现在用 Itô 公式验证。令 $Y_t = e^{\theta t} X_t$，则：

$$\begin{aligned} dY_t &= e^{\theta t} dX_t + \theta e^{\theta t} X_t dt \\ &= e^{\theta t}[\theta(\mu - X_t)dt + \sigma dW_t] + \theta e^{\theta t} X_t dt \\ &= \theta \mu e^{\theta t} dt + \sigma e^{\theta t} dW_t \end{aligned}$$

积分得：

$$Y_t = Y_0 + \mu(e^{\theta t} - 1) + \sigma \int_0^t e^{\theta s} dW_s$$

即

$$X_t = e^{-\theta t} X_0 + \mu(1 - e^{-\theta t}) + \sigma e^{-\theta t} \int_0^t e^{\theta s} dW_s$$

3.7 与 Stratonovich 积分的比较

3.7.1 Stratonovich 积分的定义

除了 Itô 积分，还有另一种重要的随机积分——Stratonovich 积分，记为 $\int_0^t f_s \circ dW_s$。其定义为：

$$\int_0^t f_s \circ dW_s = \lim_{\|\Pi\|\to 0} \sum_{i=0}^{n-1} \frac{f(t_i)+f(t_{i+1})}{2}(W_{t_{i+1}} - W_{t_i})$$

与 Itô 积分的左端点取值不同，Stratonovich 取区间两端点的平均。

3.7.2 Stratonovich 微积分公式

Stratonovich 积分满足经典链式法则：若 $dX_t = \mu_t dt + \sigma_t \circ dW_t$(Stratonovich 意义)，则

$$df(X_t) = f'(X_t) \circ dX_t$$

没有二阶修正项。这是 Stratonovich 积分的优点，但代价是失去了鞅性。

3.7.3 Itô 与 Stratonovich 的转换关系

两者可通过以下公式转换：

$$\int_0^t f_s \circ dW_s = \int_0^t f_s dW_s + \frac{1}{2}\langle f, W\rangle_t$$

其中 $\langle f, W\rangle_t$ 是 f 与 W 的二次协变差。特别地，若 $f_t = \sigma(X_t)$ 且 $dX_t = \mu_t dt + \sigma(X_t)dW_t$，则

$$\langle f, W\rangle_t = \int_0^t \sigma'(X_s)\sigma(X_s)ds$$

因此

$$\sigma(X_t) \circ dW_t = \sigma(X_t)dW_t + \frac{1}{2}\sigma'(X_t)\sigma(X_t)dt$$

3.8 Itô 公式的推广

3.8.1 时间依赖的 Itô 公式

若 $f = f(t, x)$ 显含时间，Itô 公式为：

$$df(t, X_t) = \frac{\partial f}{\partial t}dt + \frac{\partial f}{\partial x}dX_t + \frac{1}{2}\frac{\partial^2 f}{\partial x^2}(dX_t)^2$$

3.8.2 跳跃过程的 Itô 公式（Itô-Lévy 公式）

若 X_t 为跳跃扩散过程：

$$dX_t = \mu_t dt + \sigma_t dW_t + \int_{\mathbb{R}} \gamma_t(z)\tilde{N}(dt, dz)$$

其中 $\tilde{N}$ 为补偿泊松随机测度，则 Itô 公式包含跳跃项：

$$df(X_t) = f'(X_{t-})dX_t^c + \frac{1}{2}f''(X_{t-})d[X^c]_t + [f(X_{t-} + \Delta X_t) - f(X_{t-}) - f'(X_{t-})\Delta X_t]$$

其中 X_t^c 为连续部分，$[X^c]_t$ 为其二次变差。

3.8.3 无限维情形：随机偏微分方程

对 Hilbert 空间值过程，也有相应的 Itô 公式，这是研究随机偏微分方程的基础。

本章总结

Itô 公式是随机分析的基本定理，要点如下：

1. **核心思想**：由于布朗运动的二次变差非零，泰勒展开中的二阶项必须保留
2. **乘法表**：$dt^2 = 0$，$dt\,dW_t = 0$，$dW_t^2 = dt$，反映了不同微分的阶数
3. **打包特性**：Itô 公式将处理随机微分所需的三种操作（时间积分、样本积分、Itô 积分）组织在一个框架中

4. **应用广泛**：求解 SDE、计算随机积分、研究过程变换

5. **与经典微积分的对比**：多出二阶修正项，这是随机微积分的本质特征

6. **与 Stratonovich 积分的联系**：通过二次协变差相互转换

特别重要的是理解：Itô 公式不是对经典链式法则的小修改，而是反映了随机世界与确定性世界的根本差异——在随机世界中，二阶变差贡献一阶效应。

从教学角度看，掌握 Itô 公式的最佳方式是通过大量实例练习，同时理解其背后的”三种操作打包”的哲学。在下一章，我们将应用 Itô 公式深入研究随机微分方程的解理论。

历史注记

Itô 公式由伊藤清在 1944 年首次提出，是他整个随机分析理论的核心。最初的证明使用了多项式逼近技术。20 世纪 60 年代，Kunita 和 Watanabe 推广到多维情形，Meyer 建立了更一般的半鞅随机积分理论。Stratonovich 积分由苏联数学家 Stratonovich 在 1966 年提出，在物理和工程中广泛应用。Itô 公式的现代形式已成为金融数学、随机控制、统计物理等领域的标准工具。2014 年，Fields 奖得主 Martin Hairer 的正则结构理论可以看作 Itô 公式在高度奇异情况下的推广。

Chapter 4

随机微分方程的解理论

4.1 引言：SDE 解的基本概念

在前三章中，我们已经熟悉了布朗运动、Itô 积分和 Itô 公式。现在，我们将这些工具系统应用于随机微分方程（SDE）的研究。与常微分方程（ODE）理论类似，SDE 解理论的核心问题是：在什么条件下解存在、唯一，具有什么性质？

然而，随机性带来了新的复杂性。在 ODE 中，我们谈论的是确定性的解函数；在 SDE 中，解是一个随机过程。这种本质差异体现在解概念的多个层次上。

4.1.1 SDE 的一般形式

考虑如下形式的 SDE：

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t, \quad t \in [0, T]$$

其中：

- W_t 是标准布朗运动
- $\mu : [0, T] \times \mathbb{R} \to \mathbb{R}$ 是漂移系数
- $\sigma : [0, T] \times \mathbb{R} \to \mathbb{R}$ 是扩散系数

- 初始条件 X_0 是一个随机变量，通常假设与布朗运动独立

等价的积分形式为：

$$X_t = X_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

注意右边的第二项是 Itô 积分，其定义需要被积过程 $\sigma(s, X_s)$ 适应于布朗运动的自然过滤。这暗示了我们对解的要求：$\{X_t\}$ 应该是适应过程。

4.2 强解与弱解：两种解概念

在 ODE 理论中，解的概念相对单一：满足方程的函数。但在 SDE 中，由于随机性的参与，我们有两种不同强度的解概念。

4.2.1 强解

定义 4.1 (强解)**.** *给定概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$，其上的布朗运动 $\{W_t\}$ 和初始随机变量 X_0。随机过程 $\{X_t\}$ 称为 SDE 的强解，如果：*

1. *$\{X_t\}$ 适应于由 X_0 和 $\{W_t\}$ 生成的过滤 $\mathcal{F}_t = \sigma(X_0, W_s : 0 \le s \le t)$*
2. *几乎必然地，对每个 $t \in [0, T]$，有*

$$X_t = X_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

3. *路径连续：$t \mapsto X_t$ 几乎必然连续*

强解的特点在于：解过程被构造为给定布朗运动和初始条件的函数。换句话说，如果我们知道布朗运动的整个路径和初始值，就能确定解的路径。

4.2.2 弱解

定义 4.2 (弱解)**.** *SDE 的弱解是一个五元组 $(\Omega, \mathcal{F}, \mathbb{P}, \{W_t\}, \{X_t\})$，满足：*

1. *$(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间*

2. $\{W_t\}$ 是其上的布朗运动

3. $\{X_t\}$ 适应于 $\{W_t\}$ 的自然过滤

4. 几乎必然地，对每个 $t \in [0, T]$，有

$$X_t = X_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

弱解与强解的关键区别在于：在弱解中，我们可以”选择”概率空间和布朗运动，使得方程成立；而在强解中，概率空间和布朗运动是预先给定的。

4.2.3 两种解概念的关系

1. **强解一定是弱解**：这是显然的，因为强解满足弱解的所有条件。

2. **弱解不一定是强解**：存在一些 SDE，它们有弱解但没有强解。经典的例子是 Tanaka 方程：

$$dX_t = \mathrm{sgn}(X_t)dW_t, \quad X_0 = 0$$

其中 $\mathrm{sgn}(x) = 1_{\{x>0\}} - 1_{\{x<0\}}$。这个方程没有强解，但有弱解（实际上是 $|W_t|$）。

3. **路径唯一性与强解存在性**：Yamada-Watanabe 定理建立了重要联系：如果弱解存在且路径唯一（即任意两个弱解在相同概率空间上有相同的路径），那么强解存在。

弱解概念的出现体现了随机分析的一个深刻思想：有时候，我们更关心过程的统计性质（分布），而非其与特定噪声的具体关系。

4.3 存在唯一性定理

4.3.1 Lipschitz 条件与线性增长条件

与 ODE 理论类似，保证 SDE 解存在唯一的经典条件是系数满足 Lipschitz 条件和线性增长条件。

定义 4.3 (Lipschitz 条件). *存在常数 $L > 0$，使得对任意 $t \in [0,T]$ 和 $x, y \in \mathbb{R}$,*

$$|\mu(t,x) - \mu(t,y)| + |\sigma(t,x) - \sigma(t,y)| \leq L|x-y|$$

定义 4.4 (线性增长条件). *存在常数 $K > 0$, 使得对任意 $t \in [0,T]$ 和 $x \in \mathbb{R}$,*

$$|\mu(t,x)| + |\sigma(t,x)| \leq K(1+|x|)$$

Lipschitz 条件保证了解的局部行为良好（类似于 ODE 中的条件），线性增长条件防止解在有限时间内爆破。

4.3.2 强解的存在唯一性定理

定理 4.5 (SDE 强解的存在唯一性). *假设：*

1. *系数 μ, σ 满足 Lipschitz 条件和线性增长条件*
2. *初始条件 X_0 满足 $\mathbb{E}[X_0^2] < \infty$ 且与布朗运动独立*

则 SDE 存在唯一的强解 $\{X_t\}$，且满足：

$$\mathbb{E}\left[\sup_{0\leq t\leq T} |X_t|^2\right] < \infty$$

4.3.3 Picard 迭代：压缩映射原理的应用

证明的核心是 Picard 迭代法, 这与 ODE 理论的证明思想一脉相承, 但需要处理 Itô 积分的特殊性质。

定义算子 $\Phi : \mathcal{H}^2 \to \mathcal{H}^2$ 为：

$$(\Phi X)_t = X_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s$$

其中 $\mathcal{H}^2$ 是所有适应连续过程 X 满足 $\mathbb{E}[\sup_{0\leq t\leq T} |X_t|^2] < \infty$ 的空间。

迭代序列定义为：

$$X_t^{(0)} = X_0, \quad X^{(n+1)} = \Phi(X^{(n)}), \quad n \geq 0$$

证明思路. 分三步：

1. **良定性**：证明 Φ 确实将 $\mathcal{H}^2$ 映射到自身。这需要线性增长条件和 Itô 积分的估计。

2. **压缩性**：证明存在 $T_0 > 0$ 使得在区间 $[0, T_0]$ 上，Φ 是压缩映射。即存在 $\rho < 1$ 使得

$$\|\Phi X - \Phi Y\|_{\mathcal{H}^2} \leq \rho \|X - Y\|_{\mathcal{H}^2}$$

   这需要 Lipschitz 条件和 BDG 不等式。

3. **逐段延拓**：将 $[0, T]$ 分成若干小段，在每段上应用压缩映射原理，然后将解粘接起来。

□

注 4.6 (压缩性的技术细节). *压缩性的证明需要估计：*

$$\mathbb{E}\left[\sup_{0\leq s\leq t} |(\Phi X)_s - (\Phi Y)_s|^2\right] \leq C \int_0^t \mathbb{E}[|X_s - Y_s|^2] ds$$

其中常数 C 依赖于 Lipschitz 常数。由 Gronwall 引理可得唯一性。当 t 足够小时，$Ct < 1$，得到压缩性。

4.3.4 矩估计

解的二阶矩可以被初始条件和系数的增长常数控制：

$$\mathbb{E}[|X_t|^2] \leq (1 + \mathbb{E}[|X_0|^2])e^{Ct} - 1$$

其中 C 依赖于 K。这是线性增长条件的结果，防止解指数增长太快。

4.4 解的性质研究

4.4.1 马氏性

定理 4.7 (SDE 解的马氏性). *在 Lipschitz 条件下，SDE 的强解 $\{X_t\}$ 是马氏过程。即对任意有界可测函数 f 和 $0 \leq s \leq t \leq T$，*

$$\mathbb{E}[f(X_t)|\mathcal{F}_s] = \mathbb{E}[f(X_t)|X_s] \quad a.s.$$

证明思路. 由于解是强解，X_t 可以表示为 X_s 和 $\{W_u - W_s : s \le u \le t\}$ 的函数。而布朗增量与 $\mathcal{F}_s$ 独立，因此条件期望只依赖于 X_s。 □

如果系数不显含时间（自治系统），则解是时齐马氏过程。

4.4.2 强马氏性

更强的结果是强马氏性：对任意停时 τ，

$$\mathbb{E}[f(X_{\tau+t})|\mathcal{F}_\tau] = \mathbb{E}[f(X_{\tau+t})|X_\tau] \quad 在\{\tau < \infty\}上$$

布朗运动本身具有强马氏性，由它驱动的 SDE 在适当条件下也继承这一性质。

4.4.3 扩散过程与生成元

如果解 $\{X_t\}$ 是时齐马氏过程，其生成元（无穷小生成元）为：

$$\mathcal{L}f(x) = \lim_{t \downarrow 0} \frac{\mathbb{E}[f(X_t)|X_0 = x] - f(x)}{t}$$

对 SDE $dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$，生成元为二阶微分算子：

$$\mathcal{L} = \mu(x)\frac{d}{dx} + \frac{1}{2}\sigma^2(x)\frac{d^2}{dx^2}$$

这正是 Itô 公式中 dt 项的系数（去掉期望）。这建立了 SDE、马氏过程和二阶椭圆算子之间的深刻联系。

4.5 矩方程与 Fokker-Planck 方程

4.5.1 矩方程

对 SDE 取期望，利用 Itô 积分期望为零的性质，可得均值方程：

$$\frac{d}{dt}\mathbb{E}[X_t] = \mathbb{E}[\mu(t, X_t)]$$

一般这不是关于 $\mathbb{E}[X_t]$ 的闭方程，除非 μ 是线性的。类似地，可以推导二阶矩、高阶矩的方程。

例 4.8 (几何布朗运动的矩). 对 $dS_t = \mu S_t dt + \sigma S_t dW_t$，均值方程：

$$\frac{d}{dt}\mathbb{E}[S_t] = \mu\mathbb{E}[S_t] \quad \Rightarrow \quad \mathbb{E}[S_t] = S_0 e^{\mu t}$$

二阶矩：

$$\frac{d}{dt}\mathbb{E}[S_t^2] = (2\mu + \sigma^2)\mathbb{E}[S_t^2] \quad \Rightarrow \quad \mathbb{E}[S_t^2] = S_0^2 e^{(2\mu+\sigma^2)t}$$

4.5.2 Fokker-Planck 方程（Kolmogorov 向前方程）

如果解有密度 $p(t,x)$，即 $\mathbb{P}(X_t \in dx) = p(t,x)dx$，则密度满足 Fokker-Planck 方程：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu(t,x)p] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[\sigma^2(t,x)p]$$

这是确定性偏微分方程，描述概率密度随时间的演化。

例 4.9 (OU 过程的平稳分布). *OU* 过程：$dX_t = \theta(\mu - X_t)dt + \sigma dW_t$ 稳态时 $\frac{\partial p}{\partial t} = 0$，得：

$$0 = -\frac{d}{dx}[\theta(\mu - x)p] + \frac{1}{2}\frac{d^2}{dx^2}[\sigma^2 p]$$

解为高斯密度：$p(x) = \frac{1}{\sqrt{2\pi\sigma^2/(2\theta)}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2/(2\theta)}\right)$

4.5.3 向后方程与 Feynman-Kac 公式

Kolmogorov 向后方程描述期望值作为初始条件的函数：

$$\frac{\partial u}{\partial t} + \mu(x)\frac{\partial u}{\partial x} + \frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2} = 0, \quad u(T,x) = f(x)$$

其中 $u(t,x) = \mathbb{E}[f(X_T)|X_t = x]$。

Feynman-Kac 公式建立了 SDE 与线性抛物 PDE 之间的对应：上述 PDE 的解可以表示为 SDE 的条件期望。

4.6 数值方法：Euler-Maruyama 方法

4.6.1 方法构造

对于 SDE $dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$，Euler-Maruyama 方法是 Euler 方法在随机情形的推广。

取分划 $0 = t_0 < t_1 < \cdots < t_N = T$，步长 $\Delta t = T/N$。定义近似解：

$$Y_{n+1} = Y_n + \mu(Y_n)\Delta t + \sigma(Y_n)\Delta W_n$$

其中 $\Delta W_n = W_{t_{n+1}} - W_{t_n} \sim N(0, \Delta t)$。

4.6.2 收敛性

定义 4.10 (强收敛). *数值方法强收敛阶为 γ，如果存在常数 C 使得*

$$\mathbb{E}[|X_T - Y_N|] \leq C(\Delta t)^\gamma$$

定义 4.11 (弱收敛). *数值方法弱收敛阶为 γ，如果对充分光滑的函数 f，存在常数 C 使得*

$$|\mathbb{E}[f(X_T)] - \mathbb{E}[f(Y_N)]| \leq C(\Delta t)^\gamma$$

定理 4.12 (Euler-Maruyama 方法的收敛性). *在 Lipschitz 条件下，Euler-Maruyama 方法强收敛阶为 1/2，弱收敛阶为 1。*

4.6.3 Milstein 方法：提高强收敛阶

为了获得更高的强收敛阶，需要在离散化中包含 Itô 公式的更高阶项。Milstein 方法：

$$Y_{n+1} = Y_n + \mu(Y_n)\Delta t + \sigma(Y_n)\Delta W_n + \frac{1}{2}\sigma(Y_n)\sigma'(Y_n)[(\Delta W_n)^2 - \Delta t]$$

其中最后一项来自 Itô 公式的二阶展开。Milstein 方法的强收敛阶为 1。

注 4.13 (多维情形的困难). *在一维情形，Milstein 方法相对简单。但在多维情形，涉及不同布朗运动分量的交叉项，需要近似多重 Itô 积分，这更加复杂。*

4.7 系数不满足 Lipschitz 条件的情形

许多重要的物理和金融模型不满足经典的 Lipschitz 条件，需要专门处理。

4.7.1 局部 Lipschitz 条件

定义 4.14 (局部 Lipschitz 条件). 对任意 $R > 0$，存在常数 L_R 使得对 $|x|, |y| \leq R$,

$$|\mu(x) - \mu(y)| + |\sigma(x) - \sigma(y)| \leq L_R|x - y|$$

局部 Lipschitz 条件不能保证全局解的存在，因为解可能在有限时间爆破。

4.7.2 Yamada-Watanabe 条件

对于一维 SDE，存在比 Lipschitz 更弱的条件保证解的唯一性。

定理 4.15 (Yamada-Watanabe). 假设：

1. μ *Lipschitz* 连续
2. σ 满足：存在递增函数 $\rho : [0, \infty) \to [0, \infty)$，使得 $\int_0^\epsilon \rho^{-2}(u)du = \infty$ 对所有 $\epsilon > 0$，且
$$|\sigma(x) - \sigma(y)| \leq \rho(|x - y|)$$

则解路径唯一。

例如，取 $\rho(u) = \sqrt{u}$，则 $\int_0^\epsilon u^{-1}du = \infty$，因此 σ 的 1/2-Hölder 连续性足以保证唯一性。这包含了 $\sigma(x) = \sqrt{|x|}$ 等重要情形。

4.7.3 爆破时间

如果系数增长太快，解可能在有限时间趋于无穷。例如，考虑：

$$dX_t = X_t^3 dt + X_t^2 dW_t$$

系数局部 Lipschitz 但超线性增长。可以证明存在停时 τ_∞（爆破时间）使得：

$$\lim_{t \uparrow \tau_\infty} |X_t| = \infty \quad \text{a.s.}$$

但在 τ_∞ 之前，解存在唯一。

4.8 弱解的存在性

当系数不连续或仅可测时，强解可能不存在，但弱解可能存在。

4.8.1 鞅问题方法

Stroock-Varadhan 的鞅问题方法为弱解存在性提供了强大工具。基本思想：不直接构造过程，而是验证某个算子相关的鞅性质。

定义 4.16 (鞅问题)**.** 给定算子 $\mathcal{L}$，概率测度 $\mathbb{P}$ 在路径空间上解决鞅问题，如果对每个 $f \in C^2$，

$$f(X_t) - f(X_0) - \int_0^t \mathcal{L}f(X_s)ds$$

是 $\mathbb{P}$-鞅。

如果 $\mathcal{L}$ 是 SDE 的生成元，则解决鞅问题的测度对应于 SDE 的弱解。

4.8.2 Girsanov 定理与弱解

另一种构造弱解的方法是通过测度变换。从一个简单的参考过程（如布朗运动）出发，通过 Girsanov 定理改变测度，使得在新测度下过程满足目标 SDE。

例 4.17 (带漂移的布朗运动)**.** 设 W_t 是 $\mathbb{P}$ 下的布朗运动。定义新测度：

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \exp\left(\int_0^T \mu_s dW_s - \frac{1}{2}\int_0^T \mu_s^2 ds\right)$$

则在 $\mathbb{Q}$ 下，$\tilde{W}_t = W_t - \int_0^t \mu_s ds$ 是布朗运动。因此 $W_t = \tilde{W}_t + \int_0^t \mu_s ds$ 在 $\mathbb{Q}$ 下满足：

$$dW_t = \mu_t dt + d\tilde{W}_t$$

即 W_t 在 $\mathbb{Q}$ 下是带漂移 μ_t 的布朗运动。

本章总结

本章系统研究了 SDE 的解理论，要点如下：

1. **两种解概念**：强解（给定噪声的具体实现）与弱解（可选择合适的概率空间和噪声）
2. **存在唯一性**：Lipschitz 条件和线性增长条件保证强解存在唯一；更弱的条件（如 Yamada-Watanabe 条件）也可用
3. **解的性质**：马氏性、强马氏性、与扩散过程的联系
4. **矩方程与 PDE**：Fokker-Planck 方程描述密度演化，Feynman-Kac 公式连接 SDE 与 PDE
5. **数值方法**：Euler-Maruyama 方法（强收敛 1/2 阶，弱收敛 1 阶），Milstein 方法（强收敛 1 阶）
6. **非 Lipschitz 情形**：局部 Lipschitz、爆破、弱解存在性
7. **现代方法**：鞅问题、测度变换等弱解构造技术

SDE 解理论的丰富性反映了随机分析作为数学领域的成熟度。从强解到弱解，从路径 wise 唯一性到分布唯一性，从经典条件到各种推广，这一理论体系既严谨又灵活，能够处理从金融到物理的各类应用。

在下一章，我们将深入 SDE 的经典例子与求解技巧，展示如何应用这些理论工具解决具体问题。

历史注记

SDE 解的存在唯一性定理由 Itô 在 1940 年代建立，采用了 Picard 迭代法。20 世纪 60 年代，Stroock 和 Varadhan 发展了鞅问题方法，为弱解理论奠定基础。Yamada 和 Watanabe 在 1971 年给出了非 Lipschitz 系数下唯一性的精细条件。数值方法方面，Maruyama 在 1955 年推广 Euler 方法到随机情形，Milstein 在 1974 年提出高阶方法。这些工作共同构建了现代 SDE 理论的完整框架。

Chapter 5

重要示例与求解技巧

5.1 引言：SDE 求解的策略框架

在前几章中，我们建立了 SDE 的理论基础：存在唯一性、Itô 公式、解的性质等。然而，与常微分方程（ODE）类似，绝大多数 SDE 没有封闭形式的解。本章将系统研究那些可求解的特殊类型，并建立求解 SDE 的策略框架。

求解 SDE 的核心思想是：通过适当的变换，将复杂的 SDE 化为简单的、已知解的 SDE。这一过程与 ODE 中的变量分离法、积分因子法等思想一脉相承，但需要处理随机积分的特殊性质。

我们将重点研究三类可求解的 SDE：

1. **线性 SDE**：系数关于状态变量线性

2. **可分离 SDE**：可通过变换化为线性 SDE

3. **具有对称性的 SDE**：可利用对称性降维或化简

对每一类，我们将给出系统的求解方法，并通过典型例子展示技巧的应用。

5.2 线性随机微分方程

线性 SDE 是最重要且最常出现在应用中的一类，其形式相对简单，但已经能够描述许多有趣的现象。

5.2.1 一维齐次线性 SDE

考虑最简单的情形：

$$dX_t = a(t)X_t dt + b(t)X_t dW_t, \quad X_0 = x_0$$

其中 $a(t), b(t)$ 为确定性函数（或适应过程）。这类方程出现在几何布朗运动、随机利率模型等中。

求解方法：Itô 公式直接应用

设 $f(x) = \log x$，则 $f'(x) = 1/x$，$f''(x) = -1/x^2$。由 Itô 公式：

$$\begin{aligned} d(\log X_t) &= \frac{1}{X_t} dX_t - \frac{1}{2X_t^2}(dX_t)^2 \\ &= a(t)dt + b(t)dW_t - \frac{1}{2}b^2(t)dt \\ &= \left(a(t) - \frac{1}{2}b^2(t)\right) dt + b(t)dW_t \end{aligned}$$

积分得：

$$\log X_t = \log x_0 + \int_0^t \left(a(s) - \frac{1}{2}b^2(s)\right) ds + \int_0^t b(s)dW_s$$

因此：

$$X_t = x_0 \exp\left(\int_0^t \left(a(s) - \frac{1}{2}b^2(s)\right) ds + \int_0^t b(s)dW_s\right)$$

解具有乘积形式：确定性指数部分乘以随机指数部分（Doléans-Dade 指数）。

例 5.1 (几何布朗运动)**.** 取 $a(t) \equiv \mu$，$b(t) \equiv \sigma$，则：

$$X_t = x_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right) t + \sigma W_t\right)$$

这是 *Black-Scholes* 模型的基础。

5.2.2 一维非齐次线性 SDE

更一般的形式：

$$dX_t = [a(t)X_t + \alpha(t)]dt + [b(t)X_t + \beta(t)]dW_t$$

其中 $a(t), \alpha(t), b(t), \beta(t)$ 为确定性函数或适应过程。

求解方法：积分因子法

类似于 ODE，我们寻找积分因子。设 Φ_t 满足齐次方程：

$$d\Phi_t = a(t)\Phi_t dt + b(t)\Phi_t dW_t, \quad \Phi_0 = 1$$

由前文知：

$$\Phi_t = \exp\left(\int_0^t \left(a(s) - \frac{1}{2}b^2(s)\right) ds + \int_0^t b(s)dW_s\right)$$

令 $Y_t = \Phi_t^{-1}X_t$，其中 Φ_t^{-1} 满足（由 Itô 公式可验证）：

$$d(\Phi_t^{-1}) = \Phi_t^{-1}\left[(-a(t) + b^2(t))dt - b(t)dW_t\right]$$

应用 Itô 乘积法则：

$$\begin{aligned} dY_t &= d(\Phi_t^{-1}X_t) \\ &= \Phi_t^{-1}dX_t + X_t d(\Phi_t^{-1}) + d[\Phi^{-1}, X]_t \end{aligned}$$

经过计算（利用 $(dW_t)^2 = dt$ 等规则），奇迹般地发现：

$$dY_t = \Phi_t^{-1}[\alpha(t) - \beta(t)b(t)]dt + \Phi_t^{-1}\beta(t)dW_t$$

这是一个无漂移项（关于 Y_t）的 SDE，可以直接积分：

$$Y_t = Y_0 + \int_0^t \Phi_s^{-1}[\alpha(s) - \beta(s)b(s)]ds + \int_0^t \Phi_s^{-1}\beta(s)dW_s$$

最终：

$$X_t = \Phi_t\left[x_0 + \int_0^t \Phi_s^{-1}[\alpha(s) - \beta(s)b(s)]ds + \int_0^t \Phi_s^{-1}\beta(s)dW_s\right]$$

例 5.2 (Ornstein-Uhlenbeck 过程)**.** 取 $a(t) = -\theta$，$\alpha(t) = \theta\mu$，$b(t) = 0$，$\beta(t) = \sigma$。则：

$$\begin{aligned}
\Phi_t &= e^{-\theta t} \\
\Phi_t^{-1} &= e^{\theta t} \\
X_t &= e^{-\theta t}\left[x_0 + \int_0^t e^{\theta s}\theta\mu ds + \int_0^t e^{\theta s}\sigma dW_s\right] \\
&= e^{-\theta t}x_0 + \mu(1 - e^{-\theta t}) + \sigma e^{-\theta t}\int_0^t e^{\theta s}dW_s
\end{aligned}$$

5.2.3 多维线性 SDE

考虑向量形式：

$$d\mathbf{X}_t = [A(t)\mathbf{X}_t + \mathbf{a}(t)]dt + \sum_{j=1}^m [B_j(t)\mathbf{X}_t + \mathbf{b}_j(t)]dW_t^j$$

其中 $\mathbf{X}_t \in \mathbb{R}^n$，$A(t), B_j(t) \in \mathbb{R}^{n\times n}$，$\mathbf{a}(t), \mathbf{b}_j(t) \in \mathbb{R}^n$。

矩阵指数与齐次情形

当 $\mathbf{a} = \mathbf{b}_j = 0$ 时，方程为齐次：

$$d\mathbf{X}_t = A(t)\mathbf{X}_t dt + \sum_{j=1}^m B_j(t)\mathbf{X}_t dW_t^j$$

如果所有矩阵对易（即 $A(t), B_1(t), \ldots, B_m(t)$ 两两可交换），则解可显式写出。特别地，当它们为常数矩阵且对易时，解为：

$$\mathbf{X}_t = \exp\left(\left(A - \frac{1}{2}\sum_{j=1}^m B_j^2\right)t + \sum_{j=1}^m B_j W_t^j\right)\mathbf{X}_0$$

其中矩阵指数定义为幂级数。

更一般地，定义矩阵过程 Φ_t 满足：

$$d\Phi_t = A(t)\Phi_t dt + \sum_{j=1}^m B_j(t)\Phi_t dW_t^j, \quad \Phi_0 = I$$

则齐次方程的解为 $\mathbf{X}_t = \Phi_t\mathbf{X}_0$。但 Φ_t 通常没有显式表达式。

非齐次情形的常数变易法

类似于一维情形，非齐次方程的解可表示为：

$$\mathbf{X}_t = \Phi_t \left[\mathbf{X}_0 + \int_0^t \Phi_s^{-1} \left(\mathbf{a}(s) - \sum_{j=1}^m B_j(s) \mathbf{b}_j(s) \right) ds + \sum_{j=1}^m \int_0^t \Phi_s^{-1} \mathbf{b}_j(s) dW_s^j \right]$$

注 5.3 (可交换性的重要性)**.** 当矩阵不对易时，情况变得复杂。此时 Φ_t 不能用简单的指数表示，而需要涉及时间排序（*time-ordering*）概念，类似于量子力学中的 *Dyson* 级数。

5.3 Lamperti 变换：化为线性 SDE 的技巧

Lamperti 变换是一类重要的非线性变换，可将某些非线性 SDE 化为线性 SDE。其核心思想是寻找适当的函数变换，使得新过程的扩散系数变为常数。

5.3.1 基本思想

考虑一般一维 SDE：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$$

我们希望找到单调可微函数 f，使得 $Y_t = f(X_t)$ 的扩散系数为常数。

由 Itô 公式：

$$dY_t = \left[f'(X_t)\mu(X_t) + \frac{1}{2} f''(X_t)\sigma^2(X_t) \right] dt + f'(X_t)\sigma(X_t)dW_t$$

我们希望 $f'(x)\sigma(x) = c$（常数）。因此选择：

$$f'(x) = \frac{c}{\sigma(x)} \quad \Rightarrow \quad f(x) = c \int_{x_0}^x \frac{1}{\sigma(y)} dy$$

其中积分下限 x_0 任意。

5.3.2 具体应用

取 $c=1$，则 $f(x)=\int_{x_0}^{x}\frac{1}{\sigma(y)}dy$，且：

$$f''(x)=-\frac{\sigma'(x)}{\sigma^2(x)}$$

于是 $Y_t=f(X_t)$ 满足：

$$dY_t=\left[\frac{\mu(X_t)}{\sigma(X_t)}-\frac{1}{2}\sigma'(X_t)\right]dt+dW_t$$

由于 $X_t=f^{-1}(Y_t)$，这给出了关于 Y_t 的 SDE，其扩散系数为常数 1。如果漂移项能表示为 Y_t 的线性函数，则得到线性 SDE。

5.3.3 例子：CEV 模型

Constant Elasticity of Variance (CEV) 模型：

$$dS_t=\mu S_t dt+\sigma S_t^{\gamma}dW_t,\quad \gamma>0$$

在金融中用于建模波动率微笑。

当 $\gamma\neq 1$ 时，令 $Y_t=S_t^{1-\gamma}$。计算 $f(x)=x^{1-\gamma}$，则：

$$f'(x)=(1-\gamma)x^{-\gamma},\quad f''(x)=-\gamma(1-\gamma)x^{-\gamma-1}$$

由 Itô 公式：

$$\begin{aligned}
dY_t&=(1-\gamma)S_t^{-\gamma}dS_t-\frac{1}{2}\gamma(1-\gamma)S_t^{-\gamma-1}(dS_t)^2\\
&=(1-\gamma)S_t^{-\gamma}(\mu S_t dt+\sigma S_t^{\gamma}dW_t)-\frac{1}{2}\gamma(1-\gamma)S_t^{-\gamma-1}\sigma^2S_t^{2\gamma}dt\\
&=\left[\mu(1-\gamma)S_t^{1-\gamma}-\frac{1}{2}\gamma(1-\gamma)\sigma^2S_t^{\gamma-1}\right]dt+\sigma(1-\gamma)dW_t\\
&=\left[\mu(1-\gamma)Y_t-\frac{1}{2}\gamma(1-\gamma)\sigma^2Y_t^{-1}\right]dt+\sigma(1-\gamma)dW_t
\end{aligned}$$

这还不是线性 SDE。但当 $\mu=0$（风险中性测度下）时：

$$dY_t=-\frac{1}{2}\gamma(1-\gamma)\sigma^2Y_t^{-1}dt+\sigma(1-\gamma)dW_t$$

再令 $Z_t=Y_t^2$，可进一步化简。

5.3.4 Lamperti 变换的适用条件

Lamperti 变换适用的关键是：

1. 扩散系数 $\sigma(x)$ 与状态变量可分离：$\sigma(x) = \tilde{\sigma}(x)$，其中 $\tilde{\sigma}$ 不含 t
2. $\sigma(x)$ 在考虑的区域内不为零
3. 积分 $\int \frac{1}{\sigma(x)} dx$ 可显式计算
4. 变换后的漂移项具有简单形式

5.4 时间变换方法

时间变换是另一种重要的求解技巧，通过改变时间尺度来简化方程。

5.4.1 确定性时间变换

考虑 SDE：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$$

定义新的时间 $s = \varphi(t)$，其中 φ 严格递增可微。令 $Y_s = X_{\varphi^{-1}(s)}$，则：

$$dY_s = \frac{1}{\varphi'(\varphi^{-1}(s))}\mu(Y_s)ds + \frac{1}{\sqrt{\varphi'(\varphi^{-1}(s))}}\sigma(Y_s)d\tilde{W}_s$$

其中 $\tilde{W}_s = \frac{1}{\sqrt{\varphi'(t)}}W_{\varphi(t)}$（适当缩放）仍是布朗运动。

通过选择 φ 使系数简化，例如使扩散系数变为常数。

5.4.2 随机时间变换

更强大的是随机时间变换。设 $A_t = \int_0^t \sigma^2(X_s)ds$，假设 A_t 严格递增。定义逆函数 $\tau_s = \inf\{t : A_t > s\}$，即 τ_s 满足 $A_{\tau_s} = s$。

令 $Y_s = X_{\tau_s}$，$\tilde{W}_s = \int_0^{\tau_s} \sigma(X_u)dW_u$。可以证明 $\tilde{W}_s$ 是布朗运动，且：

$$dY_s = \frac{\mu(Y_s)}{\sigma^2(Y_s)}ds + d\tilde{W}_s$$

例 5.4 (Bessel 过程). 考虑 $dX_t = \frac{d-1}{2X_t}dt + dW_t$，$d > 1$。这是 d 维布朗运动的模长。

取 $\sigma(x) = 1$，则 $A_t = t$，随机时间变换退化为恒等变换。但我们可以用其他变换：令 $Y_t = X_t^2$，由 *Itô* 公式：

$$dY_t = 2X_t dX_t + dt = 2X_t\left(\frac{d-1}{2X_t}dt + dW_t\right) + dt = d\,dt + 2\sqrt{Y_t}dW_t$$

这仍然是非线性的。但可以进一步研究其性质。

5.5 对称性与降维

许多 SDE 具有对称性，可利用这些对称性简化求解或分析。

5.5.1 尺度不变性

如果存在函数 $\lambda(\epsilon)$ 和 $\mu(\epsilon)$ 使得变换 $t \to \lambda(\epsilon)t$，$X \to \mu(\epsilon)X$ 保持方程形式不变，则方程具有尺度不变性。

例 5.5 (几何布朗运动的尺度不变性). 对 $dX_t = \mu X_t dt + \sigma X_t dW_t$，考虑变换 $X \to cX$，则方程变为 $d(cX_t) = \mu(cX_t)dt + \sigma(cX_t)dW_t$，形式不变。这解释了为什么解具有指数形式。

5.5.2 平移不变性

如果变换 $X \to X + c$ 保持方程形式，则具有平移不变性。这通常出现在漂移项为常数或线性时。

5.5.3 利用对称性猜测解形式

在 ODE 中，对称性可用于降阶。在 SDE 中，对称性可用于猜测解的形式。例如，具有尺度不变性的 SDE，其解往往具有幂函数或指数函数形式。

5.6 具体模型深入分析

5.6.1 Vasicek 利率模型

Vasicek 模型描述短期利率：

$$dr_t = \kappa(\theta - r_t)dt + \sigma dW_t$$

这是 OU 过程，我们已经知道解：

$$r_t = e^{-\kappa t}r_0 + \theta(1 - e^{-\kappa t}) + \sigma e^{-\kappa t}\int_0^t e^{\kappa s}dW_s$$

分布性质：$r_t \sim N\left(e^{-\kappa t}r_0 + \theta(1 - e^{-\kappa t}), \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa t})\right)$。

平稳分布：$r_\infty \sim N\left(\theta, \frac{\sigma^2}{2\kappa}\right)$。

5.6.2 CIR 模型

Cox-Ingersoll-Ross 模型：

$$dr_t = \kappa(\theta - r_t)dt + \sigma\sqrt{r_t}dW_t$$

扩散系数 $\sigma\sqrt{r}$ 在 $r = 0$ 处不 Lipschitz，但可证明解存在唯一且保持非负。

虽然 CIR 方程没有初等函数解，但其转移密度已知（非中心卡方分布），矩生成函数可显式写出。

令 $s(t) = \frac{\sigma^2}{4\kappa}(1 - e^{-\kappa t})$，$q = \frac{2\kappa\theta}{\sigma^2} - 1$，则 r_t 的缩放 $\frac{r_t}{s(t)}$ 服从自由度为 $2q + 2$ 的非中心卡方分布。

5.6.3 Heston 随机波动率模型

Heston 模型描述资产价格 S_t 和波动率 v_t：

$$\begin{aligned} dS_t &= \mu S_t dt + \sqrt{v_t}S_t dW_t^1 \\ dv_t &= \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^2 \end{aligned}$$

其中 $dW_t^1 dW_t^2 = \rho dt$。

虽无显式解，但特征函数可显式求出，这使得欧式期权定价可通过傅里叶反演进行。

5.6.4 非线性情形：Aït-Sahalia 模型

现代利率模型考虑非线性漂移:

$$dr_t = (\alpha_{-1} r_t^{-1} + \alpha_0 + \alpha_1 r_t + \alpha_2 r_t^2)dt + \sigma r_t^{\rho} dW_t$$

这类方程一般无显式解，但转移密度可通过谱方法近似，或通过数值方法求解。

5.7 数值求解的特殊技巧

5.7.1 精确模拟方法

对某些特殊 SDE，可以利用其精确分布进行模拟，避免离散化误差。

例 5.6 (OU 过程的精确模拟). *由于 r_t 条件分布为正态，可以精确模拟:*

$$r_{t+\Delta t} \mid r_t \sim N\left(\theta + (r_t - \theta)e^{-\kappa\Delta t}, \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa\Delta t})\right)$$

例 5.7 (CIR 过程的精确模拟). *CIR 过程的转移密度为非中心卡方分布，有专门的随机数生成算法。*

5.7.2 变换后模拟

有时将 SDE 变换后，新方程的离散化性能更好。

例 5.8 (几何布朗运动的对数变换). *直接离散化 $dS_t = \mu S_t dt + \sigma S_t dW_t$ 可能产生负值（如果步长大）。但对数变换 $X_t = \log S_t$ 给出线性 SDE:*

$$dX_t = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW_t$$

可以精确模拟：$X_{t+\Delta t} = X_t + (\mu - \frac{1}{2}\sigma^2)\Delta t + \sigma\sqrt{\Delta t}Z$，$Z \sim N(0,1)$。然后取指数得 $S_{t+\Delta t}$。

本章总结

本章系统研究了 SDE 的求解技巧，要点如下：

1. **线性 SDE**：通过积分因子法可求得显式解，是应用中最重要的一类
2. **Lamperti 变换**：通过适当函数变换将扩散系数化为常数，从而可能得到线性 SDE
3. **时间变换**：改变时间尺度简化方程，包括确定性和随机时间变换
4. **对称性利用**：尺度不变性、平移不变性等可帮助猜测解形式
5. **具体模型**：Vasicek、CIR、Heston 等模型展示了不同求解策略
6. **数值技巧**：精确模拟、变换后模拟等提高数值方法精度

虽然绝大多数 SDE 没有封闭解，但通过系统的方法，我们可以：

- 识别可精确求解的特殊类型
- 通过变换简化方程
- 利用对称性分析解的性质
- 设计高效的数值方法

这些技巧的掌握不仅有助于求解具体方程，更重要的是培养了一种数学直觉：如何看待随机微分方程的结构，如何发现其中隐藏的简化可能性。

在后续章节中，我们将应用这些技巧研究具体的金融和物理模型，展示随机分析在实践中的威力。

历史注记

线性 SDE 的求解方法由 Itô 在 1940 年代建立。Lamperti 变换源于 Lamperti 在 1967 年关于半鞅表示的工作。时间变换方法在随机分析中历史悠久，与 Levy 的布朗运动理论密切相关。具体模型方面，Vasicek(1977)、

Cox-Ingersoll-Ross(1985)、Heston(1993) 的模型各自开创了利率和波动率建模的新方向。数值方法的研究随着计算能力的提升而不断发展，精确模拟方法由 Glasserman 等人系统研究。

Chapter 6

矩方程与统计性质

6.1 引言：从路径分析到统计描述

在前几章中，我们主要关注随机微分方程（SDE）的路径性质：解的存在唯一性、样本轨道连续性、Itô 公式等。然而，在许多应用中，我们更关心解的统计性质：均值、方差、相关性、分布形态等。这些统计量虽然丢失了路径的细节信息，但抓住了过程的本质特征，且往往更容易计算和分析。

本章的核心思想是：通过对 SDE 进行适当的" 操作"，提取出我们关心的统计信息。这些操作本质上是前几章讨论的三种基本操作——对时间积分、对样本积分（期望）、Itô 积分——的巧妙组合。

6.1.1 矩：随机过程的基本统计量

对于一个随机过程 $\{X_t\}$，其各阶矩提供了分布的完整信息：

- 一阶矩（均值）：$\mu(t) = \mathbb{E}[X_t]$，描述中心位置
- 二阶矩（方差/协方差）：$\sigma^2(t) = \mathrm{Var}(X_t)$，$C(s,t) = \mathrm{Cov}(X_s, X_t)$，描述波动性和相关性
- 高阶矩：偏度（三阶）、峰度（四阶）等，描述分布形态

对于由 SDE 驱动的过程，这些矩满足确定的微分方程或积分方程，即矩方程。求解这些方程往往比求解原 SDE 更容易，且能提供关键的统计信

息。

6.2 矩方程的推导方法

6.2.1 直接期望法

考虑一般 SDE：

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t, \quad X_0 = x_0$$

取期望（对 ω 积分），利用 Itô 积分期望为零的性质：

$$\begin{aligned}\frac{d}{dt}\mathbb{E}[X_t] &= \frac{d}{dt}\mathbb{E}\left[x_0 + \int_0^t \mu(s, X_s)ds + \int_0^t \sigma(s, X_s)dW_s\right] \\ &= \mathbb{E}[\mu(t, X_t)]\end{aligned}$$

这里我们交换了期望和时间的导数，需要验证条件（通常满足）。

于是得到均值方程：

$$\frac{d}{dt}\mathbb{E}[X_t] = \mathbb{E}[\mu(t, X_t)] \tag{6.1}$$

注意：这是一个关于 $\mathbb{E}[X_t]$ 的方程，但右边一般依赖于 X_t 的整个分布，而不仅仅是均值。除非 μ 是线性的，否则这不是闭方程。

6.2.2 Itô 公式法

为了得到高阶矩的方程，我们应用 Itô 公式。设 $f(x) = x^n$，则：

$$\begin{aligned}d(X_t^n) &= nX_t^{n-1}dX_t + \frac{1}{2}n(n-1)X_t^{n-2}(dX_t)^2 \\ &= nX_t^{n-1}[\mu(t, X_t)dt + \sigma(t, X_t)dW_t] + \frac{1}{2}n(n-1)X_t^{n-2}\sigma^2(t, X_t)dt \\ &= \left[nX_t^{n-1}\mu(t, X_t) + \frac{1}{2}n(n-1)X_t^{n-2}\sigma^2(t, X_t)\right]dt + nX_t^{n-1}\sigma(t, X_t)dW_t\end{aligned}$$

取期望，Itô 积分项消失：

$$\frac{d}{dt}\mathbb{E}[X_t^n] = n\mathbb{E}\left[X_t^{n-1}\mu(t, X_t)\right] + \frac{1}{2}n(n-1)\mathbb{E}\left[X_t^{n-2}\sigma^2(t, X_t)\right]$$

特别地，对于二阶矩（$n=2$）：

$$\frac{d}{dt}\mathbb{E}[X_t^2] = 2\mathbb{E}[X_t\mu(t,X_t)] + \mathbb{E}[\sigma^2(t,X_t)] \tag{6.2}$$

方差方程可由 $\mathrm{Var}(X_t) = \mathbb{E}[X_t^2] - (\mathbb{E}[X_t])^2$ 导出：

$$\frac{d}{dt}\mathrm{Var}(X_t) = 2\mathrm{Cov}(X_t, \mu(t,X_t)) + \mathbb{E}[\sigma^2(t,X_t)]$$

6.2.3 矩方程的闭合性问题

矩方程的一个根本困难是：n 阶矩的方程依赖于 n 阶和 $n+1$ 阶矩（当 μ 线性时）或更高阶矩（当 μ 非线性时）。这形成了一个无限维的方程组，称为矩层级（moment hierarchy）。

要使矩方程闭合，需要特殊结构。最常见的情况是：

1. **线性 SDE**：$\mu(t,x) = a(t)x + b(t)$，$\sigma(t,x) = c(t)x + d(t)$ 此时矩方程是闭合的，因为 $\mathbb{E}[X_t\mu(t,X_t)] = a(t)\mathbb{E}[X_t^2] + b(t)\mathbb{E}[X_t]$ 是 $\mathbb{E}[X_t]$ 和 $\mathbb{E}[X_t^2]$ 的线性组合。

2. **多项式系数**：μ 和 σ^2 是 x 的多项式如果 μ 是 m 次多项式，σ^2 是 n 次多项式，则 k 阶矩方程依赖于最高 $\max(k+m-1, k+n-2)$ 阶矩。特别地，当 μ 和 σ^2 是二次多项式时，矩层级不闭合。

3. **闭包近似**：通过某种假设（如假设分布为高斯分布）切断矩层级，得到近似闭合方程组。

6.3 线性 SDE 的矩分析

线性 SDE 是最容易进行矩分析的情形，因为其矩方程是闭合的有限维线性系统。

6.3.1 一般线性 SDE 的矩方程

考虑：

$$dX_t = [a(t)X_t + b(t)]dt + [c(t)X_t + d(t)]dW_t$$

定义矩向量 $\mathbf{m}(t) = (\mathbb{E}[X_t], \mathbb{E}[X_t^2])^T$。由公式 (6.1) 和 (6.2)：

$$\frac{d}{dt}\mathbb{E}[X_t] = a(t)\mathbb{E}[X_t] + b(t)$$
$$\frac{d}{dt}\mathbb{E}[X_t^2] = 2a(t)\mathbb{E}[X_t^2] + 2b(t)\mathbb{E}[X_t] + c^2(t)\mathbb{E}[X_t^2] + 2c(t)d(t)\mathbb{E}[X_t] + d^2(t)$$

写成矩阵形式：

$$\frac{d}{dt}\begin{pmatrix}\mathbb{E}[X_t]\\ \mathbb{E}[X_t^2]\end{pmatrix} = \begin{pmatrix} a(t) & 0 \\ 2b(t) + 2c(t)d(t) & 2a(t) + c^2(t)\end{pmatrix}\begin{pmatrix}\mathbb{E}[X_t]\\ \mathbb{E}[X_t^2]\end{pmatrix} + \begin{pmatrix} b(t) \\ d^2(t)\end{pmatrix}$$

这是一个非齐次线性 ODE，可显式求解。

6.3.2 几何布朗运动的矩

作为特例，几何布朗运动 $dS_t = \mu S_t dt + \sigma S_t dW_t$ 有：

$$\frac{d}{dt}\mathbb{E}[S_t] = \mu\mathbb{E}[S_t] \quad \Rightarrow \quad \mathbb{E}[S_t] = S_0 e^{\mu t}$$
$$\frac{d}{dt}\mathbb{E}[S_t^2] = (2\mu + \sigma^2)\mathbb{E}[S_t^2] \quad \Rightarrow \quad \mathbb{E}[S_t^2] = S_0^2 e^{(2\mu+\sigma^2)t}$$

方差为：

$$\mathrm{Var}(S_t) = \mathbb{E}[S_t^2] - (\mathbb{E}[S_t])^2 = S_0^2 e^{2\mu t}(e^{\sigma^2 t} - 1)$$

注意：均值增长率是 μ，但每个样本路径的长期增长率是 $\mu - \frac{1}{2}\sigma^2$（由 Itô 公式）。这种差异体现了期望运算与路径 wise 性质的差别。

6.3.3 Ornstein-Uhlenbeck 过程的矩

OU 过程 $dX_t = \theta(\mu - X_t)dt + \sigma dW_t$ 有：

$$\frac{d}{dt}\mathbb{E}[X_t] = \theta(\mu - \mathbb{E}[X_t]) \quad \Rightarrow \quad \mathbb{E}[X_t] = \mu + (X_0 - \mu)e^{-\theta t}$$
$$\frac{d}{dt}\mathbb{E}[X_t^2] = 2\theta\mu\mathbb{E}[X_t] - 2\theta\mathbb{E}[X_t^2] + \sigma^2$$

方差方程可直接求解：

$$\frac{d}{dt}\mathrm{Var}(X_t) = -2\theta\mathrm{Var}(X_t) + \sigma^2 \quad \Rightarrow \quad \mathrm{Var}(X_t) = \frac{\sigma^2}{2\theta}(1 - e^{-2\theta t}) + \mathrm{Var}(X_0)e^{-2\theta t}$$

当 $t \to \infty$，$\mathbb{E}[X_t] \to \mu$，$\mathrm{Var}(X_t) \to \frac{\sigma^2}{2\theta}$，对应平稳分布 $N(\mu, \frac{\sigma^2}{2\theta})$。

6.4 Fokker-Planck 方程：概率密度的演化

矩描述了分布的局部特征，而概率密度函数提供了分布的完整信息。对于扩散过程，其概率密度满足一个确定性偏微分方程——Fokker-Planck 方程（也称为 Kolmogorov 向前方程）。

6.4.1 推导：从 SDE 到 Fokker-Planck 方程

考虑一般 SDE：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$$

为简化，假设系数不显含时间（自治系统）。设 $p(t,x)$ 为 X_t 的概率密度函数，即 $\mathbb{P}(X_t \in dx) = p(t,x)dx$。

对任意光滑紧支撑函数 $\phi \in C_c^\infty(\mathbb{R})$，由 Itô 公式：

$$\begin{aligned} d\phi(X_t) &= \phi'(X_t)dX_t + \frac{1}{2}\phi''(X_t)(dX_t)^2 \\ &= \left[\mu(X_t)\phi'(X_t) + \frac{1}{2}\sigma^2(X_t)\phi''(X_t)\right]dt + \sigma(X_t)\phi'(X_t)dW_t \end{aligned}$$

取期望并交换期望与时间导数：

$$\frac{d}{dt}\mathbb{E}[\phi(X_t)] = \mathbb{E}\left[\mu(X_t)\phi'(X_t) + \frac{1}{2}\sigma^2(X_t)\phi''(X_t)\right]$$

用密度表示：

$$\begin{aligned} \mathbb{E}[\phi(X_t)] &= \int_{\mathbb{R}} \phi(x)p(t,x)dx \\ \mathbb{E}[\mu(X_t)\phi'(X_t)] &= \int_{\mathbb{R}} \mu(x)\phi'(x)p(t,x)dx \\ \mathbb{E}[\sigma^2(X_t)\phi''(X_t)] &= \int_{\mathbb{R}} \sigma^2(x)\phi''(x)p(t,x)dx \end{aligned}$$

代入并分部积分（利用 ϕ 紧支撑）：

$$\begin{aligned} \int_{\mathbb{R}} \phi(x)\frac{\partial p}{\partial t}dx &= \int_{\mathbb{R}} \left[\mu(x)\phi'(x) + \frac{1}{2}\sigma^2(x)\phi''(x)\right]p(t,x)dx \\ &= \int_{\mathbb{R}} \phi(x)\left[-\frac{\partial}{\partial x}(\mu p) + \frac{1}{2}\frac{\partial^2}{\partial x^2}(\sigma^2 p)\right]dx \end{aligned}$$

由 ϕ 的任意性，得 Fokker-Planck 方程：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu(x)p] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[\sigma^2(x)p] \tag{6.3}$$

初始条件：$p(0,x) = p_0(x)$，其中 p_0 是 X_0 的密度。

6.4.2 概率流解释

将 Fokker-Planck 方程写成守恒形式：

$$\frac{\partial p}{\partial t} + \frac{\partial J}{\partial x} = 0$$

其中概率流 $J(t,x)$ 定义为：

$$J(t,x) = \mu(x)p(t,x) - \frac{1}{2}\frac{\partial}{\partial x}[\sigma^2(x)p(t,x)]$$

第一项 μp 是对流项，反映漂移引起的概率流动；第二项 $-\frac{1}{2}\partial_x(\sigma^2 p)$ 是扩散项，反映噪声引起的概率扩散。

边界条件通常取为概率流为零：$J(t,\pm\infty) = 0$，保证概率守恒：$\int_{\mathbb{R}} p(t,x)dx = 1$。

6.4.3 平稳分布

当系数不显含时间时，可能存在平稳分布 $p_{\mathrm{s}}(x)$，满足 $\frac{\partial p}{\partial t} = 0$。由 (6.3)，平稳密度满足：

$$-\frac{d}{dx}[\mu(x)p_{\mathrm{s}}] + \frac{1}{2}\frac{d^2}{dx^2}[\sigma^2(x)p_{\mathrm{s}}] = 0$$

积分一次：

$$J = \mu(x)p_{\mathrm{s}} - \frac{1}{2}\frac{d}{dx}[\sigma^2(x)p_{\mathrm{s}}] = \text{常数}$$

通常取 $J = 0$（细致平衡条件），则：

$$\mu(x)p_{\mathrm{s}} = \frac{1}{2}\frac{d}{dx}[\sigma^2(x)p_{\mathrm{s}}]$$

整理得：

$$\frac{d}{dx}\log p_{\mathrm{s}}(x) = \frac{2\mu(x)}{\sigma^2(x)} - \frac{\sigma'(x)}{\sigma(x)}$$

解为:

$$p_{\mathrm{s}}(x)=\frac{C}{\sigma^2(x)}\exp\left(2\int_{x_0}^{x}\frac{\mu(y)}{\sigma^2(y)}dy\right) \tag{6.4}$$

其中 C 为归一化常数。

例 6.1 (OU 过程的平稳分布). 对 OU 过程: $\mu(x)=\theta(\mu-x)$, $\sigma(x)=\sigma$ 常数。

$$\frac{2\mu(x)}{\sigma^2}-\frac{\sigma'}{\sigma}=\frac{2\theta(\mu-x)}{\sigma^2}$$

$$p_s(x)=C\exp\left(\frac{2\theta}{\sigma^2}\int_{x_0}^{x}(\mu-y)dy\right)=C\exp\left(-\frac{\theta}{\sigma^2}(x-\mu)^2\right)$$

这是高斯分布 $N(\mu,\frac{\sigma^2}{2\theta})$。

例 6.2 (几何布朗运动没有平稳分布). 对 $dS_t=\mu S_t dt+\sigma S_t dW_t$, $\mu(x)=\mu x$, $\sigma(x)=\sigma x$。

$$\frac{2\mu(x)}{\sigma^2(x)}-\frac{\sigma'(x)}{\sigma(x)}=\frac{2\mu}{\sigma^2 x}-\frac{1}{x}=\frac{2\mu-\sigma^2}{\sigma^2 x}$$

$$p_s(x)=\frac{C}{x^2}\exp\left(\frac{2\mu-\sigma^2}{\sigma^2}\log x\right)=Cx^{\frac{2\mu}{\sigma^2}-2}$$

当 $x\to\infty$ 时, 若 $\frac{2\mu}{\sigma^2}-2<-1$ 即 $\mu<\frac{\sigma^2}{2}$, 则 $\int^{\infty}p_s(x)dx$ 收敛; 但当 $x\to 0$ 时, 若 $\frac{2\mu}{\sigma^2}-2>-1$ 即 $\mu>\frac{\sigma^2}{2}$, 则 $\int_0 p_s(x)dx$ 发散。无论如何, 无法在整个 $(0,\infty)$ 上归一化, 故无平稳分布。这符合几何布朗运动是指数增长/衰减的事实。

6.5 生成元与 Kolmogorov 向后方程

Fokker-Planck 方程描述概率密度随时间的演化, 是" 向前" 方程。与之对偶的是" 向后" 方程, 描述期望值作为初始条件的函数。

6.5.1 生成元的定义

扩散过程 $\{X_t\}$ 的无穷小生成元是一个算子 $\mathcal{L}$, 作用在光滑函数 f 上:

$$\mathcal{L}f(x)=\lim_{t\downarrow 0}\frac{\mathbb{E}[f(X_t)|X_0=x]-f(x)}{t}$$

对 SDE $dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$，由 Itô 公式：

$$df(X_t) = \mathcal{L}f(X_t)dt + f'(X_t)\sigma(X_t)dW_t$$

其中

$$\mathcal{L} = \mu(x)\frac{d}{dx} + \frac{1}{2}\sigma^2(x)\frac{d^2}{dx^2}$$

这正是 Itô 公式中 dt 项的系数（去掉期望）。

6.5.2 Kolmogorov 向后方程

设 $u(t,x) = \mathbb{E}[f(X_t)|X_0 = x]$。由 Itô 公式和鞅性质：

$$\begin{aligned} u(t, X_t) &= \mathbb{E}[f(X_{t+s})|\mathcal{F}_t] \quad \text{（由马氏性）} \\ &= \mathbb{E}[f(X_s)|X_0 = X_t] \quad \text{（由时齐性）} \end{aligned}$$

因此 $u(t, X_t)$ 是鞅。其漂移项为零给出：

$$\frac{\partial u}{\partial t} = \mathcal{L}u$$

即 Kolmogorov 向后方程：

$$\frac{\partial u}{\partial t} = \mu(x)\frac{\partial u}{\partial x} + \frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2}, \quad u(0,x) = f(x) \tag{6.5}$$

6.5.3 向前与向后方程的对偶性

设 $p(t,x|y)$ 为转移密度（从 y 出发，t 时刻在 x 的概率密度）。则：

- 作为 x 的函数，p 满足向前方程（Fokker-Planck 方程）：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu(x)p] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[\sigma^2(x)p]$$

- 作为 y 的函数，p 满足向后方程：

$$\frac{\partial p}{\partial t} = \mu(y)\frac{\partial p}{\partial y} + \frac{1}{2}\sigma^2(y)\frac{\partial^2 p}{\partial y^2}$$

这种对偶性反映了扩散过程的时空对称性。

6.6 Feynman-Kac 公式：连接 PDE 与 SDE 的桥梁

Kolmogorov 向后方程建立了扩散过程与抛物型 PDE 的联系。Feynman-Kac 公式推广了这一联系，允许方程中有势函数项和终端条件。

6.6.1 基本 Feynman-Kac 公式

定理 6.3 (Feynman-Kac 公式)**.** *设 $V(x)$ 和 $f(x)$ 为适当光滑函数。考虑抛物型 PDE:*

$$\frac{\partial u}{\partial t} + \mu(x)\frac{\partial u}{\partial x} + \frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2} - V(x)u = 0, \quad t \in [0, T]$$

满足终端条件 $u(T, x) = f(x)$。

则解可表示为:

$$u(t, x) = \mathbb{E}\left[f(X_T)\exp\left(-\int_t^T V(X_s)ds\right)\middle| X_t = x\right]$$

其中 $\{X_s\}$ 满足 SDE: $dX_s = \mu(X_s)ds + \sigma(X_s)dW_s$。

证明思路. 定义过程:

$$M_s = u(s, X_s)\exp\left(-\int_t^s V(X_r)dr\right), \quad s \in [t, T]$$

对 M_s 应用 Itô 公式，利用 u 满足的 PDE，可证 M_s 是鞅。因此:

$$u(t, x) = M_t = \mathbb{E}[M_T | X_t = x] = \mathbb{E}\left[f(X_T)\exp\left(-\int_t^T V(X_s)ds\right)\middle| X_t = x\right]$$

□

特别地，当 $V \equiv 0$ 时，回到 Kolmogorov 向后方程的解。

6.6.2 应用：期权定价

在 Black-Scholes 模型中，欧式看涨期权的价格 $C(t, S)$ 满足 Black-Scholes PDE:

$$\frac{\partial C}{\partial t} + rS\frac{\partial C}{\partial S} + \frac{1}{2}\sigma^2 S^2\frac{\partial^2 C}{\partial S^2} - rC = 0$$

终端条件 $C(T,S)=\max(S-K,0)$。

由 Feynman-Kac 公式，解为：

$$C(t,S)=e^{-r(T-t)}\mathbb{E}^Q[\max(S_T-K,0)|S_t=S]$$

其中 $\mathbb{E}^Q$ 表示在风险中性测度下的期望，S_t 满足风险中性动力学：

$$dS_t=rS_tdt+\sigma S_tdW_t^Q$$

这正是期权定价的风险中性公式。

6.7 遍历性与长时间行为

6.7.1 遍历性的定义

对于平稳过程，遍历性意味着时间平均等于空间平均：

$$\lim_{T\to\infty}\frac{1}{T}\int_0^T f(X_t)dt=\mathbb{E}[f(X_\infty)]\quad \text{a.s.}$$

其中 X_∞ 服从平稳分布。

对于扩散过程，遍历性通常要求：

1. 存在唯一的平稳分布 p_s
2. 对任意初始分布，X_t 的分布弱收敛到 p_s
3. 时间平均收敛到关于 p_s 的期望

6.7.2 遍历性的判别准则

对于一维扩散过程，一个实用的判别法是尺度函数和速度函数。

定义尺度函数：

$$s(x)=\exp\left(-\int_{x_0}^x\frac{2\mu(y)}{\sigma^2(y)}dy\right)$$

和速度测度密度：

$$m(x)=\frac{1}{\sigma^2(x)s(x)}$$

过程是遍历的当且仅当：

$$\int_{-\infty}^{\infty} m(x)dx < \infty \quad 且 \quad \int_{-\infty}^{\infty} s(x)dx = \infty$$

此时平稳密度为 $p_{\mathrm{s}}(x) = \frac{m(x)}{\int m(y)dy}$，正是公式 (6.4)。

例 6.4 (OU 过程的遍历性)**.** 对 OU 过程：$\mu(x) = \theta(\mu - x)$，$\sigma(x) = \sigma$。

$$s(x) = \exp\left(-\frac{2\theta}{\sigma^2}\int_{x_0}^{x}(\mu - y)dy\right) = \exp\left(\frac{\theta}{\sigma^2}[(x-\mu)^2 - (x_0-\mu)^2]\right)$$

当 $|x| \to \infty$，$s(x) \to \infty$，故 $\int s(x)dx = \infty$。

$$m(x) = \frac{1}{\sigma^2 s(x)} = \frac{1}{\sigma^2}\exp\left(-\frac{\theta}{\sigma^2}(x-\mu)^2\right)$$

$\int m(x)dx < \infty$。故 OU 过程遍历。

6.7.3 相关函数与谱密度

对于平稳过程，自相关函数：

$$R(\tau) = \mathrm{Cov}(X_t, X_{t+\tau}) = \mathbb{E}[X_t X_{t+\tau}] - \mathbb{E}[X_t]\mathbb{E}[X_{t+\tau}]$$

与时间起点 t 无关。

谱密度是自相关函数的傅里叶变换：

$$S(\omega) = \int_{-\infty}^{\infty} R(\tau)e^{-i\omega\tau}d\tau$$

对于 OU 过程，$R(\tau) = \frac{\sigma^2}{2\theta}e^{-\theta|\tau|}$，谱密度为洛伦兹型：

$$S(\omega) = \frac{\sigma^2}{\theta^2 + \omega^2}$$

本章总结

本章系统研究了 SDE 解的统计性质，要点如下：

1. **矩方程**：通过期望运算和 Itô 公式推导，反映矩的演化规律；线性 SDE 的矩方程闭合可解

2. **Fokker-Planck 方程**：描述概率密度的演化，是确定性 PDE；可求平稳分布
3. **生成元与向后方程**：描述期望值作为初始条件的函数，与 Fokker-Planck 方程对偶
4. **Feynman-Kac 公式**：连接抛物型 PDE 与 SDE 的条件期望，是金融定价的理论基础
5. **遍历性**：判断过程是否趋于平稳分布，时间平均是否等于空间平均

这些统计工具使我们能够：

- 在不求解整个 SDE 的情况下，分析解的基本特征
- 将随机问题转化为确定性 PDE 问题
- 研究长期行为和稳态性质
- 在实际应用中计算关键统计量

特别重要的是理解：矩方程、Fokker-Planck 方程、生成元等都是对同一随机过程的不同描述方式，它们通过三种基本操作相互联系。这种多角度描述的能力是随机分析的强大之处。

在下一章，我们将研究测度变换与 Girsanov 定理，这是连接不同 SDE、进行风险中性定价的关键工具。

历史注记

Fokker-Planck 方程由 Fokker(1914) 和 Planck(1917) 在统计力学中提出。Kolmogorov 在 1931 年建立了扩散过程的系统理论，包括向前和向后方程。Feynman(1948) 和 Kac(1949) 分别从物理和数学角度发现了 PDE 的概率表示。遍历理论由 Birkhoff(1931) 和 von Neumann(1932) 开创，在随机过程中由 Khasminskii 等人发展。这些工作共同构成了现代随机过程统计理论的基石。

Chapter 7

数值方法与计算视角

7.1 引言：从解析解到数值解

在前几章中，我们主要关注随机微分方程（SDE）的解析理论：存在唯一性、显式解、统计性质等。然而，现实中的绝大多数 SDE 没有封闭形式的解。即使有解析解，如几何布朗运动 $S_t = S_0 \exp((\mu - \frac{1}{2}\sigma^2)t + \sigma W_t)$，要计算其函数的期望 $\mathbb{E}[f(S_t)]$ 通常也需要数值积分或蒙特卡洛模拟。

本章将系统研究 SDE 的数值方法，核心问题是：如何通过离散化近似连续时间的随机过程？与确定性 ODE 的数值方法相比，SDE 数值方法面临两个新挑战：

1. 需要近似随机积分项 $\int \sigma dW$
2. 收敛性概念更加丰富：强收敛与弱收敛

我们将看到，SDE 的数值方法本质上是三种基本操作（对时间积分、对样本积分、Itô 积分）的离散实现。离散化将连续的随机过程转化为离散的随机序列，从而可以在计算机上模拟和分析。

7.2 收敛性概念：强收敛与弱收敛

在确定性数值分析中，收敛通常指近似解逼近精确解。在随机情形，我们需要区分两种不同的逼近概念。

7.2.1 强收敛

定义 7.1 (强收敛). 设 $\{X_t\}$ 为 *SDE* 的精确解，$\{Y_t^\Delta\}$ 为步长 Δ 的数值近似。数值方法称为强收敛阶为 γ，如果存在常数 C（不依赖于 Δ）使得

$$\mathbb{E}\left[|X_T - Y_T^\Delta|\right] \leq C\Delta^\gamma$$

对所有充分小的 Δ 成立。

强收敛要求路径 wise 的逼近。在金融中，如果需要模拟整个路径（如路径依赖期权），需要强收敛方法。

7.2.2 弱收敛

定义 7.2 (弱收敛). 数值方法称为弱收敛阶为 β，如果对任意充分光滑的函数 f（如 $f \in C^{2(\beta+1)}$），存在常数 C 使得

$$\left|\mathbb{E}[f(X_T)] - \mathbb{E}[f(Y_T^\Delta)]\right| \leq C\Delta^\beta$$

弱收敛只要求分布特征的逼近。在金融中，如果只关心期望值（如期权价格），弱收敛足够。

注 7.3 (两种收敛的关系). 一般来说：

- 强收敛蕴含弱收敛（取 $f(x) = x$）
- 弱收敛阶通常高于强收敛阶
- 强收敛方法计算更复杂，但应用更广

7.2.3 均方收敛

有时也考虑均方收敛：

$$\left(\mathbb{E}[|X_T - Y_T^\Delta|^2]\right)^{1/2} \leq C\Delta^\gamma$$

由 Cauchy-Schwarz 不等式，均方收敛阶 γ 蕴含强收敛阶 γ。

7.3 Euler-Maruyama 方法：随机 Euler 方法

Euler-Maruyama 方法是 ODE 中 Euler 方法在随机情形的直接推广，也是最简单、最常用的 SDE 数值方法。

7.3.1 方法构造

考虑自治 SDE：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = x_0$$

取等距分划 $0 = t_0 < t_1 < \cdots < t_N = T$，步长 $\Delta = T/N$。Euler-Maruyama 方法定义为：

$$Y_{n+1} = Y_n + \mu(Y_n)\Delta + \sigma(Y_n)\Delta W_n \tag{7.1}$$

其中 $\Delta W_n = W_{t_{n+1}} - W_{t_n} \sim N(0, \Delta)$ 独立同分布。

注 7.4 (实现细节)**.** *在实际计算中，生成 $\Delta W_n \sim N(0, \Delta)$ 的方法：*

1. *生成独立 $Z_n \sim N(0, 1)$*
2. *令 $\Delta W_n = \sqrt{\Delta} Z_n$*

这体现了对 Itô 积分的离散近似：$\int_{t_n}^{t_{n+1}} \sigma(X_s)dW_s \approx \sigma(Y_n)\Delta W_n$。

7.3.2 收敛性分析

定理 7.5 (Euler-Maruyama 方法的收敛性)**.** *假设系数 μ, σ 满足全局 Lipschitz 条件和线性增长条件，且适当光滑。则：*

1. *强收敛阶为 1/2*
2. *弱收敛阶为 1*

证明思路. 强收敛证明的关键是估计误差 $e_n = \mathbb{E}[|X_{t_n} - Y_n|^2]$。由 SDE 和离散格式：

$$X_{t_{n+1}} = X_{t_n} + \int_{t_n}^{t_{n+1}} \mu(X_s)ds + \int_{t_n}^{t_{n+1}} \sigma(X_s)dW_s$$
$$Y_{n+1} = Y_n + \mu(Y_n)\Delta + \sigma(Y_n)\Delta W_n$$

误差递推：

$$e_{n+1} \leq (1 + K\Delta)e_n + K\Delta^2$$

其中 K 依赖于 Lipschitz 常数。由离散 Gronwall 引理得 $e_n \leq C\Delta$，故 $\mathbb{E}[|X_{t_n} - Y_n|] \leq C\sqrt{\Delta}$。

弱收敛证明需要展开矩的误差，利用 Itô-Taylor 展开，得到更高阶的精度。 □

7.3.3 例子：几何布朗运动的模拟

对 $dS_t = \mu S_t dt + \sigma S_t dW_t$，Euler-Maruyama 格式为：

$$S_{n+1} = S_n(1 + \mu\Delta + \sigma\Delta W_n)$$

注意：这可能导致负值（如果 $1 + \mu\Delta + \sigma\Delta W_n < 0$），虽然概率很小。更好的方法是模拟对数价格 $X_t = \log S_t$：

$$dX_t = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW_t$$

Euler 格式为：

$$X_{n+1} = X_n + (\mu - \frac{1}{2}\sigma^2)\Delta + \sigma\Delta W_n$$

然后 $S_n = \exp(X_n)$ 总是正的。

7.4 Milstein 方法：提高强收敛阶

Euler-Maruyama 方法的强收敛阶只有 1/2，对于需要精确路径的应用可能不够。Milstein 方法通过包含 Itô 公式的高阶项，将强收敛阶提高到 1。

7.4.1 方法推导

从 Itô 公式出发，对 $\sigma(X_t)$ 展开：

$$\sigma(X_s) = \sigma(X_{t_n}) + \sigma'(X_{t_n})\sigma(X_{t_n}) \int_{t_n}^{s} dW_u + \text{高阶项}$$

代入 Itô 积分：

$$\int_{t_n}^{t_{n+1}} \sigma(X_s)dW_s \approx \sigma(X_{t_n})\Delta W_n + \sigma'(X_{t_n})\sigma(X_{t_n}) \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} dW_u dW_s$$

计算双重积分：

$$\int_{t_n}^{t_{n+1}} \int_{t_n}^{s} dW_u dW_s = \frac{1}{2}[(\Delta W_n)^2 - \Delta]$$

得到 Milstein 方法：

$$Y_{n+1} = Y_n + \mu(Y_n)\Delta + \sigma(Y_n)\Delta W_n + \frac{1}{2}\sigma(Y_n)\sigma'(Y_n)[(\Delta W_n)^2 - \Delta] \tag{7.2}$$

注 7.6 (几何解释). *最后一项 $\frac{1}{2}\sigma\sigma'[(\Delta W_n)^2 - \Delta]$ 正是 Itô 修正项在离散时间的体现。它校正了 Euler 方法忽略的二次变差效应。*

7.4.2 收敛性

定理 7.7 (Milstein 方法的收敛性). *在适当条件下，Milstein 方法强收敛阶为 1，弱收敛阶为 1。*

相比 Euler-Maruyama，Milstein 的强收敛阶提高了一倍，但需要计算导数 σ'。

7.4.3 导数自由格式

当 σ' 难以计算时，可用有限差分近似：

$$\sigma'(Y_n) \approx \frac{\sigma(Y_n + \sigma(Y_n)\sqrt{\Delta}) - \sigma(Y_n)}{\sigma(Y_n)\sqrt{\Delta}}$$

这得到导数自由的 Milstein 型方法。

7.5 随机 Taylor 展开与高阶方法

要构造更高阶的方法，需要系统化的展开工具——随机 Taylor 展开 (Itô-Taylor 展开)。

7.5.1 Itô-Taylor 展开

考虑自治 SDE $dX_t = \mu(X_t)dt + \sigma(X_t)dW_t$。对光滑函数 f，由 Itô 公式：

$$f(X_t) = f(X_0) + \int_0^t \mathcal{L}^0 f(X_s)ds + \int_0^t \mathcal{L}^1 f(X_s)dW_s$$

其中算子：

$$\mathcal{L}^0 = \mu\frac{\partial}{\partial x} + \frac{1}{2}\sigma^2\frac{\partial^2}{\partial x^2}, \quad \mathcal{L}^1 = \sigma\frac{\partial}{\partial x}$$

再对 $\mathcal{L}^0 f$ 和 $\mathcal{L}^1 f$ 应用 Itô 公式，得到高阶展开。记多重积分：

$$I_{(0)} = \int_{t_n}^{t_{n+1}} ds, \quad I_{(1)} = \int_{t_n}^{t_{n+1}} dW_s$$

$$I_{(1,1)} = \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} dW_u dW_s = \frac{1}{2}[(\Delta W_n)^2 - \Delta]$$

$$I_{(1,0)} = \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} dW_u ds, \quad I_{(0,1)} = \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} du dW_s$$

则 Itô-Taylor 展开到一定阶数给出相应阶的数值方法。

7.5.2 高阶方法举例

阶 1.5 强方法

包含更多项得到阶 1.5 强方法：

$$\begin{aligned} Y_{n+1} = Y_n + \mu\Delta + \sigma\Delta W_n + \frac{1}{2}\sigma\sigma'[(\Delta W_n)^2 - \Delta] \\ + \mu'\sigma I_{(1,0)} + \left(\mu\sigma' + \frac{1}{2}\sigma^2\sigma''\right) I_{(0,1)} \\ + \left(\sigma(\sigma\sigma')' + \frac{1}{2}\sigma^2\sigma''\right)\left(\frac{1}{3}(\Delta W_n)^2 - \Delta\right)\Delta W_n \end{aligned}$$

需要生成 $I_{(1,0)}$ 和 $I_{(0,1)}$ 的联合分布。

Runge-Kutta 型方法

类似于 ODE 的 Runge-Kutta 方法，也有随机版本。例如，阶 1.0 强随机 Runge-Kutta 方法：

$$\begin{aligned} k_1 &= \mu(Y_n)\Delta + \sigma(Y_n)\Delta W_n \\ k_2 &= \mu(Y_n + k_1)\Delta + \sigma(Y_n + k_1)\Delta W_n \\ Y_{n+1} &= Y_n + \frac{1}{2}(k_1 + k_2) \end{aligned}$$

但需要注意：随机 Runge-Kutta 的设计比确定性情形复杂，因为要匹配随机 Taylor 展开的项。

7.6 蒙特卡洛方法：计算期望

在许多应用中，我们最终需要计算期望 $\mathbb{E}[f(X_T)]$，如期权价格。蒙特卡洛方法通过模拟大量样本路径，用样本平均近似期望。

7.6.1 基本蒙特卡洛

算法：

1. 对 $i = 1, \ldots, M$（M 大）：
   (a) 用数值方法（如 Euler-Maruyama）模拟一条路径，得到 $Y_T^{(i)}$
   (b) 计算 $f_i = f(Y_T^{(i)})$
2. 估计 $\hat{\mu} = \frac{1}{M}\sum_{i=1}^{M} f_i$

由大数定律，$\hat{\mu} \xrightarrow{a.s.} \mathbb{E}[f(Y_T^{\Delta})]$。进一步，如果数值方法弱收敛阶 β，则

$$\left|\mathbb{E}[f(X_T)] - \mathbb{E}[f(Y_T^{\Delta})]\right| \le C_1\Delta^{\beta}$$

由中心极限定理，

$$\sqrt{M}(\hat{\mu} - \mathbb{E}[f(Y_T^{\Delta})]) \Rightarrow N(0, \mathrm{Var}(f(Y_T^{\Delta})))$$

总误差（偏差 + 标准差）：

$$\mathrm{RMSE} \approx C_1\Delta^{\beta} + \frac{C_2}{\sqrt{M}}$$

7.6.2 方差缩减技术

蒙特卡洛方法的收敛速度 $O(1/\sqrt{M})$ 较慢。方差缩减技术通过降低方差 C_2 来提高效率。

对偶变量法

对于对称分布（如布朗运动增量），生成一对路径：一条用 $\{\Delta W_n\}$，另一条用 $\{-\Delta W_n\}$。则

$$\hat{\mu}_{\mathrm{AV}} = \frac{1}{2M}\sum_{i=1}^{M}[f(Y_T^{(i)+}) + f(Y_T^{(i)-})]$$

方差减少因为 $f(Y_T^+)$ 和 $f(Y_T^-)$ 负相关。

控制变量法

如果能找到与 $f(X_T)$ 高度相关且期望已知的随机变量 $g(X_T)$，则用：

$$\hat{\mu}_{\mathrm{CV}} = \frac{1}{M}\sum_{i=1}^{M}[f(Y_T^{(i)}) - c(g(Y_T^{(i)}) - \mathbb{E}[g(X_T)])]$$

最优 $c = \mathrm{Cov}(f,g)/\mathrm{Var}(g)$。

在几何布朗运动中，常用 $g(S_T) = S_T$ 作为控制变量，因为 $\mathbb{E}[S_T] = S_0 e^{rT}$ 已知。

重要性抽样

改变测度使重要区域更多采样。设新测度 $\mathbb{Q}$ 满足 $\frac{d\mathbb{Q}}{d\mathbb{P}} = L_T$，则

$$\mathbb{E}^{\mathbb{P}}[f(X_T)] = \mathbb{E}^{\mathbb{Q}}[f(X_T)L_T^{-1}]$$

选择 $\mathbb{Q}$ 使 $f(X_T)L_T^{-1}$ 方差更小。

7.6.3 多级蒙特卡洛

多级蒙特卡洛（Multilevel Monte Carlo, MLMC）是近年来的突破性进展，巧妙结合不同精度的模拟。

基本思想

设 Y^{Δ_ℓ} 为步长 $\Delta_\ell = \Delta_0 2^{-\ell}$ 的近似，$\ell = 0, \ldots, L$。则

$$\mathbb{E}[f(Y^{\Delta_L})] = \mathbb{E}[f(Y^{\Delta_0})] + \sum_{\ell=1}^{L} \mathbb{E}[f(Y^{\Delta_\ell}) - f(Y^{\Delta_{\ell-1}})]$$

关键观察：Y^{Δ_ℓ} 和 $Y^{\Delta_{\ell-1}}$ 高度相关，因此差分 $f(Y^{\Delta_\ell}) - f(Y^{\Delta_{\ell-1}})$ 方差很小。

算法

对每层 ℓ，用 M_ℓ 对路径模拟 $f(Y^{\Delta_\ell}) - f(Y^{\Delta_{\ell-1}})$（模拟时使用相同的布朗运动）。估计量为：

$$\hat{\mu}_{\mathrm{ML}} = \frac{1}{M_0} \sum_{i=1}^{M_0} f(Y^{\Delta_0,(i)}) + \sum_{\ell=1}^{L} \frac{1}{M_\ell} \sum_{i=1}^{M_\ell} [f(Y^{\Delta_\ell,(i)}) - f(Y^{\Delta_{\ell-1},(i)})]$$

复杂度分析

最优分配 $M_\ell \propto \sqrt{\mathrm{Var}_\ell / C_\ell}$，其中 Var_ℓ 是差分方差，C_ℓ 是每对路径成本。总成本 $O(\epsilon^{-2}(\log \epsilon)^2)$，显著优于普通蒙特卡洛的 $O(\epsilon^{-3})$（考虑离散化误差和抽样误差）。

7.7 拟蒙特卡洛与随机数生成

7.7.1 拟蒙特卡洛

拟蒙特卡洛（Quasi-Monte Carlo, QMC）用低差异序列代替随机数，理论误差阶 $O((\log N)^d / N)$，优于 MC 的 $O(1/\sqrt{N})$，尤其在高维 d 不大时有效。

对 SDE 模拟，需要将布朗运动路径表示为独立高斯变量的线性组合：

$$W_t = \sum_{k=1}^{\infty} \sqrt{\lambda_k} \xi_k e_k(t)$$

其中 $\{\xi_k\}$ 独立 $N(0,1)$，$\{\lambda_k, e_k\}$ 是协方差算子 $\mathrm{Cov}(W_s, W_t) = \min(s,t)$ 的特征对。

截断到 d 维，用 QMC 点 $(\xi_1, \ldots, \xi_d)$ 生成路径。

7.7.2 随机数生成

高质量随机数对蒙特卡洛至关重要。

- **伪随机数**：线性同余、Mersenne Twister 等
- **随机数流管理**：确保可重复性、并行化
- **相关性处理**：Cholesky 分解生成相关正态变量

7.8 辛几何方法：保持结构性质

某些 SDE 具有几何结构（如辛结构、体积保持），普通数值方法可能破坏这些结构，导致长期模拟失真。

7.8.1 Stratonovich 积分的优势

对于几何性质，通常用 Stratonovich 积分更自然：

$$dX_t = \mu(X_t)dt + \sigma(X_t) \circ dW_t$$

因为它满足经典链式法则。相应的数值方法需要模拟 Stratonovich 积分。

7.8.2 隐式方法

类似于 ODE，隐式方法有更好稳定性。例如，隐式 Euler-Maruyama：

$$Y_{n+1} = Y_n + \mu(Y_{n+1})\Delta + \sigma(Y_n)\Delta W_n$$

需要解方程（通常用牛顿法）。

半隐式方法折中：

$$Y_{n+1} = Y_n + [\theta\mu(Y_{n+1}) + (1-\theta)\mu(Y_n)]\Delta + \sigma(Y_n)\Delta W_n$$

$\theta = 1/2$ 对应梯形法则。

7.8.3 投影方法

当解需要满足约束（如正性、范数保持），可在每步后投影到约束集。

7.9 高维 SDE 与稀疏网格

高维 SDE（如 $d > 3$）面临维数灾难。稀疏网格方法可以减少计算量。

7.9.1 稀疏网格求积

用稀疏网格点代替全网格，点数为 $O(N(\log N)^{d-1})$，而不是 $O(N^d)$。

7.9.2 降维技术

- **主成分分析**：用少数主要布朗运动方向
- **低秩近似**：近似扩散矩阵
- **均值场近似**：对交互粒子系统

7.10 深度学习与 SDE 求解

近年来，深度学习为高维 SDE 求解提供了新思路。

7.10.1 神经 SDE

用神经网络参数化漂移和扩散：

$$dX_t = \mu_\theta(t, X_t)dt + \sigma_\phi(t, X_t)dW_t$$

从数据学习 θ, ϕ。

7.10.2 求解高维 PDE

通过 Feynman-Kac 公式，高维 PDE $\frac{\partial u}{\partial t} + \mathcal{L}u = 0$ 的解可表示为 SDE 的条件期望。用神经网络近似 u，通过模拟 SDE 路径训练。

7.10.3 生成模型

扩散模型（diffusion models）本质上是逆向 SDE：

$$dX_t = f(X_t, t)dt + g(t)dW_t \quad (\text{正向})$$

$$dX_t = [f(X_t, t) - g^2(t)\nabla \log p_t(X_t)]dt + g(t)d\tilde{W}_t \quad (\text{逆向})$$

用神经网络学习 score 函数 $\nabla \log p_t$。

本章总结

本章系统研究了 SDE 的数值方法，要点如下：

1. **收敛性概念**：强收敛（路径逼近）与弱收敛（分布逼近）
2. **基本方法**：Euler-Maruyama（强 1/2，弱 1）、Milstein（强 1，弱 1）
3. **高阶方法**：随机 Taylor 展开、Runge-Kutta 型方法
4. **蒙特卡洛**：基本方法、方差缩减技术、多级蒙特卡洛突破
5. **结构保持**：隐式方法、辛几何方法
6. **高维挑战**：稀疏网格、降维技术
7. **现代发展**：深度学习与 SDE 结合

数值方法使理论 SDE 能够应用于实际问题。选择方法时需要权衡：

- 精度需求：强收敛还是弱收敛
- 计算资源：复杂度与成本
- 问题结构：是否需保持几何性质
- 维度：低维可用高阶方法，高维需要蒙特卡洛

SDE 数值分析是一个活跃的研究领域，传统方法不断改进，新方法（如深度学习）不断涌现。掌握这些方法不仅需要理解算法，更需要理解背后的随机分析原理。

在下一章，我们将研究测度变换与 Girsanov 定理，这是连接真实测度与风险中性测度的关键，也是金融应用的理论基础。

历史注记

Euler-Maruyama 方法由 Maruyama 在 1955 年提出。Milstein 在 1974 年提出高阶方法。随机 Taylor 展开由 Wagner 和 Platen 在 1970 年代系统发展。多级蒙特卡洛由 Heinrich(2001) 对参数积分和 Giles(2008) 对 SDE 提出，是计算数学的重要突破。神经 SDE 由 Kidger 等 (2021) 系统研究。扩散模型中的逆向 SDE 由 Song 等 (2021) 建立。这些进展共同推动了 SDE 计算能力的发展。

Chapter 8

测度变换与 Girsanov 定理

8.1 引言：改变概率视角的艺术

在前几章中，我们一直在固定的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上工作，$\mathbb{P}$ 被视为"真实"概率测度。然而，在许多应用中，特别是金融数学和统计推断中，我们经常需要改变概率测度的视角。这种改变不是任意的——我们需要新测度与原测度等价（相互绝对连续），以保证零概率事件一致。

本章的核心思想是：通过适当的密度过程（Radon-Nikodym 导数），我们可以将原测度下的随机过程转化为新测度下的不同过程。特别地，我们可以"漂移"布朗运动，使其在新测度下成为带有漂移的布朗运动，或更一般地，改变 SDE 的漂移系数。

从三种基本操作的视角看，测度变换是 ** 对样本空间 Ω 上的积分测度的变换 **。它将原测度 $\mathbb{P}$ 下的积分 $\int_\Omega X d\mathbb{P}$ 转化为新测度 $\mathbb{Q}$ 下的积分 $\int_\Omega X d\mathbb{Q} = \int_\Omega X \frac{d\mathbb{Q}}{d\mathbb{P}} d\mathbb{P}$。这种变换深刻影响了随机过程的表现形式。

8.2 绝对连续与等价测度

8.2.1 测度的绝对连续性

定义 8.1 (绝对连续测度). 设 $\mathbb{P}$ 和 $\mathbb{Q}$ 是 $(\Omega, \mathcal{F})$ 上的两个概率测度。称 $\mathbb{Q}$ 关于 $\mathbb{P}$ 绝对连续（记为 $\mathbb{Q} \ll \mathbb{P}$），如果对任意 $A \in \mathcal{F}$，

$$\mathbb{P}(A) = 0 \quad \Rightarrow \quad \mathbb{Q}(A) = 0$$

如果 $\mathbb{Q} \ll \mathbb{P}$ 且 $\mathbb{P} \ll \mathbb{Q}$，则称 $\mathbb{P}$ 与 $\mathbb{Q}$ 等价，记为 $\mathbb{P} \sim \mathbb{Q}$。

等价测度的重要性在于：它们对”什么事件可能发生”具有一致的看法（零概率事件相同），但对这些事件的概率赋值不同。

8.2.2 Radon-Nikodym 导数

定理 8.2 (Radon-Nikodym). 若 $\mathbb{Q} \ll \mathbb{P}$，则存在 $\mathcal{F}$-可测非负随机变量 Z，满足 $\mathbb{E}^{\mathbb{P}}[Z] = 1$，使得

$$\mathbb{Q}(A) = \int_A Z d\mathbb{P} = \mathbb{E}^{\mathbb{P}}[Z\mathbf{1}_A], \quad \forall A \in \mathcal{F}$$

Z 称为 $\mathbb{Q}$ 关于 $\mathbb{P}$ 的 *Radon-Nikodym* 导数，记为 $Z = \frac{d\mathbb{Q}}{d\mathbb{P}}$。

从积分变换的角度：

$$\mathbb{E}^{\mathbb{Q}}[X] = \int_\Omega X d\mathbb{Q} = \int_\Omega X \frac{d\mathbb{Q}}{d\mathbb{P}} d\mathbb{P} = \mathbb{E}^{\mathbb{P}}\left[X \frac{d\mathbb{Q}}{d\mathbb{P}}\right]$$

8.2.3 过滤下的 Radon-Nikodym 过程

在随机分析中，我们通常考虑适应于某个过滤 $\{\mathcal{F}_t\}$ 的测度变换。定义密度过程：

$$Z_t = \mathbb{E}^{\mathbb{P}}\left[\frac{d\mathbb{Q}}{d\mathbb{P}}\middle| \mathcal{F}_t\right]$$

则 $\{Z_t\}$ 是 $\mathbb{P}$-鞅，满足：

1. $Z_t \geq 0$ a.s.
2. $\mathbb{E}^{\mathbb{P}}[Z_t] = 1$

3. 对任意 $\mathcal{F}_t$-可测随机变量 X，$\mathbb{E}^{\mathbb{Q}}[X] = \mathbb{E}^{\mathbb{P}}[XZ_t]$

注 8.3 (密度过程的直观). Z_t 衡量了到时刻 t 为止，$\mathbb{Q}$ 与 $\mathbb{P}$ 的"相对权重"。如果 $Z_t > 1$，说明在已观察到的信息下，$\mathbb{Q}$ 赋予事件比 $\mathbb{P}$ 更高的概率。

8.3 Girsanov 定理：改变布朗运动的漂移

Girsanov 定理是随机分析中最重要的定理之一，它告诉我们如何通过改变测度来"漂移"布朗运动。

8.3.1 基本 Girsanov 定理

定理 8.4 (Girsanov 定理（一维）). 设 $\{W_t\}$ 是 $\mathbb{P}$ 下的标准布朗运动，$\{\theta_t\}$ 是适应过程，满足 *Novikov* 条件：

$$\mathbb{E}^{\mathbb{P}}\left[\exp\left(\frac{1}{2}\int_0^T \theta_t^2 dt\right)\right] < \infty$$

定义密度过程：

$$Z_t = \exp\left(-\int_0^t \theta_s dW_s - \frac{1}{2}\int_0^t \theta_s^2 ds\right)$$

则：

1. $\{Z_t\}$ 是 $\mathbb{P}$-鞅

2. 定义新测度 $\mathbb{Q}$ 使得 $\frac{d\mathbb{Q}}{d\mathbb{P}}\big|_{\mathcal{F}_t} = Z_t$

3. 过程 $\tilde{W}_t = W_t + \int_0^t \theta_s ds$ 是 $\mathbb{Q}$ 下的标准布朗运动

证明思路. 关键步骤：

1. 由 Novikov 条件保证 Z_t 是鞅（而不仅仅是局部鞅）
2. 对任意 f，计算 $\mathbb{E}^{\mathbb{Q}}[f(\tilde{W}_t)] = \mathbb{E}^{\mathbb{P}}[f(\tilde{W}_t)Z_t]$
3. 通过 Itô 公式验证 $\tilde{W}_t$ 在 $\mathbb{Q}$ 下具有布朗运动的有限维分布
4. Lévy 刻画定理：验证 $\tilde{W}_t$ 是 $\mathbb{Q}$-鞅且 $(\tilde{W}_t)^2 - t$ 是 $\mathbb{Q}$-鞅

□

8.3.2 Novikov 条件的意义

Novikov 条件 $\mathbb{E}[\exp(\frac{1}{2}\int_0^T \theta_t^2 dt)] < \infty$ 保证 $\{Z_t\}$ 是鞅（不仅仅是局部鞅）。如果只假设 $\int_0^T \theta_t^2 dt < \infty$ a.s.，则 Z_t 是局部鞅，但不一定是鞅，这可能导致新测度 $\mathbb{Q}$ 不是概率测度（总质量可能小于 1）。

在实际应用中，如果 θ_t 有界或确定性，Novikov 条件通常满足。

8.3.3 多维推广

定理 8.5 (多维 Girsanov 定理)**.** *设 $\mathbf{W}_t = (W_t^1, \ldots, W_t^d)$ 是 $\mathbb{P}$ 下的 d 维布朗运动，$\boldsymbol{\theta}_t = (\theta_t^1, \ldots, \theta_t^d)$ 适应过程，满足*

$$\mathbb{E}^{\mathbb{P}}\left[\exp\left(\frac{1}{2}\int_0^T \|\boldsymbol{\theta}_t\|^2 dt\right)\right] < \infty$$

定义

$$Z_t = \exp\left(-\int_0^t \boldsymbol{\theta}_s \cdot d\mathbf{W}_s - \frac{1}{2}\int_0^t \|\boldsymbol{\theta}_s\|^2 ds\right)$$

则 $\tilde{\mathbf{W}}_t = \mathbf{W}_t + \int_0^t \boldsymbol{\theta}_s ds$ 是 $\mathbb{Q}$ 下的 d 维布朗运动，其中 $\frac{d\mathbb{Q}}{d\mathbb{P}} = Z_T$。

8.4 Girsanov 定理的应用：SDE 的测度变换

8.4.1 改变 SDE 的漂移系数

考虑 $\mathbb{P}$ 下的 SDE：

$$dX_t = \mu(t, X_t)dt + \sigma(t, X_t)dW_t$$

我们希望找到等价测度 $\mathbb{Q}$，使得 X_t 在 $\mathbb{Q}$ 下满足：

$$dX_t = \tilde{\mu}(t, X_t)dt + \sigma(t, X_t)d\tilde{W}_t$$

其中 $\tilde{W}_t$ 是 $\mathbb{Q}$ 下的布朗运动。

设 θ_t 满足：

$$\mu(t, X_t) - \tilde{\mu}(t, X_t) = \sigma(t, X_t)\theta_t$$

即 $\theta_t = \frac{\mu(t,X_t)-\tilde{\mu}(t,X_t)}{\sigma(t,X_t)}$（假设 $\sigma \neq 0$）。

由 Girsanov 定理，取

$$Z_t = \exp\left(-\int_0^t \theta_s dW_s - \frac{1}{2}\int_0^t \theta_s^2 ds\right)$$

则 $\tilde{W}_t = W_t + \int_0^t \theta_s ds$ 是 $\mathbb{Q}$ 下的布朗运动，且

$$\begin{aligned}
dX_t &= \mu(t, X_t)dt + \sigma(t, X_t)dW_t \\
&= \mu(t, X_t)dt + \sigma(t, X_t)\left(d\tilde{W}_t - \theta_t dt\right) \\
&= \left[\mu(t, X_t) - \sigma(t, X_t)\theta_t\right]dt + \sigma(t, X_t)d\tilde{W}_t \\
&= \tilde{\mu}(t, X_t)dt + \sigma(t, X_t)d\tilde{W}_t
\end{aligned}$$

8.4.2 风险中性测度：金融中的经典应用

在 Black-Scholes 模型中，股票价格在真实测度 $\mathbb{P}$ 下满足：

$$dS_t = \mu S_t dt + \sigma S_t dW_t$$

其中 μ 为期望收益率，σ 为波动率。

在期权定价中，我们希望找到等价测度 $\mathbb{Q}$（风险中性测度），使得贴现价格过程 $\tilde{S}_t = e^{-rt}S_t$ 是 $\mathbb{Q}$-鞅。这要求漂移系数为 r：

$$dS_t = rS_t dt + \sigma S_t d\tilde{W}_t$$

取 $\theta_t = \frac{\mu - r}{\sigma}$（常数，称为市场风险价格），则

$$Z_t = \exp\left(-\frac{\mu - r}{\sigma}W_t - \frac{1}{2}\left(\frac{\mu - r}{\sigma}\right)^2 t\right)$$

定义了风险中性测度 $\mathbb{Q}$。在 $\mathbb{Q}$ 下，$\tilde{W}_t = W_t + \frac{\mu - r}{\sigma}t$ 是布朗运动，且

$$dS_t = rS_t dt + \sigma S_t d\tilde{W}_t$$

欧式期权价格可计算为：

$$C(t, S_t) = e^{-r(T-t)}\mathbb{E}^{\mathbb{Q}}[\max(S_T - K, 0)|\mathcal{F}_t]$$

8.4.3 Cameron-Martin 公式：确定性漂移

当 $\theta_t = \theta$ 常数时，Girsanov 定理退化为经典的 Cameron-Martin 公式：

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \exp\left(-\theta W_T - \frac{1}{2}\theta^2 T\right)$$

且在 $\mathbb{Q}$ 下，$W_t + \theta t$ 是布朗运动。

这可以看作无穷维空间上的平移：测度 $\mathbb{Q}$ 是 $\mathbb{P}$ 沿方向 θt 的平移。

8.5 局部鞅与半鞅的 Girsanov 定理

8.5.1 连续半鞅的 Girsanov 定理

更一般地，考虑 $\mathbb{P}$ 下的连续半鞅：

$$X_t = M_t + A_t$$

其中 M_t 是 $\mathbb{P}$-局部鞅，A_t 是有限变差过程。

设 Z_t 是严格正连续鞅，定义 $\mathbb{Q}$ 使得 $\frac{d\mathbb{Q}}{d\mathbb{P}}\big|_{\mathcal{F}_t} = Z_t$。由鞅表示定理，存在适应过程 ψ_t 使得

$$dZ_t = Z_t \psi_t dM_t$$

(假设 M 有连续路径且 $\langle M\rangle_t$ 绝对连续)。

则在 $\mathbb{Q}$ 下，

$$X_t = \tilde{M}_t + \int_0^t \psi_s d\langle M\rangle_s + A_t$$

其中 $\tilde{M}_t$ 是 $\mathbb{Q}$-局部鞅。

8.5.2 扩散系数不变性

一个重要观察：在扩散过程中，测度变换只改变漂移系数，不改变扩散系数。直观上，这是因为扩散系数 $\sigma(t, X_t)$ 描述了过程的”噪声强度”，这是路径的局部性质，而测度变换（等价测度）不能改变几乎必然成立的路径性质。

数学上，二次变差过程 $[X]_t = \int_0^t \sigma^2(s, X_s)ds$ 在 $\mathbb{P}$ 和 $\mathbb{Q}$ 下相同，因为它是路径 wise 定义的。

8.6 鞅表示定理与测度变换

8.6.1 鞅表示定理回顾

在布朗运动滤波 $\{\mathcal{F}_t^W\}$ 下，任何平方可积 $\mathcal{F}_T^W$-鞅 M_t 可表示为：

$$M_t = M_0 + \int_0^t \phi_s dW_s$$

其中 ϕ_s 适应且 $\int_0^T \mathbb{E}[\phi_s^2]ds < \infty$。

8.6.2 测度变换下的鞅表示

设 $\mathbb{Q} \sim \mathbb{P}$，密度过程 $Z_t = \frac{d\mathbb{Q}}{d\mathbb{P}}|_{\mathcal{F}_t}$。若 M_t 是 $\mathbb{P}$-鞅，则 $\tilde{M}_t = M_t Z_t$ 一般是 $\mathbb{Q}$-鞅吗？不一定。

实际上，如果 M_t 是 $\mathbb{P}$-鞅且与 Z_t 独立，则 $\tilde{M}_t$ 是 $\mathbb{Q}$-鞅。更一般地，有 Bayes 公式：

定理 8.6 (Bayes 公式)**.** 设 $\mathbb{Q} \ll \mathbb{P}$，$Z_t = \frac{d\mathbb{Q}}{d\mathbb{P}}|_{\mathcal{F}_t}$。若 X 是 $\mathcal{F}_T$-可测可积随机变量，则

$$\mathbb{E}^{\mathbb{Q}}[X|\mathcal{F}_t] = \frac{\mathbb{E}^{\mathbb{P}}[XZ_T|\mathcal{F}_t]}{Z_t}$$

特别地，若 M_t 是 $\mathbb{P}$-鞅，则 $\frac{M_t}{Z_t}$ 是 $\mathbb{Q}$-鞅当且仅当 $M_t Z_t$ 是 $\mathbb{P}$-鞅。

8.7 统计推断中的应用：参数估计

8.7.1 似然比过程

设观测到过程 $\{X_t\}$ 满足：

$$dX_t = \theta b(t, X_t)dt + \sigma(t, X_t)dW_t$$

其中 θ 是未知参数。

考虑简单假设检验：$H_0 : \theta = 0$ vs $H_1 : \theta = \theta_1$。在 H_0 下，$dX_t = \sigma(t, X_t)dW_t$；在 H_1 下，$dX_t = \theta_1 b(t, X_t)dt + \sigma(t, X_t)dW_t$。

似然比（Radon-Nikodym 导数）为：

$$L_T = \exp\left(\int_0^T \frac{\theta_1 b(t, X_t)}{\sigma^2(t, X_t)} dX_t - \frac{1}{2}\int_0^T \frac{\theta_1^2 b^2(t, X_t)}{\sigma^2(t, X_t)} dt\right)$$

注意：这里 dX_t 出现在被积函数中，需要小心解释（通常理解为 Itô 积分）。

8.7.2 最大似然估计

对一般 θ，似然函数为：

$$L_T(\theta) = \exp\left(\int_0^T \frac{\theta b(t, X_t)}{\sigma^2(t, X_t)} dX_t - \frac{1}{2}\int_0^T \frac{\theta^2 b^2(t, X_t)}{\sigma^2(t, X_t)} dt\right)$$

对数似然：

$$\ell_T(\theta) = \theta \int_0^T \frac{b(t, X_t)}{\sigma^2(t, X_t)} dX_t - \frac{\theta^2}{2}\int_0^T \frac{b^2(t, X_t)}{\sigma^2(t, X_t)} dt$$

最大似然估计：

$$\hat{\theta}_T = \frac{\int_0^T \frac{b(t,X_t)}{\sigma^2(t,X_t)} dX_t}{\int_0^T \frac{b^2(t,X_t)}{\sigma^2(t,X_t)} dt}$$

8.8 市场完备性与鞅表示

8.8.1 完备市场与等价鞅测度

在金融中，一个基本问题是：给定资产价格过程 $\{S_t\}$，是否存在唯一的等价鞅测度（EMM）$\mathbb{Q}$ 使得贴现价格是 $\mathbb{Q}$-鞅?

定义 8.7 (完备市场). *市场称为完备的，如果任何未定权益（$\mathcal{F}_T$-可测随机变量 H）都可以通过自融资交易策略复制。*

定理 8.8 (完备性定理). *在布朗运动驱动的模型中，市场完备当且仅当等价鞅测度唯一。*

证明思路：如果 EMM 唯一，则任何未定权益 H 的贴现价格 $e^{-rT}H$ 在风险中性测度下的条件期望给出复制策略，由鞅表示定理保证可表示性。

8.8.2 多资产情形

设有 d 个风险资产，m 个布朗运动源（$m \geq d$）。如果 $m = d$ 且扩散矩阵非奇异（满秩），则市场完备，EMM 唯一。如果 $m > d$，市场不完备，存在多个 EMM。

8.9 跳过程的 Girsanov 定理

8.9.1 泊松过程的测度变换

设 N_t 是 $\mathbb{P}$ 下的泊松过程，强度 $\lambda > 0$。我们希望改变强度到 $\tilde{\lambda} > 0$。

定义密度过程：

$$Z_t = \left(\frac{\tilde{\lambda}}{\lambda}\right)^{N_t} \exp\Big(-(\tilde{\lambda} - \lambda)t\Big)$$

则 Z_t 是 $\mathbb{P}$-鞅，且在新测度 $\mathbb{Q}$（由 Z_t 定义）下，N_t 是强度为 $\tilde{\lambda}$ 的泊松过程。

8.9.2 跳跃扩散过程的 Girsanov 定理

考虑跳跃扩散过程：

$$dX_t = \mu_t dt + \sigma_t dW_t + \gamma_t dN_t$$

其中 N_t 是泊松过程，强度 λ。

可以同时改变布朗运动的漂移和泊松过程的强度：

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \exp\left(-\int_0^T \theta_s dW_s - \frac{1}{2}\int_0^T \theta_s^2 ds\right)\left(\frac{\tilde{\lambda}}{\lambda}\right)^{N_T} \exp\Big(-(\tilde{\lambda} - \lambda)T\Big)$$

在 $\mathbb{Q}$ 下，$\tilde{W}_t = W_t + \int_0^t \theta_s ds$ 是布朗运动，N_t 是强度 $\tilde{\lambda}$ 的泊松过程。

8.10 实际计算中的注意事项

8.10.1 Novikov 条件的验证

在实际中，验证 Novikov 条件可能困难。常用的充分条件：

1. θ_t 确定性有界
2. θ_t 适应且 $\int_0^T \mathbb{E}[\exp(\frac{1}{2}\theta_t^2)]dt < \infty$
3. Kazamaki 条件：$\sup_\tau \mathbb{E}[\exp(\frac{1}{2}\int_0^\tau \theta_t dW_t)] < \infty$，其中 τ 为停时

8.10.2 模拟中的测度变换

在蒙特卡洛模拟中，有两种策略：

1. 在 $\mathbb{P}$ 下模拟，用重要性抽样加权
2. 在 $\mathbb{Q}$ 下直接模拟

方法 1：在 $\mathbb{P}$ 下模拟路径，计算 Z_T，估计 $\mathbb{E}^{\mathbb{Q}}[X] = \mathbb{E}^{\mathbb{P}}[XZ_T]$
方法 2：在 $\mathbb{Q}$ 下模拟，需要生成 $\mathbb{Q}$ 下的路径（布朗运动带有漂移）
方法 2 通常方差更小，因为 X 与 Z_T 可能负相关。

8.10.3 Radon-Nikodym 导数的路径 wise 解释

虽然 $Z_t = \frac{d\mathbb{Q}}{d\mathbb{P}}|_{\mathcal{F}_t}$ 是整体定义的，但可以给出启发式的路径 wise 解释。考虑两条" 相近" 的路径 ω 和 ω'，则

$$\frac{\mathbb{Q}(d\omega)}{\mathbb{P}(d\omega)} \approx \frac{\text{“}\mathbb{Q}\text{ 下路径 }\omega\text{ 的概率密度”}}{\text{“}\mathbb{P}\text{ 下路径 }\omega\text{ 的概率密度”}}$$

在有限维近似中，这对应于有限维分布的密度比。

本章总结

本章深入研究了测度变换与 Girsanov 定理，要点如下：

1. **等价测度**：保证零概率事件一致，通过 Radon-Nikodym 导数关联
2. **Girsanov 定理**：通过指数鞅改变测度，从而漂移布朗运动
3. **金融应用**：风险中性定价的核心，将真实测度转化为风险中性测度
4. **SDE 变换**：测度变换只改变漂移系数，不改变扩散系数
5. **统计推断**：参数估计中的似然比计算

6. **市场完备性**：与等价鞅测度唯一性的关系
7. **跳过程**：泊松过程的强度变换

Girsanov 定理的重要性在于它提供了 ** 改变随机过程视角 ** 的系统方法。从三种基本操作的视角看：

- 测度变换改变了 ** 对样本 ω 积分 ** 的测度
- 这进而影响了 **Itô 积分 ** 的表现形式（通过改变布朗运动）
- 最终改变了 ** 时间积分 ** 项（漂移项）

在金融中，这允许我们从真实世界（$\mathbb{P}$ 测度）转换到风险中性世界（$\mathbb{Q}$ 测度），从而简化定价。在统计中，这提供了假设检验和参数估计的基础。

掌握 Girsanov 定理不仅需要理解其数学表述，更需要理解其几何直观：概率测度的" 倾斜" 或" 平移"，以及这种变换如何影响随机过程的动力学。

在下一章，我们将进入倒向随机微分方程（BSDE）的世界，这是随机分析的另一重要分支，在金融、控制等领域有广泛应用。

历史注记

Girsanov 定理由苏联数学家 I.V. Girsanov 在 1960 年提出，是随机分析里程碑式的成果。Radon-Nikodym 定理可追溯到 1930 年代。在金融中的应用由 Harrison 和 Kreps(1979)、Harrison 和 Pliska(1981) 系统发展，建立了风险中性定价理论。鞅表示定理由 Itô(1951) 和 Kunita-Watanabe(1967) 建立。这些理论共同构成了现代金融数学的基础。

Chapter 9

倒向随机微分方程入门

9.1 引言：正向与倒向的哲学对话

在前八章中，我们研究的都是 ** 正向随机微分方程（SDE）**：给定初始条件 X_0，方程描述系统向未来的演化。这种" 因果性" 与物理学中的时间箭头一致：现在决定未来。

然而，在许多实际问题中，我们面临的是 ** 倒向问题 **：给定终端条件 $X_T = \xi$，需要反推系统过去的状态或演化规律。这类问题出现在：

- 金融：期权定价——给定到期收益，反推当前价格
- 控制：最优控制——给定终端目标，设计控制策略
- 偏微分方程：给定边界条件，求解方程

倒向随机微分方程（Backward Stochastic Differential Equation, BSDE）正是为这类问题设计的数学工具。与 SDE 相比，BSDE 的独特之处在于：

1. **终端条件**：给定 $\xi \in \mathcal{F}_T$，而非初始条件
2. **解对**：解是过程对 (Y_t, Z_t)，而非单一过程
3. **适应性与非因果性**：Y_t 需要适应未来信息 ξ

从三种基本操作的视角看，BSDE 将 ** 对样本 ω 的积分 **（体现在终端条件 ξ 的随机性）与 ** 对时间 t 的积分 ** 和 **Itô 积分 ** 以一种新颖的方式结合起来。特别地，Z_t 过程起到了" 对冲未来不确定性" 的作用。

9.2 BSDE 的基本形式与直观解释

9.2.1 标准形式

考虑最简单的一维 BSDE：

$$\begin{cases} dY_t = -f(t, Y_t, Z_t)dt + Z_t dW_t, \quad t \in [0, T] \\ Y_T = \xi \end{cases} \tag{9.1}$$

等价积分形式：

$$Y_t = \xi + \int_t^T f(s, Y_s, Z_s)ds - \int_t^T Z_s dW_s \tag{9.2}$$

这里：

- ξ：终端条件，$\mathcal{F}_T$-可测随机变量
- f：生成元（generator），可能依赖于 Y_t, Z_t
- (Y_t, Z_t)：解对，要求适应

注意符号约定：时间积分从 t 到 T（倒向），且带负号；Itô 积分也带负号。这使得方程在 $t = T$ 时给出 $Y_T = \xi$。

9.2.2 金融直观：复制与对冲

考虑金融中的复制问题。设 Y_t 是衍生品在 t 时刻的价格，ξ 是到期收益。如果存在交易策略 Z_t（持有标的资产的数量），使得：

$$\text{价格变化} = \text{资金成本} + \text{交易收益}$$

即

$$dY_t = rY_t dt + Z_t(dS_t/S_t - rdt)$$

其中 $dS_t/S_t = \mu dt + \sigma dW_t$。代入得：

$$dY_t = rY_t dt + Z_t\sigma(dW_t + \frac{\mu - r}{\sigma}dt) = rY_t dt + Z_t\sigma dW_t^Q$$

其中 $dW_t^Q = dW_t + \frac{\mu-r}{\sigma}dt$ 是风险中性测度下的布朗运动。

重排得：

$$dY_t = -(-rY_t)dt + Z_t\sigma dW_t^Q$$

这正是 BSDE 形式，$f(t,y,z) = -ry$，终端条件 ξ 为收益。

Z_t 的意义：对冲比率，用于复制终端收益。

9.2.3 与 SDE 的对比

	正向 SDE	倒向 BSDE
条件	初始 X_0 给定	终端 $Y_T = \xi$ 给定
解	过程 X_t	过程对 (Y_t, Z_t)
适应要求	$X_t \in \mathcal{F}_t$	$Y_t, Z_t \in \mathcal{F}_t$ 但 $\xi \in \mathcal{F}_T$
信息流	因果：过去 $\to$ 未来	非因果：需要适配未来
主要工具	Itô 公式	鞅表示定理

关键难点：在 BSDE 中，Y_t 必须适应 $\mathcal{F}_t$，但它依赖于未来信息 ξ。这似乎矛盾！解决这一矛盾的关键是 ** 鞅表示定理 **，它允许我们将 ξ 的"未来信息"编码到 Z_t 过程中。

9.3 鞅表示定理与线性 BSDE

9.3.1 鞅表示定理回顾

设 $\{W_t\}$ 为布朗运动，$\{\mathcal{F}_t\}$ 为其自然过滤。鞅表示定理说：对任意平方可积 $\mathcal{F}_T$-可测 ξ，存在适应过程 $\{Z_t\}$ 使得

$$\xi = \mathbb{E}[\xi] + \int_0^T Z_t dW_t$$

且表示唯一（在 L^2 意义下）。

等价地，对任意 t，

$$\mathbb{E}[\xi|\mathcal{F}_t] = \mathbb{E}[\xi] + \int_0^t Z_s dW_s$$

9.3.2 线性 BSDE 的显式解

考虑线性 BSDE：

$$\begin{cases} dY_t = -(a_tY_t + b_tZ_t + c_t)dt + Z_tdW_t \\ Y_T = \xi \end{cases} \tag{9.3}$$

这类方程可显式求解。思想：寻找积分因子。

设 Γ_t 满足：

$$d\Gamma_t = \Gamma_t(a_tdt + b_tdW_t), \quad \Gamma_0 = 1$$

即 $\Gamma_t = \exp\left(\int_0^t a_sds + \int_0^t b_sdW_s - \frac{1}{2}\int_0^t b_s^2ds\right)$。

计算 $d(\Gamma_tY_t)$：

$$\begin{aligned} d(\Gamma_tY_t) &= \Gamma_tdY_t + Y_td\Gamma_t + d[\Gamma, Y]_t \\ &= \Gamma_t[-(a_tY_t + b_tZ_t + c_t)dt + Z_tdW_t] \\ &\quad + Y_t\Gamma_t(a_tdt + b_tdW_t) + \Gamma_tb_tZ_tdt \\ &= -\Gamma_tc_tdt + \Gamma_t(Z_t + b_tY_t)dW_t \end{aligned}$$

积分从 t 到 T：

$$\Gamma_TY_T - \Gamma_tY_t = -\int_t^T \Gamma_sc_sds + \int_t^T \Gamma_s(Z_s + b_sY_s)dW_s$$

取条件期望 $\mathbb{E}[\cdot|\mathcal{F}_t]$，Itô 积分项消失（因为是鞅增量）：

$$\mathbb{E}[\Gamma_T\xi|\mathcal{F}_t] - \Gamma_tY_t = -\mathbb{E}\left[\int_t^T \Gamma_sc_sds \,\middle|\, \mathcal{F}_t\right]$$

解得：

$$Y_t = \frac{1}{\Gamma_t}\mathbb{E}\left[\Gamma_T\xi + \int_t^T \Gamma_sc_sds \,\middle|\, \mathcal{F}_t\right] \tag{9.4}$$

Z_t 可通过鞅表示定理得到：设

$$M_t = \mathbb{E}\left[\Gamma_T\xi + \int_0^T \Gamma_sc_sds \,\middle|\, \mathcal{F}_t\right]$$

则 $dM_t = \phi_tdW_t$，而由推导：

$$d(\Gamma_tY_t) = -\Gamma_tc_tdt + \Gamma_t(Z_t + b_tY_t)dW_t$$

比较得 $\Gamma_t(Z_t + b_tY_t) = \phi_t$，故

$$Z_t = \frac{\phi_t}{\Gamma_t} - b_tY_t$$

9.3.3 特例：$f = 0$ 的 BSDE

当 $f \equiv 0$ 时，BSDE 简化为：

$$Y_t = \xi - \int_t^T Z_s dW_s$$

这正是鞅表示定理：$Y_t = \mathbb{E}[\xi|\mathcal{F}_t]$，$Z_t$ 是表示过程。

此时 BSDE 解就是条件期望过程，Z_t 衡量 ξ 对布朗运动的敏感性。

9.4 Pardoux-Peng 定理：一般存在唯一性

对于非线性 BSDE，Pardoux 和 Peng 在 1990 年建立了基本的存在唯一性定理。

9.4.1 定理陈述

定理 9.1 (Pardoux-Peng, 1990)**.** 设：

1. $\xi \in L^2(\Omega, \mathcal{F}_T, \mathbb{P})$（终端条件平方可积）
2. $f : [0,T] \times \Omega \times \mathbb{R} \times \mathbb{R} \to \mathbb{R}$ 满足：
   (a) 对每个 (y,z)，$f(\cdot,\cdot,y,z)$ 适应
   (b) *Lipschitz* 条件：存在 $L > 0$ 使得

$$|f(t,\omega,y,z) - f(t,\omega,y',z')| \le L(|y-y'| + |z-z'|)$$

   (c) 可积性：$\mathbb{E}\left[\int_0^T |f(t,0,0)|^2 dt\right] < \infty$

则 *BSDE(9.1)* 存在唯一适应解 (Y_t, Z_t) 满足

$$\mathbb{E}\left[\sup_{0\le t\le T} |Y_t|^2 + \int_0^T |Z_t|^2 dt\right] < \infty$$

9.4.2 证明思想：Picard 迭代

类似于 SDE 的 Picard 迭代，但需要处理倒向结构。

定义迭代：从 $(Y_t^0, Z_t^0) \equiv (0,0)$ 开始。给定 (Y^n, Z^n)，解线性 BSDE：

$$\begin{cases} dY_t^{n+1} = -f(t, Y_t^n, Z_t^n)dt + Z_t^{n+1}dW_t \\ Y_T^{n+1} = \xi \end{cases}$$

由线性 BSDE 理论，这有唯一解。

证明 $\{(Y^n, Z^n)\}$ 在适当空间中是 Cauchy 序列，极限即为解。

关键技术估计：

$$\begin{aligned} &\mathbb{E}\left[\sup_t |Y_t^{n+1} - Y_t^n|^2 + \int_0^T |Z_t^{n+1} - Z_t^n|^2 dt\right] \\ &\quad \le C\mathbb{E}\left[\int_0^T (|Y_t^n - Y_t^{n-1}|^2 + |Z_t^n - Z_t^{n-1}|^2)dt\right] \end{aligned}$$

当 T 足够小或 L 足够小时，得到压缩映射。

9.4.3 推广与变体

- **反射 BSDE**：附加约束 $Y_t \ge S_t$（障碍条件），解包含递增过程
- **带跳 BSDE**：包含泊松随机测度
- **二次增长 BSDE**：f 关于 z 二次增长，出现在随机控制中
- **无穷时间 BSDE**：$T = \infty$，要求解有界

9.5 非线性 Feynman-Kac 公式

线性 BSDE 与线性抛物 PDE 通过 Feynman-Kac 公式联系。非线性 BSDE 对应的是 ** 非线性 **Feynman-Kac 公式。

9.5.1 从 PDE 到 BSDE

考虑半线性抛物 PDE：

$$\begin{cases} \frac{\partial u}{\partial t} + \mathcal{L}u + f(t, x, u, \nabla u\sigma) = 0, \quad (t,x) \in [0,T) \times \mathbb{R}^d \\ u(T,x) = g(x) \end{cases} \tag{9.5}$$

其中 $\mathcal{L}$ 是生成元：$\mathcal{L}u = \mu \cdot \nabla u + \frac{1}{2}\operatorname{tr}(\sigma\sigma^T D^2 u)$。

设 $X_t^{t,x}$ 是 SDE 的解：

$$dX_s = \mu(s, X_s)ds + \sigma(s, X_s)dW_s, \quad X_t = x$$

定义：

$$Y_s = u(s, X_s^{t,x}), \quad Z_s = \nabla u(s, X_s^{t,x})\sigma(s, X_s^{t,x}) \tag{9.6}$$

由 Itô 公式：

$$\begin{aligned} dY_s &= \left(\frac{\partial u}{\partial s} + \mathcal{L}u\right) ds + \nabla u \cdot \sigma dW_s \\ &= -f(s, X_s, u, \nabla u\sigma)ds + Z_s dW_s \\ &= -f(s, X_s, Y_s, Z_s)ds + Z_s dW_s \end{aligned}$$

且 $Y_T = u(T, X_T^{t,x}) = g(X_T^{t,x})$。

因此 (Y_s, Z_s) 满足 BSDE，生成元 f，终端条件 $\xi = g(X_T^{t,x})$。

9.5.2 从 BSDE 到 PDE

反之，给定 BSDE 解 (Y_t, Z_t)，如果可以证明 Y_t 是 X_t 的确定性函数 $u(t, X_t)$，且 u 足够光滑，则 u 满足 PDE(9.5)。

这需要：

1. Markov 结构：系数 μ, σ, f, g 只通过 X_t 依赖 ω
2. 解的正则性：$u \in C^{1,2}$

9.5.3 非线性期望

BSDE 的一个重要应用是定义非线性期望。固定生成元 f，定义：

$$\mathcal{E}_{t,T}^f[\xi] := Y_t$$

其中 Y_t 是 BSDE(ξ, f) 的解。

性质：

- 如果 f 关于 (y, z) 线性，则 $\mathcal{E}^f$ 是线性期望（对应条件期望）

- 如果 f 关于 z 凸，则 $\mathcal{E}^f$ 是次线性期望
- 一般 f 给出非线性期望

特别地，g-期望：取 $f(t,y,z)=g(z)$，其中 g 凸，则 $\mathcal{E}^g$ 是次线性期望，用于模型不确定性。

9.6 比较定理与单调性

9.6.1 比较定理

BSDE 的一个重要性质是单调性：如果终端条件和生成元都增大，解也增大。

定理 9.2 (比较定理)**.** *设 (Y^1,Z^1) 和 (Y^2,Z^2) 分别是 BSDE(ξ^1,f^1) 和 (ξ^2,f^2) 的解。假设：*

1. $\xi^1 \geq \xi^2$ *a.s.*
2. $f^1(t,y,z) \geq f^2(t,y,z)$ *a.s. 对所有* (t,y,z)
3. f^1 *或* f^2 *满足某种单调性条件（如关于* y *Lipschitz)*

则 $Y_t^1 \geq Y_t^2$ *a.s. 对所有* t*。*

注 9.3 (金融解释)**.** *在期权定价中，如果收益更大（$\xi^1 \geq \xi^2$），价格也更大。如果资金成本更高（f 更大），价格可能更小（注意 f 前有负号）。*

9.6.2 应用：定价中的套利边界

考虑两个生成元 $f^{\min} \leq f \leq f^{\max}$，对应不同模型假设。则价格满足：

$$Y_t^{\min} \leq Y_t \leq Y_t^{\max}$$

给出模型不确定下的价格区间。

9.7 数值方法

BSDE 的数值方法比 SDE 更复杂，因为需要同时逼近 Y_t 和 Z_t。

9.7.1 动态规划方程

对时间离散化 $0 = t_0 < t_1 < \cdots < t_N = T$。倒向递推：

在 t_N：$Y_N = \xi$

从 t_{n+1} 到 t_n：已知 Y_{n+1}，求解

$$Y_n = \mathbb{E}\left[Y_{n+1} + f(t_n, Y_n, Z_n)\Delta t \,|\, \mathcal{F}_n\right]$$

且 Z_n 满足某种表示。

具体方法：

1. 用条件期望表示 Z_n：$Z_n \approx \frac{1}{\Delta t}\mathbb{E}[Y_{n+1}\Delta W_n|\mathcal{F}_n]$
2. 代入解 Y_n

9.7.2 最小二乘蒙特卡洛（LSMC）

用基函数展开条件期望。设 $\{\phi_k(x)\}$ 是基函数集，近似：

$$\mathbb{E}[Y_{n+1}|X_n = x] \approx \sum_{k=1}^{K} \alpha_k^n \phi_k(x)$$

系数 α_k^n 通过回归估计（在模拟路径上最小二乘）。

类似地，估计 Z_n：

$$\mathbb{E}[Y_{n+1}\Delta W_n|X_n = x] \approx \sum_{k=1}^{K} \beta_k^n \phi_k(x)$$

9.7.3 深度学习求解

用神经网络近似 Y_t 和 Z_t 作为 t 和 X_t 的函数。通过模拟路径和 BSDE 结构定义损失函数：

损失 $= \mathbb{E}\left[|Y_T - \xi|^2 + \int_0^T |Z_t - \nabla_Y \text{网络}|^2 dt\right]$

训练网络使损失最小。

9.8 金融应用：非线性定价与风险度量

9.8.1 非线性 Black-Scholes 模型

传统 Black-Scholes 假设市场完备、无摩擦。考虑更现实因素：

- 交易成本：$f(t,y,z) = -ry + \alpha|z|$
- 借贷利差：$f(t,y,z) = -(r + \delta\,\mathrm{sgn}(y))y$
- 波动率不确定：$f(t,y,z) = -ry + \sup_{\sigma\in[\underline{\sigma},\overline{\sigma}]} \frac{1}{2}(\sigma^2 - \hat{\sigma}^2)z$

这些导致 BSDE 生成元非线性，价格 Y_t 由非线性 BSDE 给出。

9.8.2 风险度量与资本分配

设 X_T 是未来损失，风险度量 $\rho(X_T)$ 是所需资本。Coherent 风险度量（如 Expected Shortfall）可表示为：

$$\rho(X_T) = \sup_{\mathbb{Q}\in\mathcal{Q}} \mathbb{E}^{\mathbb{Q}}[X_T]$$

其中 $\mathcal{Q}$ 是一组概率测度。

这对应 BSDE 生成元：

$$f(t,y,z) = \sup_{\theta\in\Theta}\{-\theta z\}$$

其中 Θ 对应测度变化范围。

9.8.3 信用风险：CVA 计算

信用价值调整（CVA）考虑对手方违约风险。设 τ 为违约时间，L 为违约损失率。未违约价值 V_t 满足 BSDE：

$$dY_t = -(-rY_t - LZ_t\lambda_t)dt + Z_t dW_t$$

其中 λ_t 为违约强度，Z_t 是 Y_t 对风险的敏感性。

9.9 随机控制与 BSDE

9.9.1 Hamilton-Jacobi-Bellman 方程与 BSDE

考虑随机控制问题：控制过程 α_t，状态方程：

$$dX_t = b(t, X_t, \alpha_t)dt + \sigma(t, X_t, \alpha_t)dW_t$$

目标最小化：

$$J(\alpha) = \mathbb{E}\left[\int_0^T f(t, X_t, \alpha_t)dt + g(X_T)\right]$$

值函数 $V(t,x) = \inf_\alpha J(t,x,\alpha)$ 满足 HJB 方程：

$$\frac{\partial V}{\partial t} + \inf_a \{\mathcal{L}^a V + f(t,x,a)\} = 0$$

其中 $\mathcal{L}^a$ 是控制 a 下的生成元。

通过随机最大值原理，最优控制与伴随 BSDE 联系。伴随过程 (p_t, q_t) 满足线性 BSDE：

$$dp_t = -H_x(t, X_t, \alpha_t, p_t, q_t)dt + q_t dW_t, \quad p_T = g_x(X_T)$$

其中 H 是 Hamiltonian。

9.10 与粗糙路径的联系

近年来，BSDE 理论与粗糙路径理论开始交叉。考虑 BSDE：

$$Y_t = \xi + \int_t^T f(s, Y_s, Z_s)ds - \int_t^T Z_s d\mathbf{X}_s$$

其中 $\mathbf{X}$ 是粗糙路径（如分形布朗运动 $H \neq 1/2$）。

此时积分需要粗糙路径积分理论，解的存在性需要不同技术。

本章总结

本章系统介绍了倒向随机微分方程的基本理论，要点如下：

1. **基本概念**：终端条件、解对 (Y_t, Z_t)、倒向结构
2. **与 SDE 对比**：正向给定初始条件，倒向给定终端条件；解对 vs 单一过程
3. **存在唯一性**：Pardoux-Peng 定理，Lipschitz 条件下解存在唯一
4. **线性 BSDE**：显式解，通过积分因子法
5. **非线性 Feynman-Kac**：连接半线性 PDE 与 BSDE
6. **比较定理**：单调性，终端条件或生成元增大导致解增大
7. **数值方法**：动态规划、最小二乘蒙特卡洛、深度学习
8. **金融应用**：非线性定价、风险度量、信用风险

BSDE 理论体现了随机分析中 ** 倒向思维 ** 的力量。从三种基本操作的视角：

- 终端条件 ξ 体现 ** 对样本 ω 的依赖 **
- Y_t 的演化包含 ** 对时间 t 的积分 **（漂移项）
- Z_t 通过 **Itô 积分 ** 对冲未来不确定性

BSDE 的美妙之处在于它通过 Z_t 过程解决了适应性矛盾：Y_t 虽然依赖未来信息 ξ，但通过 Z_t 的适当选择，可以保持适应性。这本质上是鞅表示定理的深刻应用。

BSDE 不仅是理论优美的数学对象，更是连接随机分析、偏微分方程、控制理论、金融数学的桥梁。它为我们处理终端条件问题、非线性期望、模型不确定性等提供了系统工具。

在下一章，我们将进入粗糙路径理论，这是处理非半鞅驱动信号的现代理论，与 BSDE 有深刻联系。

历史注记

BSDE 理论由 Pardoux 和 Peng 在 1990 年开创。线性 BSDE 与随机控制中的伴随方程相关，可追溯到 Bismut(1973) 的工作。非线性 Feynman-Kac 公式由 Peng(1991) 建立。比较定理由 Peng(1992) 证明。在金融中的应用由 El Karoui 等 (1997) 系统发展。数值方法方面，Douglas 等 (1996) 提出有限差分方法，Gobet 等 (2005) 研究最小二乘蒙特卡洛。近年来，深度

学习求解高维 BSDE 由 E 等 (2017) 推动。这些进展使 BSDE 成为现代随机分析的重要分支。

Chapter 10

粗糙路径理论概览

10.1 引言：经典 Itô 理论的边界

在经典随机分析中，我们处理的是布朗运动驱动的随机微分方程。布朗运动具有两个关键性质：

1. 样本路径是 Hölder 连续指数 $\alpha < 1/2$（但不可微）
2. 二次变差非零：$(dW_t)^2 = dt$

正是二次变差非零这一事实，导致了 Itô 公式中的二阶修正项。

然而，许多自然现象和数学模型涉及更粗糙的信号：

- 分形布朗运动（fBm）：Hölder 连续指数 $H \in (0,1)$，当 $H \neq 1/2$ 时不是半鞅
- 物理中的噪声：如湍流速度场
- 金融中的高频数据：表现出长记忆性

对于这些信号，经典的 Itô 积分理论失效，因为：

1. 当 Hölder 指数 $\alpha \leq 1/2$ 时，路径变差无穷，黎曼-斯蒂尔切斯积分无定义
2. 当信号不是半鞅时，Itô 的 L^2 极限构造不适用
3. 当信号没有独立增量时，鞅理论工具不可用

粗糙路径理论（Rough Path Theory）由 Terry Lyons 在 1998 年开创，其核心思想是：要定义微分方程 $dY = f(Y)dX$，我们不仅需要路径 X_t 本

身，还需要它的某些”迭代积分”信息。这种提升（lift）的观点使得我们可以处理比布朗运动更粗糙的信号。

10.2 Young 积分：走向粗糙的第一步

在进入粗糙路径理论之前，我们先回顾一个中间理论：Young 积分。

10.2.1 Young 定理

定理 10.1 (Young, 1936)**.** 设 $f \in C^\alpha([0,T])$，$g \in C^\beta([0,T])$，其中 $\alpha, \beta > 0$ 且 $\alpha + \beta > 1$。则黎曼和

$$\sum_{i=0}^{n-1} f(t_i)[g(t_{i+1}) - g(t_i)]$$

收敛，极限记为 $\int_0^T f dg$，且满足：

$$\left| \int_s^t f dg - f(s)[g(t) - g(s)] \right| \leq C|t-s|^{\alpha+\beta}$$

这里的条件是 $\alpha + \beta > 1$。当 $\alpha = \beta = 1/2$ 时，$\alpha + \beta = 1$，这是临界情况，Young 积分可能不存在。布朗运动的典型 Hölder 指数 $\alpha < 1/2$，所以对于布朗运动，即使 f 是 1/2-Hölder 连续的，$\alpha + \beta < 1$，Young 积分也不存在。

10.2.2 临界指数 1/2 的意义

指数 1/2 在随机分析中反复出现：

- 布朗运动是 Hölder $1/2-$ 连续的
- Young 积分的临界条件是 $\alpha + \beta > 1$，当 $\alpha = \beta$ 时要求 $\alpha > 1/2$
- Itô 积分处理 $\alpha = 1/2$ 的情形，但需要概率结构和适应性

粗糙路径理论的目标之一就是突破 1/2 的障碍，处理 $\alpha \in (1/3, 1/2]$ 的情形。

10.3 粗糙路径的基本定义

10.3.1 提升（Lift）的概念

考虑驱动信号 $X : [0,T] \to \mathbb{R}^d$。在经典微积分中，要定义 $\int f(X)dX$，我们需要 X 的可微性或有限变差性。粗糙路径的关键洞见是：我们需要的其实不是 X 本身的可微性，而是某种”高阶结构”。

定义 X 的增量：$X_{s,t} := X_t - X_s$。在经典情形，我们有近似：

$$\int_s^t f(X_u)dX_u \approx f(X_s)X_{s,t}$$

但这对于粗糙路径不够精确。

Lyons 的想法是：显式地提供”二阶信息”。定义 $\mathbb{X}_{s,t} \approx \int_s^t (X_{s,u} \otimes dX_u)$，其中 $\otimes$ 是张量积。准确地说：

10.3.2 粗糙路径的定义

定义 10.2 (p-粗糙路径)**.** 设 $p \geq 1$。一个 p-粗糙路径是一个对 $\mathbf{X} = (X, \mathbb{X})$，其中：

1. $X : [0,T] \to \mathbb{R}^d$ 是连续路径，$X_0 = 0$
2. $\mathbb{X} : \Delta_T := \{(s,t) : 0 \leq s \leq t \leq T\} \to \mathbb{R}^{d\times d}$ 是连续函数
3. 它们满足 *Chen* 关系式（*Chen's identity*）：对 $0 \leq s \leq u \leq t$，

$$\mathbb{X}_{s,t} = \mathbb{X}_{s,u} + \mathbb{X}_{u,t} + X_{s,u} \otimes X_{u,t} \tag{10.1}$$

4. 正则性条件：存在常数 C 使得

$$|X_{s,t}| \leq C|t-s|^{1/p}$$
$$|\mathbb{X}_{s,t}| \leq C|t-s|^{2/p}$$

注 10.3 (张量积的含义)**.** 在 $\mathbb{R}^d$ 中，$a \otimes b$ 是 $d \times d$ 矩阵，$(a \otimes b)^{ij} = a^i b^j$。$\mathbb{X}_{s,t}$ 应理解为 $\int_s^t (X_{s,u} \otimes dX_u)$ 的”候选”，但它不是通过积分定义的，而是作为粗糙路径的公理部分给出。

10.3.3 Chen 关系式的几何意义

Chen 关系式 (10.1) 是粗糙路径理论的核心代数条件。它可以改写为:

$$\mathbb{X}_{s,u} + \mathbb{X}_{u,t} - \mathbb{X}_{s,t} = -X_{s,u} \otimes X_{u,t}$$

左边衡量 $\mathbb{X}$ 的可加性偏差，右边由一阶增量 X 的张量积给出。这类似于微分形式中的结构方程。

10.3.4 几何粗糙路径

定义 10.4 (几何粗糙路径)**.** *如果存在一列光滑路径 $X^{(n)}$，使得对应的迭代积分 $\mathbb{X}_{s,t}^{(n)} = \int_s^t (X_{s,u}^{(n)} \otimes dX_u^{(n)})$（黎曼积分意义）收敛到 $(X, \mathbb{X})$，则称 $(X, \mathbb{X})$ 为几何粗糙路径。*

几何粗糙路径满足对称性条件:$\mathrm{Sym}(\mathbb{X}_{s,t}) = \frac{1}{2} X_{s,t} \otimes X_{s,t}$,其中 $\mathrm{Sym}(A) = \frac{1}{2}(A + A^T)$。

非几何粗糙路径的反对称部分 $\mathrm{Anti}(\mathbb{X}_{s,t}) = \frac{1}{2}(\mathbb{X}_{s,t} - \mathbb{X}_{s,t}^T)$ 是额外信息，在 Stratonovich 积分的极限中可能出现。

10.4 粗糙积分

有了粗糙路径 $(X, \mathbb{X})$，我们可以定义积分 $\int Y dX$，其中 Y 本身可能依赖于 X。

10.4.1 控制微分方程

考虑方程:

$$dY_t = f(Y_t) dX_t, \quad Y_0 = y_0$$

在粗糙路径框架下，这需要解释为控制微分方程。

设 $f : \mathbb{R}^e \to \mathcal{L}(\mathbb{R}^d, \mathbb{R}^e)$（线性映射空间）。定义:

定义 10.5 (粗糙微分方程的解)**.** *Y 是上述方程的解，如果存在余项 R^Y 使得对 $s \le t$,*

$$Y_{s,t} = f(Y_s) X_{s,t} + f'(Y_s) f(Y_s) \mathbb{X}_{s,t} + R_{s,t}^Y \tag{10.2}$$

其中 $|R^Y_{s,t}| \le C|t-s|^{3/p}$。

这里 $f'(Y_s)f(Y_s)$ 是二阶项：$f'(y)f(y)$ 是 $d\times d$ 矩阵，$(f'(y)f(y))^{ij} = \sum_k \partial_{y^k} f^i(y) f^{kj}(y)$。

10.4.2 积分构造

给定" 被积函数"Y（本身是某个 RDE 的解），定义积分 $\int Y dX$ 为：

$$\left(\int_s^t Y dX\right)^i := \lim_{|\Pi|\to 0} \sum_{[u,v]\in\Pi} \left[Y^i_u X_{u,v} + \sum_{j,k} \partial_{y^j} f^{ik}(Y_u) f^{kj}(Y_u) \mathbb{X}^{jk}_{u,v} \right]$$

其中 Π 是 $[s,t]$ 的分划。

10.4.3 与经典积分的对应

- **Itô 积分**：取 $\mathbb{X}^{\text{Itô}}_{s,t} = \int_s^t (X_{s,u} \otimes dX_u)$（Itô 意义）
- **Stratonovich 积分**：取 $\mathbb{X}^{\text{Strat}}_{s,t} = \int_s^t (X_{s,u} \otimes \circ dX_u)$（Stratonovich 意义），此时 $\text{Sym}(\mathbb{X}_{s,t}) = \frac{1}{2} X_{s,t} \otimes X_{s,t}$

对于布朗运动，可以证明：p-变差几乎必然有限对 $p>2$，所以可以取 $p\in(2,3)$，此时要求 $\alpha = 1/p > 1/3$。布朗运动的 Hölder 指数 $1/2 > 1/3$，所以可以处理。

10.5 普遍极限定理

粗糙路径理论的一个核心结果是普遍极限定理（Universal Limit Theorem），它表明粗糙微分方程的解连续依赖于驱动粗糙路径。

10.5.1 粗糙路径度量

定义 p-变差度量：对两个粗糙路径 $\mathbf{X} = (X, \mathbb{X})$ 和 $\tilde{\mathbf{X}} = (\tilde{X}, \tilde{\mathbb{X}})$，

$$\rho_{p\text{-var}}(\mathbf{X}, \tilde{\mathbf{X}}) = \sup_{\Pi} \left(\sum_{[s,t]\in\Pi} |X_{s,t} - \tilde{X}_{s,t}|^p \right)^{1/p} + \sup_{\Pi} \left(\sum_{[s,t]\in\Pi} |\mathbb{X}_{s,t} - \tilde{\mathbb{X}}_{s,t}|^{p/2} \right)^{2/p}$$

定理 10.6 (普遍极限定理). *设 f 是 C^3 函数。则粗糙微分方程 $dY = f(Y)d\mathbf{X}$ 的解映射 $\mathbf{X} \mapsto Y$ 在 p-变差度量下是局部 Lipschitz 连续的。*

这意味着：如果 $\mathbf{X}^{(n)} \to \mathbf{X}$ 在粗糙路径意义下，则对应的解 $Y^{(n)} \to Y$。

10.5.2 应用：Wong-Zakai 近似

Wong-Zakai 定理说：如果 $X^{(n)}$ 是一列光滑逼近布朗运动的路径，则 SDE 的经典解（Itô 意义）与用 $X^{(n)}$ 驱动的 ODE 解的极限不同，相差一个 Stratonovich 修正。

在粗糙路径框架下，取 $\mathbf{X}^{(n)} = (X^{(n)}, \mathbb{X}^{(n)})$，其中 $\mathbb{X}^{(n)}_{s,t} = \int_s^t (X^{(n)}_{s,u} \otimes dX^{(n)}_u)$（黎曼意义）。则 $\mathbf{X}^{(n)}$ 收敛到 $\mathbf{X}^{\text{Strat}} = (W, \mathbb{X}^{\text{Strat}})$，其中 $\mathbb{X}^{\text{Strat}}$ 的对称部分是 $\frac{1}{2}W_{s,t} \otimes W_{s,t}$。

因此，RDE 的解收敛到 Stratonovich SDE 的解，这与经典 Wong-Zakai 定理一致。

10.6 粗糙路径的构造

10.6.1 从随机过程构造

给定一个随机过程 X_t，如何自然地获得粗糙路径 $(X, \mathbb{X})$?

对于布朗运动 W_t，定义：

$$\mathbb{X}^{\text{Itô}}_{s,t} = \int_s^t (W_{s,u} \otimes dW_u) \quad (\text{Itô 积分})$$
$$\mathbb{X}^{\text{Strat}}_{s,t} = \int_s^t (W_{s,u} \otimes \circ dW_u) \quad (\text{Stratonovich 积分})$$

可以证明：以概率 1，$(W, \mathbb{X}^{\text{Itô}})$ 和 $(W, \mathbb{X}^{\text{Strat}})$ 都是 p-粗糙路径对 $p > 2$。

10.6.2 分形布朗运动

分形布朗运动 B^H_t 的 Hölder 指数为 $H \in (0, 1)$。当 $H > 1/4$ 时，可以构造二阶粗糙路径。特别地：

- 当 $H > 1/2$ 时，路径有限变差，可用 Young 积分

- 当 $H \in (1/3, 1/2]$ 时，需要粗糙路径理论
- 当 $H \leq 1/3$ 时，需要三阶或更高阶粗糙路径

  对于 $H > 1/4$，可以定义：

$$\mathbb{X}_{s,t} = \int_s^t (B^H_{s,u} \otimes dB^H_u)$$

这里的积分需要特殊定义（如用 Malliavin 计算或正则化技巧）。

10.7 高阶粗糙路径

当驱动信号非常粗糙（Hölder 指数 $\alpha \leq 1/3$）时，需要更高阶的信息。

10.7.1 三级粗糙路径

三级粗糙路径是三元组 $\mathbf{X} = (X, \mathbb{X}, \mathbb{X}^{(3)})$，其中 $\mathbb{X}^{(3)}_{s,t} \approx \int_s^t \int_s^{u_2} (X_{s,u_1} \otimes dX_{u_1}) \otimes dX_{u_2}$，满足推广的 Chen 关系式。

一般地，N 级粗糙路径包含直到 N 阶的迭代积分信息。

10.7.2 签名（Signature）

定义 10.7 (路径的签名). 设 $X : [0, T] \to \mathbb{R}^d$ 是光滑路径。定义其签名为形式幂级数：

$$S(X)_{s,t} = 1 + \int_{s<t_1<t} dX_{t_1} + \int_{s<t_1<t_2<t} dX_{t_1} \otimes dX_{t_2} + \int_{s<t_1<t_2<t_3<t} dX_{t_1} \otimes dX_{t_2} \otimes dX_{t_3} + \cdots$$

其中每一项在张量代数 $T((\mathbb{R}^d)) = \bigoplus_{k=0}^{\infty} (\mathbb{R}^d)^{\otimes k}$ 中。

签名的美妙性质：

1. Chen 定理：$S(X)_{s,t} = S(X)_{s,u} \otimes S(X)_{u,t}$
2. 唯一性：在一定条件下，签名唯一确定路径（模树状等价）
3. 粗糙路径可以看作签名的截断

10.8 与正则结构理论的关系

Hairer 的正则结构（Regularity Structures）理论可以看作粗糙路径理论的推广，用于处理奇异随机偏微分方程。

10.8.1 正则结构的基本元素

正则结构包含：

- 正则性指数集 $\mathcal{A} \subset \mathbb{R}$
- 模型空间 $\mathcal{T} = \bigoplus_{\alpha \in \mathcal{A}} \mathcal{T}_\alpha$
- 结构群 G 作用在 $\mathcal{T}$ 上

一个模型是赋值 $\Pi : \mathcal{T} \to \mathcal{D}'$（分布）和 $\Gamma : \mathbb{R}^d \times \mathbb{R}^d \to G$，满足相容条件。

10.8.2 与粗糙路径的对应

粗糙路径可以嵌入正则结构：

- $\mathcal{A} = \{0, 1, 2\}$ 对应 $(X, \mathbb{X})$ 的阶数
- $\mathcal{T}_0$ 由常数 1 生成
- $\mathcal{T}_1$ 由抽象符号 $X_1, \ldots, X_d$ 生成，对应坐标
- $\mathcal{T}_2$ 由符号 $X_i X_j$ 生成，对应二阶积分
- 结构群 G 实现 Chen 关系式

正则结构理论的威力在于可以处理负正则性对象（如白噪声），这是粗糙路径理论难以直接处理的。

10.9 数值方法

10.9.1 粗糙路径的模拟

模拟粗糙路径需要生成 $(X, \mathbb{X})$。对于布朗运动：

1. 模拟布朗运动路径 W_t

2. 计算 $\mathbb{X}^{\text{Itô}}_{s,t} = \int_s^t (W_{s,u} \otimes dW_u)$ 这可以通过离散近似：$\mathbb{X}_{t_i,t_{i+1}} \approx \frac{1}{2}(W_{t_i,t_{i+1}})^{\otimes 2}$（对于小步长，误差可接受）

10.9.2 粗糙微分方程的数值解

类似于 SDE 的数值方法，但有额外考虑：

1. 需要同时离散 X 和 $\mathbb{X}$
2. 方法需要保持 Chen 关系式
3. 常用的有 Davie 方法、Taylor 展开方法

10.10 金融应用

10.10.1 粗糙波动率模型

近年来的粗糙波动率模型假设波动率过程满足：

$$dS_t = S_t \sqrt{v_t} dW_t$$

$$v_t = \xi(t) \exp(\eta B_t^H)$$

其中 B_t^H 是分形布朗运动，$H < 1/2$。

这类模型能更好拟合波动率微笑和实际数据。由于 B_t^H 不是半鞅，需要粗糙路径理论处理。

10.10.2 路径依赖期权定价

对于强路径依赖期权（如亚式期权、障碍期权），价格可以表示为粗糙微分方程的解。粗糙路径框架提供了统一的处理方式。

本章总结

粗糙路径理论是现代随机分析的重要发展，要点如下：

1. **核心思想**：为了定义 $\int f(Y)dX$，需要提供高阶迭代积分信息

2. **基本对象**：p-粗糙路径 $(X, \mathbb{X})$，满足 Chen 关系式和正则性条件
3. **积分定义**：通过补偿的黎曼和，包含二阶修正项
4. **普遍极限定理**：解连续依赖于驱动粗糙路径，统一了各种逼近情形
5. **与经典理论的对应**：Itô 和 Stratonovich 积分作为特例
6. **高阶推广**：签名包含所有阶信息，正则结构处理负正则性
7. **应用范围**：分形布朗运动、粗糙波动率、奇异 SPDE 等

从三种基本操作的视角看，粗糙路径理论：

- 将 ** 对时间 t 的积分 ** 的结构显式化（通过 $\mathbb{X}$）
- 保持了 **Itô 积分 ** 的思想但去除了概率假设
- 可以处理 ** 对样本 ω 积分 ** 的更一般随机过程

粗糙路径理论的优美之处在于它将分析、代数、几何结合：

- **分析**：Hölder 正则性、p-变差
- **代数**：张量代数、Chen 关系式、签名
- **几何**：流形上的推广、李群结构

这一理论不仅扩展了随机分析的范围，而且提供了更清晰的结构理解：微分方程的解依赖于驱动路径的”签名”而不仅仅是路径本身。

在下一章，我们将简要介绍正则结构理论，这是处理奇异随机偏微分方程的更强大框架。

历史注记

粗糙路径理论由 Terry Lyons 在 1998 年的一系列论文中创立。早期思想可追溯到 Chen(1957) 的迭代积分和签名。Young 积分由 Young(1936) 提出。普遍极限定理由 Lyons(1998) 证明。与经典随机分析的连接由 Lyons 和 Qian(2002) 详细研究。数值方法由 Davie(2007) 等发展。金融应用由 Gatheral 等 (2014) 推动。正则结构理论由 Hairer(2014) 建立，是粗糙路径的自然推广。这些工作共同构成了现代路径 wise 随机分析的基础。

Chapter 11

奇异 SPDE 与正则结构简介

11.1 引言：从正则性到奇异性

在前十章中，我们研究的随机微分方程（SDE）和偏微分方程（PDE）大多具有一个共同特征：解具有足够的正则性（光滑性），使得方程中的各项在经典意义下良好定义。然而，自然界和数学中的许多重要现象涉及高度奇异的对象，传统的分析工具在此失效。

本章介绍 Martin Hairer 在 2014 年获得 Fields 奖的工作——** 正则结构理论 **，它为解决奇异随机偏微分方程（Singular SPDE）提供了革命性的框架。这些方程的" 奇异" 体现在：

1. 噪声高度奇异：如时空白噪声，其正则性为负
2. 解的正则性比噪声更差：非线性项无经典意义
3. 需要系统化的重整化（Renormalization）来定义方程

从三种基本操作的视角看，奇异 SPDE 的挑战在于：** 对样本 ω 的积分 **（期望）和 ** 对时空的积分 ** 相互交织，且噪声的奇异性使得经典微积分中的乘法运算无定义。正则结构理论通过引入" 提升" 操作，将奇异对象提升到具有更好代数结构的空间中，从而定义原本无定义的运算。

11.2 经典 SPDE 的局限与奇异性的来源

11.2.1 经典 SPDE 理论回顾

在 Da Prato-Zabczyk 理论中，考虑 Hilbert 空间 H 上的线性 SPDE：

$$dX_t = AX_t dt + BdW_t$$

其中 A 是强连续半群生成元，B 有界线性算子，W_t 是柱面布朗运动。

解（温和解）表示为：

$$X_t = S(t)X_0 + \int_0^t S(t-s)BdW_s$$

这里的关键是：噪声通过半群 $S(t)$ 平滑，从而积分有意义。

11.2.2 奇异性示例

KPZ 方程

Kardar-Parisi-Zhang 方程描述界面生长：

$$\partial_t h = \Delta h + |\nabla h|^2 + \xi$$

其中 ξ 是时空白噪声，在三维时空中的正则性为 $-3/2-\epsilon$（负的 Hölder 指数）。

问题：h 预期正则性为 $1/2-\epsilon$（类似布朗运动空间轨迹），那么 ∇h 的正则性为 $-1/2-\epsilon$，$|\nabla h|^2$ 的正则性为 $-1-2\epsilon$，比噪声 ξ 的正则性 $-3/2-\epsilon$ 更差。因此，非线性项 $|\nabla h|^2$ 在经典分布理论中无定义。

Φ_3^4 模型

量子场论中的标量场模型：

$$\partial_t \Phi = \Delta\Phi - \Phi^3 + \xi$$

在三维空间（下标 3 表示空间维数）。时空白噪声 ξ 在三维空间中的正则性为 $-3/2-\epsilon$，Φ 预期正则性为 $-1/2-\epsilon$，那么 Φ^3 的正则性为 $-3/2-3\epsilon$，比噪声更奇异。

11.2.3 重整化的必要性

这些方程的形式解往往涉及发散的表达式。例如，在 Φ_3^4 模型中，尝试用扰动法展开解：

$$\Phi = \Phi_0 + \Phi_1 + \cdots$$

其中 Φ_0 是线性方程 $\partial_t \Phi_0 = \Delta \Phi_0 + \xi$ 的解。计算 Φ_0^3 时，会出现" 无穷大" 项，需要从方程中减去，即重整化：

$$\partial_t \Phi = \Delta \Phi - (\Phi^3 - \infty \cdot \Phi) + \xi$$

这里的"∞" 需要严格定义。

11.3 正则结构理论的核心思想

正则结构理论的基本哲学是：在高度奇异的情况下，我们不能直接处理原方程，而是需要将方程" 提升" 到一个具有丰富代数结构的环境中。

11.3.1 三个基本组件

正则结构由三个部分组成：

1. **正则性指数集** $\mathcal{A}$：通常取为 $\mathbb{R}$ 的离散子集，表示不同" 符号" 的正则性
2. **模型空间** $\mathcal{T}$：分级向量空间 $\mathcal{T} = \bigoplus_{\alpha \in \mathcal{A}} \mathcal{T}_\alpha$，每个 $\mathcal{T}_\alpha$ 包含正则性为 α 的抽象符号
3. **结构群** $\mathcal{G}$：$\mathcal{T}$ 上的线性自同构群，描述不同尺度下的变换

例 11.1 (KPZ 方程的正则结构)**.** *对于 KPZ 方程，一个重要符号是 Ξ 表示噪声，正则性为 $-3/2 - \epsilon$。其他符号包括：*

- 1：*常数，正则性* 0
- $\mathcal{I}(\Xi)$：*噪声的卷积* $\Delta^{-1}\xi$，*正则性* $-1/2 - \epsilon$
- $\Xi\mathcal{I}(\Xi)$：*噪声与其卷积的积，正则性* $-2 - 2\epsilon$

这些符号通过乘法和积分运算生成更大的代数。

11.3.2 模型与重构

定义 11.2 (模型). 一个模型是 (Π, Γ)，其中：

- $\Pi : \mathcal{T} \to \mathcal{D}'(\mathbb{R}^d)$（分布空间）的线性映射
- $\Gamma : \mathbb{R}^d \times \mathbb{R}^d \to \mathcal{G}$，满足相容性条件

Π 将抽象符号映射到具体分布。Γ_{xy} 描述从点 x 到点 y 的视角变换。

定义 11.3 (容许模型). 模型 (Π, Γ) 称为容许的，如果满足局部估计：

$$|\Pi_x \tau(\phi_x^\lambda)| \lesssim \lambda^\alpha, \quad \tau \in \mathcal{T}_\alpha$$

其中 $\phi_x^\lambda(y) = \lambda^{-d}\phi((y-x)/\lambda)$ 是尺度为 λ 的试验函数。

定理 11.4 (重构定理). 给定一个满足适当一致性的模型 (Π, Γ)，存在唯一的线性映射 $\mathcal{R} : \mathcal{T} \to \mathcal{D}'(\mathbb{R}^d)$（重构算子），使得对每个 $\tau \in \mathcal{T}_\alpha$，

$$|\mathcal{R}\tau - \Pi_x \tau| \lesssim \lambda^\alpha$$

在适当意义下。

重构定理是正则结构理论的基石：它允许我们从局部展开（由模型给出）重构全局分布。

11.4 从粗糙路径到正则结构

正则结构理论可以看作粗糙路径理论的无限维推广。理解这一联系对把握理论本质至关重要。

11.4.1 粗糙路径的回顾

对于粗糙微分方程 $dY = f(Y)dX$，其中 X 是 Hölder 连续路径（正则性 $\alpha > 1/3$), Lyons 的粗糙路径理论要求将 X 提升为增强路径 $\mathbf{X} = (X, \mathbb{X})$，其中 $\mathbb{X}$ 是二阶 Lévy 区域，满足 Chen 关系式：

$$\mathbb{X}_{s,t} = \mathbb{X}_{s,u} + \mathbb{X}_{u,t} + X_{s,u} \otimes X_{u,t}$$

在正则结构的语言中：

- 符号：1（正则性 0），X（正则性 α），$\mathbb{X}$（正则性 2α）
- 模型：$\Pi_x(1) = 1$，$\Pi_x(X) = X - X(x)$，$\Pi_x(\mathbb{X}) = \mathbb{X} - \mathbb{X}(x)$
- 结构群：由平移算子生成

11.4.2 正则结构作为”喷气束”提升

Hairer 将正则结构描述为”粗糙路径理论的喷气束版本”。在粗糙路径中，我们提升路径到有限阶张量代数；在正则结构中，我们提升分布到无限阶分级代数，包含所有可能的局部展开项。

关键区别：

	粗糙路径	**正则结构**
对象	路径 X_t	分布（如白噪声）
正则性	$\alpha > 1/3$	α 可为负
提升	有限阶（通常 2 阶）	无限阶
代数	张量代数 $T^{(2)}$	分级 Hopf 代数
应用	常微分方程	偏微分方程

11.5 重整化：减去无穷大

正则结构理论的一个核心贡献是系统化的重整化程序。与量子场论中的重整化类似，我们需要从形式发散的表达式中减去”无穷大”项，得到有限结果。

11.5.1 重整化群

定义重整化群 $\mathcal{R}$ 为模型空间 $\mathcal{T}$ 上的线性变换群。一个重整化方案是选择 $\mathcal{R}$ 的一个单参数子群 $\{M^\varepsilon\}_{\varepsilon>0}$，其中 M^ε 通常形如：

$$M^\varepsilon = \exp\left(\sum_i c_i(\varepsilon) L_i\right)$$

其中 L_i 是适当选择的导数算子，$c_i(\varepsilon)$ 是发散系数（当 $\varepsilon \to 0$ 时 $c_i(\varepsilon) \to \pm\infty$）。

重整化后的模型为 $\Pi^\varepsilon = \Pi \circ M^\varepsilon$。

11.5.2 收敛性定理

定理 11.5 (重整化收敛性). *存在适当选择的重整化子群 $\{M^\varepsilon\}$，使得当 $\varepsilon \to 0$ 时，重整化后的模型 Π^ε 收敛到某个极限模型 $\hat{\Pi}$。相应的重整化方程的解也收敛。*

这意味着，虽然原始方程中的项可能发散，但通过减去适当的发散部分（重整化），我们可以得到良好定义的极限。

例 11.6 (Φ_3^4 的重整化). *对于 Φ_3^4 方程，需要三个重整化常数：*

$$\Phi^3 \quad \to \quad \Phi^3 - 3C_1(\varepsilon)\Phi + C_2(\varepsilon)$$

其中 $C_1(\varepsilon), C_2(\varepsilon) \to \infty$ 当 $\varepsilon \to 0$。这些常数有明确的表达式，涉及噪声的协方差正则化。

11.6 具体方程分析

11.6.1 KPZ 方程的 Cole-Hopf 变换

KPZ 方程有一个幸运的性质：可通过 Cole-Hopf 变换线性化。令 $u = e^h$，则 u 满足随机热方程：

$$\partial_t u = \Delta u + u\xi$$

这是线性方程，但仍奇异，因为乘积 $u\xi$ 无经典意义。

在正则结构框架下，需要定义” 重整化乘积”$u \circ \xi$，它等于 $u\xi - \infty \cdot u$ 的极限。

通过 Cole-Hopf 变换，KPZ 方程的解定义为：

$$h = \log u$$

其中 u 是重整化随机热方程的解。

11.6.2 Φ_3^4 模型的构造

Φ_3^4 模型是正则结构理论的试金石。构造分为几步：

1. 正则化噪声：$\xi_\varepsilon = \rho_\varepsilon * \xi$，其中 ρ_ε 是磨光核
2. 考虑正则化方程：$\partial_t \Phi_\varepsilon = \Delta \Phi_\varepsilon - \Phi_\varepsilon^3 + \xi_\varepsilon$
3. 重整化：$\partial_t \Phi_\varepsilon = \Delta \Phi_\varepsilon - (\Phi_\varepsilon^3 - 3C_1(\varepsilon)\Phi_\varepsilon) + \xi_\varepsilon$
4. 证明当 $\varepsilon \to 0$ 时，Φ_ε 收敛到极限 Φ

   收敛性证明需要正则结构理论的全套工具。

11.7 与其它理论的联系

11.7.1 paraproduct 与仿微分计算

正则结构理论与仿微分计算（paracifferential calculus）有深刻联系。在仿微分计算中，一个分布 f 可分解为：

$$f = \sum_{j \geq -1} \Delta_j f$$

其中 Δ_j 是 Littlewood-Paley 投影。paraproduct 定义为：

$$f \prec g = \sum_{j<k} \Delta_j f \Delta_k g$$

当 f 比 g 更正则时，这个乘积良好定义。

在正则结构中，这对应于模型中的展开：将 fg 表示为 $f \prec g + f \succ g + f \circ g$，其中 $f \circ g$ 是谐振分量，最奇异。

11.7.2 Hairer 的 regularity structures 与 Gubinelli 的粗糙路径

Gubinelli 的受控路径理论（controlled paths）是粗糙路径的另一种表述，也与正则结构相关。一个路径 Y_t 称为受控于 X_t，如果

$$Y_t = Y_s + Y_s' X_{s,t} + R_{s,t}$$

其中余项 $R_{s,t} = O(|t-s|^{2\alpha})$。

在正则结构中，这对应于局部展开：Y 在点 s 处展开为 $Y(s) + Y'(s)X +$ 高阶项。

11.7.3 范畴论视角

正则结构理论可以用范畴论语言重新表述。考虑范畴：

- 对象：正则结构 $(\mathcal{A}, \mathcal{T}, \mathcal{G})$
- 态射：保持结构的映射

模型是正则结构到具体函数空间的实现。重整化群是自态射的单参数子群。

这种范畴观点揭示了理论的内在结构，并可能引导进一步推广。

11.8 数值方法简介

奇异 SPDE 的数值方法是一个活跃的研究领域。基本思想：离散化时也要重整化。

11.8.1 谱 Galerkin 方法

对于 Φ_3^4 方程，考虑谱截断：

$$\partial_t \Phi_N = \Delta \Phi_N - (\Phi_N^3 - 3C_N \Phi_N) + \xi_N$$

其中 ξ_N 是噪声在 N 个模式上的投影，C_N 是相应的重整化常数。

证明当 $N \to \infty$ 时，Φ_N 收敛到连续极限。

11.8.2 有限差分方法

空间离散化：

$$\frac{d}{dt}\Phi_i = \Delta_h \Phi_i - (\Phi_i^3 - 3C_h \Phi_i) + \xi_i$$

其中 Δ_h 是离散 Laplacian，C_h 依赖于网格尺寸 h。

挑战：需要计算离散重整化常数 C_h。

11.9 应用领域

11.9.1 统计物理

- 界面生长：KPZ 普适类
- 动力 Ising 模型：在接近临界点的标度极限
- 定向聚合物：在随机环境中的自由能

11.9.2 量子场论

- 欧氏量子场论：Φ_d^4 模型的构造（$d = 2, 3$）
- 规范理论：Yang-Mills 理论（仍是开放问题）
- 共形场论：与随机 Loewner 演化联系

11.9.3 金融数学

- 随机波动率模型：波动率的波动率
- 利率模型中的奇异性
- 大投资组合的极限行为

11.10 当前研究方向

11.10.1 几何随机偏微分方程

考虑流形上的 SPDE，如随机平均曲率流、随机 Yang-Mills 方程。挑战：保持几何结构的同时重整化。

11.10.2 长程相互作用

噪声相关函数不是局部时，如分数噪声。需要修改正则结构以适应不同的标度律。

11.10.3 准线性与完全非线性方程

目前理论主要处理半线性方程。推广到准线性方程 $\partial_t u = \nabla\cdot(a(u)\nabla u) + \xi$ 和完全非线性方程仍需发展。

11.10.4 与深度学习联系

用神经网络学习正则结构中的模型，或求解高维奇异 SPDE。

本章总结

正则结构理论是 21 世纪随机分析的重大突破，要点如下：

1. **奇异性问题**：经典理论失效，因为解的正则性太差，非线性项无定义
2. **三个组件**：正则性指数集 $\mathcal{A}$、模型空间 $\mathcal{T}$、结构群 $\mathcal{G}$
3. **提升哲学**：将奇异对象提升到具有丰富代数结构的空间
4. **重构定理**：从局部展开重构全局分布
5. **系统重整化**：通过减去发散常数得到有限极限
6. **与粗糙路径联系**：正则结构是粗糙路径的无限维推广
7. **具体方程**：KPZ、Φ^4_3 等方程的成功处理

从三种基本操作的视角看，正则结构理论引入了第四种操作：** 提升操作 **。它将原本无法定义的对象提升到可以操作的空间：

- 提升后的对象可以进行代数运算（乘法、积分）
- 通过重构定理回到原空间
- 重整化处理发散性

这一理论的深刻性在于它统一了随机分析、泛函分析、代数、几何等多个数学分支的思想。它不仅提供了解决具体问题的方法，更重要的是改变了我们看待奇异对象的思维方式：不是避免奇异性，而是提升它、驯服它。

正则结构理论仍在快速发展中，新的应用和推广不断涌现。它代表了现代数学的一个趋势：通过创造新的抽象框架来解决传统工具无法处理的问题。

注 11.7 (学习建议)**.** 学习正则结构理论需要：

1. 扎实的随机分析基础（特别是粗糙路径）
2. 泛函分析知识（分布理论、函数空间）
3. 代数结构理解（*Hopf* 代数、李代数）
4. 物理直觉（重整化思想）

建议从 *Hairer* 的原始论文和课程笔记开始，结合具体例子理解抽象概念。

正则结构理论不仅解决了长期悬而未决的数学问题，更重要的是打开了一扇门：让我们看到，即使是最奇异的对象，也可以通过适当的数学框架变得可处理。这正是数学创造力的体现——不是等待问题变得容易，而是创造工具使困难的问题变得可解。

Chapter 12

Malliavin 分析基础

12.1 引言：随机变量的微分学

在前十一章中，我们建立了随机过程（特别是扩散过程）的完整理论。我们学会了如何对随机过程积分（Itô 积分），如何微分（Itô 公式），如何变换测度（Girsanov 定理）。然而，所有这些操作都是针对 ** 过程 ** 的。一个自然的问题是：能否对 ** 随机变量 ** 本身进行微分？

Malliavin 分析，也称为随机变分学或随机分析中的无穷维分析，正是回答这一问题的理论。其核心思想是：将定义在 Wiener 空间上的随机变量视为" 函数"，并定义其导数。这需要：

1. 将随机变量视为定义在路径空间上的函数
2. 定义路径空间上的微分结构
3. 建立相应的积分（散度算子）

从三种基本操作的视角看，Malliavin 分析是在 ** 样本空间 Ω** 上建立的微分结构。如果说 Itô 积分是对时间的随机积分，那么 Malliavin 导数可以看作对样本 ω 的" 方向导数"。这种微分结构使我们能够：

- 研究随机变量的正则性（光滑性）
- 计算密度函数的存在性与光滑性
- 发展随机计算中的积分-by-parts 公式
- 在金融中计算 Greeks（敏感性）

12.2 Wiener 空间与 Cameron-Martin 空间

12.2.1 Wiener 空间作为路径空间

设 $W = C_0([0,T],\mathbb{R})$ 为从 0 出发的连续函数空间，配备一致收敛拓扑。Wiener 测度 μ 是 W 上的概率测度，使得坐标过程 $W_t(\omega) = \omega(t)$ 是标准布朗运动。

这个三元组 $(W, \mathcal{B}(W), \mu)$ 称为经典 Wiener 空间。随机变量是 W 上的可测函数 $F : W \to \mathbb{R}$。

12.2.2 Cameron-Martin 空间

Wiener 空间 W 是无穷维的，没有自然的 Lebesgue 测度。然而，有一个重要的子空间——Cameron-Martin 空间 H：

$$H = \left\{ h \in W : h(t) = \int_0^t \dot{h}(s)ds,\ \dot{h} \in L^2([0,T]) \right\}$$

配备内积 $\langle h_1, h_2 \rangle_H = \int_0^T \dot{h}_1(s)\dot{h}_2(s)ds$。

H 是 Wiener 空间的" 切线空间" 原型。直观上，H 中的函数比典型布朗运动路径更光滑（有限能量）。

定理 12.1 (Cameron-Martin 定理)**.** *设 $h \in H$，定义平移算子 $T_h : W \to W$ 为 $T_h(\omega) = \omega + h$。则平移后的测度 $\mu_h = \mu \circ T_h^{-1}$ 关于 μ 绝对连续，且*

$$\frac{d\mu_h}{d\mu}(\omega) = \exp\left(\int_0^T \dot{h}(t)d\omega(t) - \frac{1}{2}\int_0^T |\dot{h}(t)|^2 dt \right)$$

其中 $\int_0^T \dot{h}(t)d\omega(t)$ 是 Itô 积分。

这个定理表明：沿 Cameron-Martin 方向 h 的平移产生等价测度。这启发我们将 H 视为 Wiener 空间的" 方向" 空间。

12.3 Malliavin 导数：定义与性质

12.3.1 简单泛函的导数

考虑最简单的一类随机变量：光滑柱函数。设 $F : W \to \mathbb{R}$ 形如

$$F(\omega) = f\left(\int_0^T h_1(t)dW_t, \ldots, \int_0^T h_n(t)dW_t\right)$$

其中 $f \in C^\infty(\mathbb{R}^n)$ 有界且各阶导数有界，$h_i \in L^2([0,T])$。

定义 F 沿方向 $h \in H$ 的 directional derivative：

$$D_h F(\omega) = \lim_{\epsilon \to 0} \frac{F(\omega + \epsilon h) - F(\omega)}{\epsilon}$$

通过链式法则：

$$D_h F(\omega) = \sum_{i=1}^n \frac{\partial f}{\partial x_i}\left(\int_0^T h_1 dW, \ldots\right) \langle h_i, h\rangle_H$$

注意到导数线性依赖于 h，故可定义 DF 为取值于 H 的随机变量：

$$DF = \sum_{i=1}^n \frac{\partial f}{\partial x_i}\left(\int_0^T h_1 dW, \ldots\right) h_i$$

即对任意 $h \in H$，$D_h F = \langle DF, h\rangle_H$。

12.3.2 Sobolev 空间 $\mathbb{D}^{1,2}$

我们希望将导数算子扩展到更广的函数类。定义 Sobolev 范数：

$$\|F\|_{1,2}^2 = \mathbb{E}[|F|^2] + \mathbb{E}[\|DF\|_H^2]$$

其中 $\|DF\|_H^2 = \int_0^T |D_t F|^2 dt$，$D_t F$ 是 DF 在时间 t 的分量。

定义 12.2 (Sobolev 空间 $\mathbb{D}^{1,2}$)**.** $\mathbb{D}^{1,2}$ 是光滑柱函数在 $\|\cdot\|_{1,2}$ 范数下的完备化。

Malliavin 导数 $D : \mathbb{D}^{1,2} \subset L^2(W) \to L^2(W; H)$ 是闭稠定算子。

12.3.3 导数算子的性质

定理 12.3 (Malliavin 导数的性质). 设 $F, G \in \mathbb{D}^{1,2}$，$\varphi \in C^1(\mathbb{R})$ 且 φ' 有界。则：

1. **链式法则**：$\varphi(F) \in \mathbb{D}^{1,2}$ 且 $D\varphi(F) = \varphi'(F)DF$
2. **乘积法则**：$FG \in \mathbb{D}^{1,2}$ 且 $D(FG) = FDG + GDF$
3. **闭性**：若 $F_n \in \mathbb{D}^{1,2}$，$F_n \to F$ 在 L^2 中，且 DF_n 在 $L^2(W;H)$ 中收敛，则 $F \in \mathbb{D}^{1,2}$ 且 $DF = \lim DF_n$

12.3.4 导数的具体计算

例 12.4 (布朗运动本身的导数). 对固定 s，$F = W_s$ 是光滑泛函：$W_s = \int_0^T \mathbf{1}_{[0,s]}(t)dW_t$。因此

$$D_t W_s = \mathbf{1}_{[0,s]}(t) = \begin{cases} 1, & t \le s \\ 0, & t > s \end{cases}$$

特别地，$D_t W_t = 1$。

例 12.5 (Itô 积分的导数). 设 $F = \int_0^T u_s dW_s$，其中 u 适应且 $\mathbb{E}\int_0^T u_s^2 ds < \infty$。若 $u \in \mathbb{D}^{1,2}(L^2)$，则

$$D_t F = u_t + \int_t^T D_t u_s dW_s$$

注意：如果 u 适应，则 $D_t u_s = 0$ 对 $s < t$，因此通常 $D_t F = u_t$。

12.4 散度算子（Skorokhod 积分）

Malliavin 导数是线性算子 $D : \mathbb{D}^{1,2} \to L^2(W;H)$。我们考虑其伴随算子。

12.4.1 定义与性质

定义 12.6 (散度算子). 散度算子 $\delta : Dom(\delta) \subset L^2(W;H) \to L^2(W)$ 是 *Malliavin* 导数 D 的伴随算子，即：

$$\mathbb{E}[\langle DF, u\rangle_H] = \mathbb{E}[F\delta(u)], \quad \forall F \in \mathbb{D}^{1,2}$$

$\delta(u)$ 也称为 u 的 Skorokhod 积分。如果 u 适应，则 $\delta(u)$ 就是 Itô 积分 $\int_0^T u_t dW_t$。但对非适应过程，Skorokhod 积分是 Itô 积分的推广。

12.4.2 与 Itô 积分的比较

	Itô 积分	Skorokhod 积分
被积过程	适应	可非适应
鞅性	鞅	一般非鞅
等距	$\mathbb{E}[(\int u dW)^2] = \mathbb{E}[\int u^2 dt]$	$\mathbb{E}[\delta(u)^2] = \mathbb{E}[\int u^2 dt] + \mathbb{E}[\int\int D_s u_t D_t u_s ds dt]$
域	$L^2(\Omega \times [0,T])$ 适应部分	$\mathrm{Dom}(\delta) \subset L^2(W;H)$

12.4.3 计算例子

例 12.7 (适应过程的散度)**.** 设 u_t 适应且 $\int_0^T \mathbb{E}[u_t^2]dt < \infty$，则 $\delta(u) = \int_0^T u_t dW_t$。

例 12.8 (非适应例子：$u_t = W_T$)**.** $u_t = W_T$ 不依赖 t 且非适应。计算：对任意 $F \in \mathbb{D}^{1,2}$，

$$\mathbb{E}[\langle DF, u\rangle_H] = \mathbb{E}\left[\int_0^T D_t F \cdot W_T dt\right]$$

但 $D_t F$ 通常与 W_T 相关。通过计算可得 $\delta(W_T) = \int_0^T W_T dW_t = W_T^2 - T$。

12.5 Clark-Ocone 公式

Clark-Ocone 公式是鞅表示定理在 Malliavin 分析中的精细化版本。

12.5.1 公式陈述

定理 12.9 (Clark-Ocone 公式)**.** 设 $F \in \mathbb{D}^{1,2}$，则

$$F = \mathbb{E}[F] + \int_0^T \mathbb{E}[D_t F|\mathcal{F}_t] dW_t$$

对比鞅表示定理：存在适应过程 ϕ_t 使得 $F = \mathbb{E}[F] + \int_0^T \phi_t dW_t$。Clark-Ocone 公式明确给出了 $\phi_t = \mathbb{E}[D_t F|\mathcal{F}_t]$。

证明思路. 定义鞅 $M_t = \mathbb{E}[F|\mathcal{F}_t]$。由鞅表示定理，$dM_t = \phi_t dW_t$。另一方面，对 M_t 应用 Malliavin 导数，利用条件期望和导数的交换性。 □

12.5.2 应用：计算对冲策略

在金融中,设 F 是衍生品收益($\mathcal{F}_T$-可测),其价格过程为 $V_t = e^{-r(T-t)}\mathbb{E}^Q[F|\mathcal{F}_t]$。风险中性测度 Q 下，V_t 是鞅。

由 Clark-Ocone 公式（在 Q 下）:

$$F = \mathbb{E}^Q[F] + \int_0^T \mathbb{E}^Q[D_t^Q F|\mathcal{F}_t]dW_t^Q$$

其中 W_t^Q 是 Q 下的布朗运动。

因此复制策略为:

$$\Delta_t = e^{-r(T-t)}\mathbb{E}^Q[D_t^Q F|\mathcal{F}_t]$$

这是计算 Greeks 的 Malliavin 方法的基础。

12.6 Malliavin 协方差矩阵与密度存在性

12.6.1 Malliavin 协方差矩阵

设 $F = (F^1, \ldots, F^n)$，$F^i \in \mathbb{D}^{1,2}$。定义 Malliavin 协方差矩阵 γ_F:

$$\gamma_F^{ij} = \langle DF^i, DF^j \rangle_H = \int_0^T D_t F^i D_t F^j dt$$

定理 12.10 (Malliavin 判据)**.** 假设:

1. $F^i \in \mathbb{D}^\infty := \bigcap_{k\geq 1, p\geq 1} \mathbb{D}^{k,p}$
2. $\gamma_F^{-1} \in L^p$ 对所有 $p \geq 1$（即矩阵几乎处处可逆且逆矩阵各阶矩存在）

则 F 的分布有光滑密度 $p_F(x)$。

直观：如果 F 在 Malliavin 意义下”非退化”（协方差矩阵可逆），则其分布绝对连续且密度光滑。

12.6.2 应用：扩散过程的密度

设 X_t 是 SDE 的解：

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = x_0$$

在适当条件下（Hörmander 条件），可以证明对 $t > 0$，X_t 的 Malliavin 协方差矩阵 γ_{X_t} 可逆，从而 X_t 有光滑密度。

这是研究 SDE 解的正则性的有力工具，比经典 PDE 方法（Fokker-Planck 方程）更灵活。

12.7 积分-by-parts 公式与 Greeks 计算

12.7.1 基本积分-by-parts 公式

设 $F, G \in \mathbb{D}^{1,2}$，$u \in \mathrm{Dom}(\delta)$。则

$$\mathbb{E}[G\langle DF, u\rangle_H] = \mathbb{E}[F\delta(Gu)] - \mathbb{E}[FG\delta(u)] - \mathbb{E}[F\langle DG, u\rangle_H]$$

特别地，取 u 使得 $\delta(u) = 1$，则

$$\mathbb{E}[G\langle DF, u\rangle_H] = \mathbb{E}[F\delta(Gu)] - \mathbb{E}[F\langle DG, u\rangle_H]$$

这类似于有限维的 $\int f'g = fg - \int fg'$。

12.7.2 计算金融中的 Greeks

在 Black-Scholes 模型中，期权价格 $C = e^{-rT}\mathbb{E}^Q[\max(S_T - K, 0)]$，其中 $dS_t = rS_t dt + \sigma S_t dW_t^Q$。

希腊字母是价格对参数的导数：

- Delta: $\Delta = \frac{\partial C}{\partial S_0}$
- Gamma: $\Gamma = \frac{\partial^2 C}{\partial S_0^2}$
- Vega: $\mathcal{V} = \frac{\partial C}{\partial \sigma}$

传统方法：求导期望内部，需要密度知识。Malliavin 方法：交换导数和期望。

例 12.11 (Delta 的计算)**.** 由 *Clark-Ocone* 公式:

$$\max(S_T-K,0)=\mathbb{E}^Q[\max(S_T-K,0)]+\int_0^T\mathbb{E}^Q[D_t\max(S_T-K,0)|\mathcal{F}_t]dW_t^Q$$

计算 D_tS_T:由链式法则,$D_tS_T=\sigma S_T$(因为 $S_T=S_0\exp((r-\frac{1}{2}\sigma^2)T+\sigma W_T^Q)$)。因此

$$D_t\max(S_T-K,0)=\mathbf{1}_{\{S_T>K\}}\sigma S_T$$

故

$$\Delta=e^{-rT}\mathbb{E}^Q\left[\frac{S_T}{S_0}\mathbf{1}_{\{S_T>K\}}\right]$$

这正是熟悉的公式，但通过 *Malliavin* 导数系统得到。

例 12.12 (无需密度计算 Gamma)**.** *Gamma* 通常需要密度:$\Gamma=e^{-rT}\phi(d_1)/(S_0\sigma\sqrt{T})$,其中 ϕ 是正态密度。

Malliavin 方法：用积分-*by-parts* 公式。设 $F=\max(S_T-K,0)$，$G=S_T/S_0$。则

$$\Delta=e^{-rT}\mathbb{E}^Q[G\mathbf{1}_{\{S_T>K\}}]=e^{-rT}\mathbb{E}^Q[FH]$$

其中 H 通过积分-*by-parts* 找到。计算得 Γ 的表达式不显含密度。

这在高维或复杂模型中优势明显：不需要知道密度的显式形式。

12.8 维纳混沌分解

12.8.1 多重 Itô 积分

定义多重 Itô 积分：对对称函数 $f_n\in L^2([0,T]^n)$,

$$I_n(f_n)=n!\int_0^T\int_0^{t_n}\cdots\int_0^{t_2}f_n(t_1,\ldots,t_n)dW_{t_1}\cdots dW_{t_n}$$

性质:

1. $\mathbb{E}[I_n(f_n)]=0$
2. $\mathbb{E}[I_n(f_n)I_m(g_m)]=0$ 当 $n\neq m$
3. $\mathbb{E}[I_n(f_n)^2]=n!\|f_n\|^2_{L^2([0,T]^n)}$

12.8.2 混沌分解定理

定理 12.13 (维纳混沌分解). 任何 $F \in L^2(W)$ 可唯一分解为:

$$F = \sum_{n=0}^{\infty} I_n(f_n)$$

其中 $f_n \in L^2([0,T]^n)$ 对称，且

$$\mathbb{E}[F^2] = \sum_{n=0}^{\infty} n! \|f_n\|_{L^2}^2$$

这里 $I_0(f_0) = \mathbb{E}[F]$。第 n 项 $I_n(f_n)$ 属于第 n 维纳混沌。

12.8.3 Malliavin 导数在混沌中的表现

设 $F = \sum_{n=0}^{\infty} I_n(f_n)$，则

$$D_t F = \sum_{n=1}^{\infty} n I_{n-1}(f_n(\cdot, t))$$

其中 $f_n(\cdot, t)$ 固定第 n 个变量为 t，得到 $(n-1)$ 变元函数。

这表明：Malliavin 导数使混沌阶数降低一阶。

12.9 拟必然分析与支撑定理

12.9.1 支撑定理

支撑定理描述扩散过程的小扰动行为。设 X_t^ϵ 是 SDE 的解:

$$dX_t^\epsilon = b(X_t^\epsilon)dt + \epsilon\sigma(X_t^\epsilon)dW_t, \quad X_0^\epsilon = x_0$$

当 $\epsilon \to 0$ 时，X_t^ϵ 收敛到确定性 ODE 的解 x_t:

$$\frac{dx_t}{dt} = b(x_t), \quad x_0 = x_0$$

更精细地，过程的支撑是使得过程以正概率停留在其任意邻域中的路径集合。支撑定理说：X_t 的支撑是确定性方程 $x_t = x_0 + \int_0^t b(x_s)ds + \int_0^t \sigma(x_s)h(s)ds$，其中 $h \in H$ 遍历所有可能。

12.9.2 拟必然分析

由于布朗运动路径几乎必然连续但不可微，某些分析操作需要小心。拟必然分析（quasi-sure analysis）通过考虑容度（capacity）而非测度来研究精细路径性质。

定义容度：$C(A) = \sup\{\mu(A) : \mu \ll \mu, \frac{d\mu}{d\mu} \in L^p\}$。一个性质拟必然成立如果它在 C-几乎处处成立。

在拟必然分析框架下，可以定义路径 wise 的 SDE 解，研究细部性质。

12.10 无穷维分析视角

12.10.1 Wiener 空间作为无穷维流形

从微分几何观点，Wiener 空间可视为无穷维流形，Cameron-Martin 空间是其切空间。但与传统有限维流形不同：

- 没有处处非零的体积形式
- Cameron-Martin 空间不是整个切空间（是稠密子空间）
- 平移不变性只在 Cameron-Martin 方向成立

12.10.2 Ornstein-Uhlenbeck 算子

定义 Ornstein-Uhlenbeck 算子 $L = -\delta D$。在混沌分解下，

$$LI_n(f_n) = -nI_n(f_n)$$

即 $I_n(f_n)$ 是 L 的特征函数，特征值 $-n$。

L 是无穷维拉普拉斯算子的类似物。其半群 $P_t = e^{tL}$ 是 Ornstein-Uhlenbeck 半群，具有各向同性收缩性质。

12.11 应用扩展

12.11.1 跳跃过程的 Malliavin 分析

对泊松过程或更一般的 Lévy 过程，也有相应的 Malliavin 分析理论。需要处理跳跃的离散性，通常使用随机测度框架。

12.11.2 分数布朗运动

分数布朗运动 B_t^H（Hurst 参数 $H \in (0,1)$）不是半鞅（除非 $H = 1/2$）。其 Malliavin 分析需要基于分数积分/微积分。

当 $H > 1/2$ 时, 路径正则性更好, Malliavin 分析相对简单; 当 $H < 1/2$ 时，需要粗糙路径思想。

12.11.3 统计推断中的应用

在参数估计中，Malliavin 分析用于：

- 计算似然比的导数
- 研究估计量的渐近分布
- 构造渐近展开

本章总结

本章系统介绍了 Malliavin 分析的基础理论，要点如下：

1. **基本框架**：Wiener 空间、Cameron-Martin 空间、光滑泛函
2. **Malliavin 导数**：定义、性质、计算规则
3. **散度算子**：Skorokhod 积分作为 Itô 积分的推广
4. **Clark-Ocone 公式**：鞅表示定理的精细化
5. **密度判据**：Malliavin 协方差矩阵可逆保证光滑密度
6. **积分-by-parts**：随机变量的分部积分公式
7. **维纳混沌**：L^2 空间的正交分解
8. **应用**：金融 Greeks 计算、扩散过程密度研究

Malliavin 分析的美妙之处在于它将 ** 有限维微积分 ** 的思想成功推广到 ** 无穷维 Wiener 空间 **。从三种基本操作的视角：

- 它建立了 ** 对样本 ω 的微分运算 **
- 与 ** 对时间 t 的积分 **（通过 Clark-Ocone 公式）联系
- 与 **Itô 积分 **（通过散度算子）对偶

Malliavin 分析不仅是理论优美的数学构造，更是强大的应用工具。它使我们可以：

- 在不显式知道密度的情况下计算导数
- 研究扩散过程的正则性
- 处理非适应随机积分
- 建立随机变量的精细渐近展开

这门理论由 Paul Malliavin 在 1976 年开创，最初用于证明 Hörmander 定理的概率版本。如今，它已成为随机分析的核心分支，与偏微分方程、微分几何、数学金融等深度交叉。

历史注记

Malliavin 分析由 Paul Malliavin 在 1976 年开创，用于研究扩散过程的平滑性。Stroock(1981) 和 Bismut(1981) 做出了重要贡献。Clark-Ocone 公式由 Clark(1970) 和 Ocone(1984) 建立。金融应用由 Fournié 等 (1999) 系统发展。维纳混沌分解可追溯到 Wiener(1938) 和 Itô(1951)。近年来，Malliavin 分析与粗糙路径、正则结构等现代理论结合，继续活跃发展。

Chapter 13

专题 A：金融数学中的 SDE

13.1 引言：从物理到金融的范式转移

随机微分方程在金融数学中的应用，标志着数学金融学的诞生。与物理学中 SDE 建模微观粒子受随机力作用的运动不同，金融中的 SDE 描述的是资产价格、利率、波动率等经济变量的演化。这种应用不仅仅是数学工具的移植，更带来了一系列深刻的哲学和方法论转变：

- **从确定性到概率性**：资产价格不再被视为确定性变量，而是具有内在随机性
- **从绝对时间到信息时间**：过滤 $\{\mathcal{F}_t\}$ 代表信息逐步揭示的过程
- **从客观概率到风险中性概率**：定价不是基于真实概率，而是基于风险中性概率
- **从解析解到数值解与模拟**：绝大多数金融模型没有闭式解，依赖数值方法

本章将系统展示 SDE 理论如何应用于金融建模的核心问题。我们将看到，前几章讨论的三种基本操作——对时间积分、对样本积分、Itô 积分——在金融语境中获得具体的金融解释。

13.2 资产价格建模的基本范式

13.2.1 几何布朗运动：Black-Scholes-Merton 基石

1973 年，Black、Scholes 和 Merton 的革命性工作基于一个简单而深刻的模型：资产价格 S_t 服从几何布朗运动：

$$dS_t = \mu S_t dt + \sigma S_t dW_t \tag{13.1}$$

其中 μ 为期望收益率，σ 为波动率。

这个模型的优美之处在于：

1. **正性保持**：由 Itô 公式，$S_t = S_0 \exp\left((\mu - \frac{1}{2}\sigma^2)t + \sigma W_t\right) > 0$
2. **对数正态分布**：$\log S_t$ 正态分布，与实证观察相符
3. **比例波动**：波动幅度与价格水平成正比，符合金融直觉

然而，Black-Scholes 模型隐含的常数波动率假设与市场观察到的波动率微笑（volatility smile）矛盾，这催生了更复杂的模型。

13.2.2 风险中性定价原理

金融数学的核心发现是：在无套利市场中，衍生品价格与投资者的风险偏好无关。这导致风险中性定价方法：

设真实测度 $\mathbb{P}$ 下：

$$dS_t = \mu S_t dt + \sigma S_t dW_t^{\mathbb{P}}$$

通过 Girsanov 定理，存在等价测度 $\mathbb{Q}$（风险中性测度），使得：

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}}$$

其中 r 为无风险利率，$dW_t^{\mathbb{Q}} = dW_t^{\mathbb{P}} + \frac{\mu - r}{\sigma} dt$。

欧式期权价格：

$$C(t, S_t) = e^{-r(T-t)} \mathbb{E}^{\mathbb{Q}}[\max(S_T - K, 0) | \mathcal{F}_t]$$

Black-Scholes 公式由此导出：

$$C(t, S) = S\Phi(d_1) - Ke^{-r(T-t)}\Phi(d_2)$$

其中 Φ 为标准正态分布函数，

$$d_1 = \frac{\log(S/K) + (r + \sigma^2/2)(T-t)}{\sigma\sqrt{T-t}}, \quad d_2 = d_1 - \sigma\sqrt{T-t}$$

13.3 波动率建模的演进

13.3.1 局部波动率模型

Dupire(1994) 提出局部波动率模型：

$$dS_t = rS_t dt + \sigma(t, S_t) S_t dW_t \tag{13.2}$$

其中 $\sigma(t, S)$ 是时间和价格的确定性函数。

局部波动率函数可通过期权市场价格反推（Dupire 公式）：

$$\sigma^2(T, K) = \frac{\frac{\partial C}{\partial T} + rK\frac{\partial C}{\partial K}}{\frac{1}{2}K^2\frac{\partial^2 C}{\partial K^2}}$$

局部波动率模型能精确拟合任意期限和行权价的期权价格，但预测能力有限：它假设未来波动率仅依赖于未来价格，不依赖于当前波动率水平。

13.3.2 随机波动率模型

更符合直觉的是随机波动率模型，波动率本身是随机过程。

Heston 模型

Heston(1993) 模型是最著名的随机波动率模型：

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_t^1 \tag{13.3}$$

$$dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t} dW_t^2 \tag{13.4}$$

$$dW_t^1 dW_t^2 = \rho dt \tag{13.5}$$

其中：

- v_t：方差过程（波动率的平方）
- κ：均值回复速度

- θ：长期平均方差
- ξ：波动率的波动率（vol of vol）
- ρ：价格与波动率的相关系数（通常为负，体现杠杆效应）

Heston 模型的特征函数可显式计算，使得期权定价可通过傅里叶反演快速计算。

SABR 模型

Hagan 等 (2002) 提出的 SABR 模型在利率衍生品中广泛应用：

$$dF_t = \alpha_t F_t^{\beta} dW_t^1 \tag{13.6}$$

$$d\alpha_t = \nu \alpha_t dW_t^2 \tag{13.7}$$

$$dW_t^1 dW_t^2 = \rho dt \tag{13.8}$$

其中 F_t 为远期利率，α_t 为随机波动率，β 控制微笑形状。

SABR 模型有近似解析公式，便于市场报价。

13.3.3 局部随机波动率模型（LSV）

结合局部波动率和随机波动率的优点：

$$dS_t = rS_t dt + \sigma(t, S_t)\sqrt{v_t} S_t dW_t$$

其中 $\sigma(t, S)$ 为局部调整因子，v_t 为随机波动率过程。

LSV 模型既能拟合市场微笑，又能保持动力学的合理性，但校准复杂。

13.4 利率期限结构模型

利率建模比股票更复杂，因为涉及整个期限结构（收益率曲线）。

13.4.1 短期利率模型

建模瞬时短期利率 r_t，债券价格 $P(t,T) = \mathbb{E}^{\mathbb{Q}}[e^{-\int_t^T r_s ds} | \mathcal{F}_t]$。

Vasicek 模型

Vasicek(1977) 提出第一个均衡利率模型：

$$dr_t = \kappa(\theta - r_t)dt + \sigma dW_t \tag{13.9}$$

这是 OU 过程，利率可正可负（在正态分布下），有解析解。

CIR 模型

Cox-Ingersoll-Ross(1985) 模型保证利率非负：

$$dr_t = \kappa(\theta - r_t)dt + \sigma\sqrt{r_t}dW_t \tag{13.10}$$

解的条件分布为非中心卡方分布。

Hull-White 模型（扩展 Vasicek）

Hull-White(1990) 模型：

$$dr_t = (\theta(t) - ar_t)dt + \sigma dW_t$$

其中 $\theta(t)$ 为确定性函数，可精确拟合初始收益率曲线。

13.4.2 远期利率模型：HJM 框架

Heath-Jarrow-Morton(1992) 框架直接建模整个远期利率曲线 $f(t,T)$ (T 时刻的瞬时远期利率)：

$$df(t,T) = \alpha(t,T)dt + \sigma(t,T)dW_t$$

无套利条件给出漂移限制：

$$\alpha(t,T) = \sigma(t,T)\int_t^T \sigma(t,s)ds$$

HJM 是理论上优美的框架，但实际应用中需要参数化波动率结构。

13.4.3 市场模型：LIBOR 市场模型

Brace-Gatarek-Musiela(1997) 的 LIBOR 市场模型建模离散远期 LIBOR 利率：

$$dL_n(t) = \text{漂移项} + L_n(t)\gamma_n(t)dW_t$$

其中 $L_n(t)$ 为 $[T_n, T_{n+1}]$ 区间的远期 LIBOR 利率，$\gamma_n(t)$ 为波动率。

LMM 模型直接对交易工具建模，便于定价利率衍生品（如百慕大式互换期权）。

13.5 多维资产与相关性结构

13.5.1 多维几何布朗运动

n 个相关资产：

$$dS_t^i = \mu_i S_t^i dt + S_t^i \sum_{j=1}^{n} \sigma_{ij} dW_t^j, \quad i = 1, \ldots, n$$

其中 $dW_t^i dW_t^j = \rho_{ij} dt$，$\Sigma = (\sigma_{ij})$ 为波动率矩阵。

相关系数矩阵 $R = (\rho_{ij})$ 必须半正定。实践中通过 Cholesky 分解生成相关布朗运动。

13.5.2 随机相关模型

实证显示相关性也随机变化。可建模为：

$$dS_t^i = \mu_i S_t^i dt + \sigma_i S_t^i dW_t^i \tag{13.11}$$

$$d\rho_t = \kappa_\rho(\theta_\rho - \rho_t)dt + \sigma_\rho dW_t^\rho \tag{13.12}$$

$$dW_t^i dW_t^j = \rho_t dt \tag{13.13}$$

13.6 跳跃扩散模型

资产价格不仅连续变化，也有跳跃（如公司公告、重大新闻）。

13.6.1 Merton 跳跃扩散模型

Merton(1976) 在几何布朗运动中加入复合泊松跳跃：

$$\frac{dS_t}{S_{t-}} = \mu dt + \sigma dW_t + dJ_t \tag{13.14}$$

其中 $J_t = \sum_{i=1}^{N_t}(Y_i - 1)$，$N_t$ 为泊松过程，Y_i 为跳跃幅度（通常取对数正态分布）。

特征函数：

$$\phi_T(u) = \exp\left(iu(\mu - \frac{1}{2}\sigma^2)T - \frac{1}{2}u^2\sigma^2 T + \lambda T(\phi_Y(u) - 1)\right)$$

其中 ϕ_Y 为 Y_i 的特征函数。

13.6.2 Kou 双指数模型

Kou(2002) 模型假设跳跃幅度服从双指数分布：

$$f_Y(y) = p\eta_1 e^{-\eta_1 y}\mathbf{1}_{\{y>0\}} + (1-p)\eta_2 e^{\eta_2 y}\mathbf{1}_{\{y<0\}}$$

能产生不对称的微笑。

13.6.3 方差伽玛模型

方差伽玛（Variance Gamma, VG）模型通过时间改变构造：

$$S_t = S_0 \exp\left(\mu t + \theta G_t + \sigma W_{G_t}\right)$$

其中 G_t 为伽玛过程（递增跳跃过程）。VG 过程是纯跳跃过程（无扩散部分），能产生丰富的分布形状。

13.7 信用风险建模

13.7.1 结构化模型（Merton 模型）

Merton(1974) 将公司价值 V_t 建模为几何布朗运动：

$$dV_t = \mu V V_t dt + \sigma_V V_t dW_t$$

债务面值 D，到期 T。违约发生在 $V_T < D$ 时。

股权视为看涨期权：$E_t = \text{Call}(V_t, D, T-t)$ 债权价值：$D_t = V_t - E_t$

13.7.2 强度模型（简化模型）

违约时间 τ 由强度过程 λ_t 驱动：

$$\mathbb{P}(\tau > t) = \mathbb{E}\left[\exp\left(-\int_0^t \lambda_s ds\right)\right]$$

强度可建模为 CIR 过程：

$$d\lambda_t = \kappa(\theta - \lambda_t)dt + \sigma\sqrt{\lambda_t}dW_t$$

信用衍生品（如 CDS）定价涉及两个未知过程：违约强度和违约损失率。

13.7.3 双边违约：CVA 与 DVA

考虑交易对手违约风险时，需要计算信用价值调整（CVA）和债务价值调整（DVA）。设：

- τ_C：交易对手违约时间，强度 λ_t^C
- τ_I：自身违约时间，强度 λ_t^I
- L_C, L_I：违约损失率

无违约价值 V_t 与有违约价值 $\tilde{V}_t$ 的关系由 BSDE 给出：

$$\tilde{V}_t = \mathbb{E}\left[\int_t^T e^{-\int_t^s (r_u + \lambda_u^C + \lambda_u^I)du}(\text{现金流})ds \,\middle|\, \mathcal{F}_t\right]$$

13.8 数值方法在金融中的应用

13.8.1 蒙特卡洛模拟

金融中的高维问题（如百慕大式期权、投资组合优化）依赖蒙特卡洛。

例：亚式期权定价收益 $\left(\frac{1}{T}\int_0^T S_t dt - K\right)^+$，需要模拟路径并计算时间平均。

方差缩减技术：

- 对偶变量法：用 $\{-W_t\}$ 路径
- 控制变量法：用几何平均亚式期权作为控制变量
- 重要性抽样：向价内方向倾斜

13.8.2 有限差分法

一维或二维 PDE 可用有限差分求解。

Black-Scholes PDE：

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS\frac{\partial V}{\partial S} - rV = 0$$

隐式差分格式无条件稳定，显式格式需要满足 CFL 条件。

13.8.3 傅里叶方法

利用特征函数定价。对欧式期权：

$$C(T,K) = e^{-rT}\mathbb{E}[(S_T - K)^+] = S_0 - Ke^{-rT} - \frac{1}{\pi}\int_0^\infty \Re\left(\frac{e^{-iu\log K}\phi_T(u-i)}{iu\phi_T(-i)}\right) du$$

其中 $\phi_T(u) = \mathbb{E}[e^{iu\log S_T}]$。

快速傅里叶变换（FFT）可一次计算多个行权价的价格。

13.9 风险管理：Greeks 计算

Greeks 衡量衍生品价格对参数的敏感性：

- Delta: $\Delta = \frac{\partial V}{\partial S}$，对冲比率
- Gamma: $\Gamma = \frac{\partial^2 V}{\partial S^2}$，凸性
- Vega: $\mathcal{V} = \frac{\partial V}{\partial \sigma}$，波动率风险
- Theta: $\Theta = \frac{\partial V}{\partial t}$，时间衰减
- Rho: $\rho = \frac{\partial V}{\partial r}$，利率风险

13.9.1 路径 wise 导数

通过 Malliavin 计算，得到无偏估计：

$$\Delta = \mathbb{E}\left[e^{-rT}(S_T - K)^+ \frac{W_T}{S_0 \sigma T}\right]$$

13.9.2 似然比法

改变测度技巧：

$$\Delta = e^{-rT}\mathbb{E}[(S_T - K)^+ H]$$

其中 H 为权重函数。

13.10 现代挑战与前沿

13.10.1 高维问题

投资组合优化、抵押债务凭证（CDO）定价涉及数十到数百个资产。维数灾难使传统方法失效。

解决方案：

- 深度学习：用神经网络近似高维函数
- 稀疏网格：降低离散化点数
- 降维技术：主成分分析、随机投影

13.10.2 模型不确定性与稳健性

模型总是近似的，需要考虑模型误差。

方法：

- 模型平均：组合多个模型预测
- 不确定性量化：参数置信区间
- 稳健控制：最坏情况优化

13.10.3 机器学习与 SDE 结合

- **神经 SDE**：用神经网络参数化漂移和扩散
- **生成模型**：扩散模型本质是逆向 SDE
- **强化学习**：随机控制问题的近似解

13.10.4 市场微观结构

高频交易需要考虑：

- 买卖价差
- 订单簿动态
- 交易成本
- 市场影响

建模为带控制的 SDE：

$$dX_t = \mu dt + \sigma dW_t - \alpha_t dt$$

其中 α_t 为交易速度。

本章总结

金融数学中的 SDE 应用展现了随机分析的强大建模能力：

1. **基础模型**：几何布朗运动提供基准，但需扩展以符合市场现象
2. **波动率建模演进**：从常数到局部，从确定到随机，再到混合模型
3. **利率模型分层**：短期利率模型 →HJM 框架 → 市场模型
4. **跳跃与信用**：捕捉不连续变化和违约事件
5. **数值方法核心地位**：绝大多数问题依赖数值解
6. **风险管理**：Greeks 计算和对冲策略
7. **现代挑战**：高维度、模型不确定性、机器学习融合

从三种基本操作的视角回顾：

- **对时间积分**：漂移项建模趋势，dt 项

- **对样本积分**：期望运算给出价格，风险中性测度变换
- **Itô 积分**：扩散项建模不确定性，dW_t 项

金融数学不是简单应用现有 SDE 理论，而是推动理论发展：BSDE 来自对冲问题，局部波动率模型来自市场校准，跳跃模型来自价格不连续性观察。

未来方向包括：更高维模型的高效计算、模型不确定性的量化、机器学习与传统随机分析的融合、市场微观结构的精细建模。

金融数学中的 SDE 不仅是工具，更是理解金融市场本质的透镜。它告诉我们，金融的不确定性不是需要消除的噪声，而是需要理解和管理的核心特征。

Chapter 14

专题 B：物理与工程应用

14.1 引言：从数学抽象到物理现实

在前几章中，我们系统建立了随机微分方程（SDE）的理论框架：从 Itô 积分的构造、Itô 公式、解的存在唯一性，到数值方法和倒向方程。然而，数学的真正力量在于它描述和解释现实世界的能力。本章将聚焦于 SDE 在物理学和工程学中的经典与现代应用，展示抽象数学如何照亮具体现象。

物理学与工程学为 SDE 提供了最丰富的应用场景，同时也为理论发展提出了最具挑战性的问题。这种互动关系是双向的：

- **物理驱动数学**：布朗运动的观察催生了随机分析，量子场论的奇异性激发了正则结构理论
- **数学澄清物理**：随机微积分为朗之万方程提供了严格基础，遍历理论解释了统计平衡

从三种基本操作的视角看，物理系统天然地混合了：

1. **对时间积分**：确定性动力学演化
2. **对样本积分**：统计系综平均
3. **随机积分**：热涨落或量子涨落

本章将围绕四个核心主题展开：统计力学基础、非线性现象、滤波与控制、以及现代交叉领域。

14.2 朗之万方程：布朗运动的微观理论

14.2.1 历史背景：从花粉运动到数学理论

1827 年，植物学家罗伯特 · 布朗观察到悬浮在液体中的花粉颗粒的无规则运动。1905 年，爱因斯坦给出了理论解释：颗粒受到大量液体分子碰撞，其运动可用扩散方程描述。1906 年，朗之万提出了更精细的动力学方程。

14.2.2 朗之万方程的形式与解释

考虑质量为 m 的布朗粒子在液体中运动，位置 X_t，速度 $V_t = \dot{X}_t$。朗之万方程：

$$m\frac{dV_t}{dt} = -\gamma V_t + \sigma\xi_t \tag{14.1}$$

其中：

- $-\gamma V_t$：黏滞阻力，与速度成正比（斯托克斯定律）
- ξ_t：白噪声，模拟分子碰撞
- σ：噪声强度，与温度相关

白噪声 ξ_t 是广义函数，满足：

$$\mathbb{E}[\xi_t] = 0, \quad \mathbb{E}[\xi_t\xi_s] = \delta(t-s)$$

在数学上，需将 (14.1) 理解为 SDE：

$$mdV_t = -\gamma V_t dt + \sigma dW_t \tag{14.2}$$

这是 Ornstein-Uhlenbeck 过程。

14.2.3 能均分定理与涨落耗散定理

由 OU 过程理论，平稳速度分布为高斯：

$$p_{\mathrm{st}}(v) = \sqrt{\frac{m}{2\pi k_B T}}\exp\left(-\frac{mv^2}{2k_B T}\right)$$

这给出能均分定理：

$$\frac{1}{2}m\mathbb{E}[V^2] = \frac{1}{2}k_BT$$

因此噪声强度与温度关系：$\sigma = \sqrt{2\gamma k_BT}$。这就是涨落耗散定理：耗散系数 γ 与涨落强度 σ^2 通过温度 T 联系。

14.2.4 过阻尼极限：从二阶到一阶 SDE

当惯性项 mdV_t 远小于阻尼项 $\gamma V_t dt$（即 $m/\gamma \to 0$），得到过阻尼朗之万方程：

$$\gamma dX_t = F(X_t)dt + \sigma dW_t \tag{14.3}$$

其中 $F(x)$ 为外力。这是最常见的物理 SDE 形式。

例 14.1 (在周期势中的布朗运动). *考虑 $F(x) = -U'(x), U(x) = U_0\cos(2\pi x/L)$。方程：*

$$dX_t = -\frac{U_0 2\pi}{\gamma L}\sin\left(\frac{2\pi X_t}{L}\right)dt + \sqrt{\frac{2k_BT}{\gamma}}dW_t$$

描述粒子在周期势中的热激活跃迁。Kramers 公式给出了跃迁速率的解析表达式。

14.3 统计力学：从微观随机到宏观确定

14.3.1 福克-普朗克方程与平衡统计

对过阻尼 SDE $dX_t = \mu(X_t)dt + \sigma dW_t$，其概率密度 $p(t,x)$ 满足福克-普朗克方程：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu(x)p] + D\frac{\partial^2 p}{\partial x^2}$$

其中 $D = \sigma^2/2$ 为扩散系数。

平衡分布 $p_{\text{eq}}(x)$ 满足 $\partial p/\partial t = 0$。如果存在势函数 $U(x)$ 使得 $\mu(x) = -U'(x)$，则

$$p_{\text{eq}}(x) = \frac{1}{Z}\exp\left(-\frac{U(x)}{k_BT}\right)$$

这正是统计力学中的玻尔兹曼分布，配分函数 $Z = \int \exp(-U(x)/k_BT)dx$。

14.3.2 细致平衡与可逆性

SDE $dX_t = \mu(X_t)dt + \sigma dW_t$ 在平衡态满足细致平衡条件：

$$p_{\text{eq}}(x)p(t, y|x) = p_{\text{eq}}(y)p(t, x|y)$$

其中 $p(t, y|x)$ 是转移概率密度。这意味着过程在平衡态是时间可逆的：正向与反向过程不可区分。

14.3.3 熵产生与不可逆性

对于非平衡系统，定义熵产生率：

$$\dot{S}_{\text{prod}} = \frac{d}{dt} D_{\text{KL}}(p_t \| p_{\text{eq}}) \geq 0$$

其中 D_{KL} 是 Kullback-Leibler 散度。这是热力学第二定律的随机版本。

14.4 随机共振：噪声增强信号

随机共振是噪声帮助弱周期信号通过非线性系统的现象，1981 年在气候模型中首次提出。

14.4.1 双稳系统模型

考虑双势阱中的布朗粒子：

$$dX_t = (X_t - X_t^3)dt + A\cos(\omega t)dt + \sigma dW_t$$

势函数 $U(x) = -\frac{1}{2}x^2 + \frac{1}{4}x^4$ 有两个极小点 $x = \pm 1$。

无噪声 ($\sigma = 0$) 且无驱动 ($A = 0$) 时，粒子停留在其中一个势阱。加弱周期驱动 (A 小) 但无噪声，粒子无法越过势垒。加入适当噪声，粒子能同步于驱动在两阱间跃迁。

14.4.2 信噪比与共振峰

定义输出信噪比 (SNR) 为功率谱中信号频率处的峰值与背景之比。SNR 随噪声强度 σ 变化，在某个最优 σ_{opt} 处达到最大——这就是随机共振。

理论计算（两态近似）给出 SNR 公式：

$$\text{SNR} \propto \frac{A^2\sigma^2}{\sigma^4 + \text{常数}}$$

在 $\sigma_{\text{opt}} \sim$ 势垒高度 处取极大。

14.4.3 应用实例

- **神经科学**：感觉神经元对弱刺激的检测
- **气候学**：冰川期-间冰期周期的触发
- **工程**：弱信号检测设备

14.5 反应扩散方程与界面生长

14.5.1 KPZ 方程

Kardar-Parisi-Zhang (1986) 方程描述界面生长：

$$\frac{\partial h}{\partial t} = \nu\nabla^2 h + \frac{\lambda}{2}(\nabla h)^2 + \eta(t,x)$$

其中：

- $h(t,x)$：界面高度
- ν：表面张力系数（平滑项）
- λ：非线性项，反映生长沿法向
- η：空间时间白噪声

这是奇异随机偏微分方程，因为 $(\nabla h)^2$ 在分布意义下无定义（h 的 Hölder 指数 $< 1/2$）。需要正则结构理论（Hairer）或重正化群处理。

14.5.2 标度律与普适类

KPZ 方程展示普适标度行为：

$$\text{宽度} \sim t^{\beta}, \quad \text{关联长度} \sim t^{1/z}$$

对于 $(1+1)$ 维：$\beta = 1/3$, $z = 3/2$。这是 KPZ 普适类的特征。

14.5.3 精确解与 Tracy-Widom 分布

近年来，某些初始条件的 $(1+1)$ 维 KPZ 方程被精确求解，高度起伏的分布收敛于随机矩阵理论中的 Tracy-Widom 分布（$\mathrm{F}_{\mathrm{GUE}}$）。

14.6 量子力学中的随机过程

14.6.1 薛定谔方程的随机路径积分表示

费曼路径积分将量子传播子表示为：

$$K(x_f, t_f; x_i, t_i) = \int \exp\left(\frac{i}{\hbar} S[\text{路径}]\right) \mathcal{D}[\text{路径}]$$

通过 Wick 旋转 $t \to -i\tau$（欧几里得化），得到：

$$K_E = \int \exp\left(-\frac{1}{\hbar} S_E[\text{路径}]\right) \mathcal{D}[\text{路径}]$$

这类似于统计力学的配分函数，可与随机过程联系。

14.6.2 随机量子化

Parisi 和 Wu (1981) 提出：量子场论中的欧几里得场 $\phi(x)$ 可视为随机过程 $\phi(x,\tau)$ 的平衡分布，其中 τ 是虚拟时间：

$$\frac{\partial \phi}{\partial \tau} = -\frac{\delta S_E}{\delta \phi} + \eta(x,\tau)$$

η 是空间时间白噪声。当 $\tau \to \infty$，$\phi(x,\tau)$ 的分布趋于 $e^{-S_E[\phi]}$。

这是研究非微扰量子场论的一种数值方法。

14.7 滤波理论：从噪声中提取信号

滤波是从含噪声观测中估计隐藏状态的问题，在导航、通信、金融中广泛应用。

14.7.1 问题设置

隐藏状态过程 X_t（如目标位置）：

$$dX_t = f(t, X_t)dt + g(t, X_t)dW_t$$

观测过程 Y_t（如雷达测量）：

$$dY_t = h(t, X_t)dt + dV_t$$

其中 W_t, V_t 独立布朗运动。

目标：基于 $\mathcal{F}_t^Y = \sigma(Y_s : 0 \le s \le t)$ 估计 X_t。

14.7.2 条件分布与 Kushner 方程

条件密度 $\pi_t(x) = p(X_t = x|\mathcal{F}_t^Y)$ 满足 Kushner-Stratonovich 方程（无穷维）：

$$d\pi_t(x) = \mathcal{L}^*\pi_t(x)dt + [h(x) - \bar{h}_t]\pi_t(x)[dY_t - \bar{h}_t dt]$$

其中 $\mathcal{L}^*$ 是 X_t 生成元的共轭，$\bar{h}_t = \int h(x)\pi_t(x)dx$。

14.7.3 线性高斯情形：卡尔曼滤波

当 f, g, h 线性，噪声高斯时，有闭式解——卡尔曼滤波 (1960)。

状态方程：$dX_t = A_t X_t dt + B_t dW_t$

观测方程：$dY_t = H_t X_t dt + dV_t$

条件分布 $X_t|\mathcal{F}_t^Y \sim N(\hat{X}_t, P_t)$，其中 $\hat{X}_t$ 和 P_t 满足 Riccati 微分方程：

$$\begin{aligned} d\hat{X}_t &= A_t\hat{X}_t dt + P_t H_t^T(dY_t - H_t\hat{X}_t dt) \\ \frac{dP_t}{dt} &= A_t P_t + P_t A_t^T + B_t B_t^T - P_t H_t^T H_t P_t \end{aligned}$$

14.7.4 粒子滤波（序贯蒙特卡洛）

对于非线性非高斯情形，用粒子（样本）近似条件分布。算法：

1. 初始化：从先验分布采样 N 个粒子 $\{X_0^{(i)}\}$
2. 预测：对每个粒子，按状态方程演化一步
3. 更新：根据观测 Y_t 赋予权重 $w_t^{(i)} \propto p(Y_t|X_t^{(i)})$
4. 重采样：按权重重采样粒子，避免退化

14.8 随机控制：不确定性下的最优决策

14.8.1 问题框架

状态方程：$dX_t = b(t, X_t, u_t)dt + \sigma(t, X_t, u_t)dW_t$

控制过程：$u_t \in U$（允许控制集）

目标：最小化成本泛函

$$J(u) = \mathbb{E}\left[\int_0^T f(t, X_t, u_t)dt + g(X_T)\right]$$

14.8.2 动态规划与 HJB 方程

值函数 $V(t,x) = \inf_u J(t,x;u)$ 满足 Hamilton-Jacobi-Bellman 方程：

$$\frac{\partial V}{\partial t} + \inf_{u \in U}\{\mathcal{L}^u V + f(t,x,u)\} = 0$$

其中 $\mathcal{L}^u$ 是控制 u 下的生成元。

最优反馈控制：$u^*(t,x) = \arg\min_u\{\mathcal{L}^u V + f\}$

14.8.3 随机最大值原理与伴随 BSDE

另一种方法：引入伴随过程 (p_t, q_t) 满足线性 BSDE：

$$dp_t = -H_x(t, X_t, u_t, p_t, q_t)dt + q_t dW_t, \quad p_T = g_x(X_T)$$

其中 Hamiltonian $H(t,x,u,p,q) = pb(t,x,u) + q\sigma(t,x,u) + f(t,x,u)$。

最优控制满足：$H(t, X_t, u_t, p_t, q_t) = \min_u H(t, X_t, u, p_t, q_t)$

14.8.4 应用：投资组合优化

Merton 问题 (1969)：投资者分配财富于风险资产和无风险资产，最大化终端效用。

状态：财富 W_t 控制：投资于风险资产的比例 π_t 状态方程：

$$dW_t = W_t[(r + \pi_t(\mu - r))dt + \pi_t \sigma dW_t]$$

目标：$\max \mathbb{E}[U(W_T)]$，U 为效用函数（如 CRRA：$U(w) = w^{1-\gamma}/(1-\gamma)$）。

解：$\pi_t^* = \frac{\mu - r}{\gamma \sigma^2}$（常数比例策略）。

14.9 随机共振在工程中的应用

14.9.1 微弱信号检测

在强噪声背景中检测弱周期信号：

$$dX_t = [-\alpha X_t + \beta X_t^3 + A\cos(\omega t)]dt + \sigma dW_t$$

通过调节噪声强度 σ 至最优值，可使输出信号的信噪比最大。

14.9.2 能量采集

从环境振动中采集能量：

$$m\ddot{x} + \gamma \dot{x} + kx + \eta x^3 = F\cos(\Omega t) + \xi(t)$$

非线性（双稳）设计结合噪声可提高宽频带能量采集效率。

14.10 生物物理中的应用

14.10.1 神经元放电模型

Hodgkin-Huxley 模型的简化：FitzHugh-Nagumo 模型

$$dV_t = [V_t - \frac{1}{3}V_t^3 - w_t + I]dt + \sigma dW_t^1$$
$$dw_t = \epsilon(V_t + a - bw_t)dt + \sigma' dW_t^2$$

其中 V_t 为膜电位，w_t 为恢复变量，I 为输入电流，噪声模拟离子通道随机开关。

14.10.2 基因表达噪声

基因表达中的随机性：

$$dM_t = [\alpha - \beta M_t]dt + \sqrt{\alpha + \beta M_t}dW_t^1 + \sqrt{\gamma P_t}dW_t^2$$

$$dP_t = [\kappa M_t - \delta P_t]dt + \sqrt{\kappa M_t + \delta P_t}dW_t^3$$

M_t 为 mRNA 数量，P_t 为蛋白质数量。噪声来自转录和翻译的随机性。

14.11 随机偏微分方程在材料科学中的应用

14.11.1 相分离与 Cahn-Hilliard-Cook 方程

描述二元混合物相分离：

$$\frac{\partial \phi}{\partial t} = \nabla^2 \left(-\phi + \phi^3 - \nabla^2 \phi\right) + \eta(t, x)$$

其中 ϕ 为浓度差，噪声 η 模拟热涨落。用于研究 spinodal 分解的早期阶段。

14.11.2 弹性线钉扎

描述无序介质中的弹性线（如磁通线、电荷密度波）：

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2} + F(u, x) + \eta(t, x)$$

其中 $F(u, x)$ 为随机钉扎力。展示亚稳态、蠕变等行为。

14.12 数值方法在物理模拟中的挑战

14.12.1 刚度问题

某些物理系统的时间尺度分离导致刚度。如化学反应网络：

$$dX_t = [\epsilon^{-1} f_{\text{fast}}(X_t) + f_{\text{slow}}(X_t)]dt + \sigma dW_t$$

需要隐式方法或多尺度方法。

14.12.2 守恒律保持

哈密顿系统的随机扰动：

$$dq = \frac{\partial H}{\partial p}dt, \quad dp = -\frac{\partial H}{\partial q}dt + \sigma dW_t$$

数值方法应保持辛结构或至少保持能量统计性质。

14.12.3 大偏差模拟

研究稀有事件（如核裂变、蛋白质折叠）需要特殊技术：

- 重要性抽样
- 过渡路径理论
- 弦方法

本章总结

本章展示了 SDE 在物理与工程中的丰富应用，要点如下：

1. **统计力学基础**：朗之万方程、福克-普朗克方程、平衡分布、涨落耗散定理
2. **非线性现象**：随机共振、双稳系统、标度律与普适类
3. **滤波与控制**：卡尔曼滤波、粒子滤波、随机最优控制
4. **量子关联**：随机量子化、路径积分表示
5. **跨学科应用**：生物物理、材料科学、信号处理
6. **计算挑战**：刚度、守恒律保持、大偏差模拟

从三种基本操作的视角回顾：

- **对时间积分**：描述确定性动力学（牛顿定律、反应速率）
- **对样本积分**：统计系综平均（温度、压强、期望效用）
- **随机积分**：热涨落、量子涨落、测量噪声

物理与工程不仅为 SDE 提供了应用场景，更提出了深刻的数学问题：奇异性 (KPZ)、非平衡统计 (熵产生)、多尺度耦合等。这些挑战推动了正则结构、大偏差理论、随机同伦论等现代数学的发展。

最终，我们看到数学与物理的共生关系：物理直觉引导数学发现，数学严谨澄清物理概念。这种对话是科学进步的核心动力。

历史注记

布朗运动理论始于爱因斯坦 (1905) 和朗之万 (1906)。OU 过程由 Uhlenbeck 和 Ornstein(1930) 严格化。随机共振由 Benzi 等 (1981) 在气候学中发现。KPZ 方程由 Kardar、Parisi 和 Zhang(1986) 提出，其数学理论由 Hairer(2014) 的正则结构完成。卡尔曼滤波由 Kalman(1960) 发明。随机控制由 Fleming、Rishel、Kushner 等发展。这些工作共同构建了随机过程在物理与工程中的应用版图。

专题 C：计算与数据科学中的随机方法

14.13 引言：从随机分析到数据科学

在前九章中，我们系统学习了随机微分方程的理论体系，从 Itô 积分到 SDE 解理论，再到 BSDE 和测度变换。这些理论不仅数学优美，而且在金融、物理等领域有经典应用。然而，近年来随机分析正在经历一场深刻的变革：它与机器学习、数据科学的融合正在催生新的交叉学科。

本章将探讨这一前沿交叉领域。我们将看到，随机分析中的核心概念——随机过程、扩散、测度变换——正在为现代数据科学提供新的工具和视角。反过来，数据科学的需求也在推动随机分析的新发展，特别是在高维计算、近似推断和生成建模方面。

从三种基本操作的视角看，数据科学问题往往涉及：

1. **对时间积分**：在随机动力学建模中
2. **对样本积分**：在期望计算、损失函数优化中
3. **随机积分**：在随机梯度下降、扩散模型中

这些操作以新颖的方式组合，为解决高维优化、概率建模等问题提供了强大框架。

14.14 神经随机微分方程

14.14.1 从 ODE 到 SDE 的神经网络推广

神经 ODE（Neural ODE）是 2018 年提出的突破性工作，将残差网络视为常微分方程：

$$\frac{dh(t)}{dt} = f_\theta(h(t), t), \quad h(0) = x$$

其中 f_θ 是神经网络。解 $h(T)$ 作为网络输出。

神经 SDE（Neural SDE）进一步引入随机性：

$$dH_t = \mu_\theta(H_t, t)dt + \sigma_\phi(H_t, t)dW_t, \quad H_0 = x$$

这里 μ_θ 和 σ_ϕ 都是神经网络。

14.14.2 优势与应用

神经 SDE 相比神经 ODE 的优势：

- **不确定性量化**：SDE 自然建模不确定性，可给出预测分布
- **鲁棒性**：对输入噪声更稳定
- **表达能力**：可建模更复杂的动态

应用场景：

1. **时间序列建模**：股票价格、气候数据等随机过程
2. **生成模型**：作为扩散模型的另一种视角
3. **强化学习**：环境动态建模

14.14.3 训练与反传

神经 SDE 的训练需要特殊技巧，因为直接反向传播涉及随机积分的梯度。

1. **伴随方法**：类似神经 ODE，定义伴随过程 p_t 满足倒向 SDE
$$dp_t = -p_t \frac{\partial \mu_\theta}{\partial h} dt - p_t \frac{\partial \sigma_\phi}{\partial h} dW_t + \text{修正项}$$
2. **路径 wise 导数**：如果 σ_ϕ 与参数无关或确定，可用重参数化技巧
3. **分数匹配**：通过估计 score 函数 $\nabla \log p_t(h)$ 训练

14.14.4 与经典 SDE 理论的联系

神经 SDE 可以看作参数化的 SDE 族，学习过程是寻找最优参数使生成的数据分布接近目标分布。这本质上是 ** 测度变换 ** 问题：从简单测度（先验 SDE）变换到复杂测度（数据分布）。

从 Girsanov 定理视角，密度比为：

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \exp\left(\int_0^T \theta_t dW_t - \frac{1}{2}\int_0^T \theta_t^2 dt\right)$$

其中 θ_t 是学习的漂移调整。

14.15 扩散模型：生成建模的随机视角

14.15.1 前向与逆向过程

扩散模型（Diffusion Models）是当前最先进的生成模型，其核心是随机微分方程。

前向过程（加噪）：

$$dX_t = f(t)X_t dt + g(t)dW_t, \quad t \in [0, T]$$

通常取 $f(t) = -\frac{1}{2}\beta(t)$，$g(t) = \sqrt{\beta(t)}$，其中 $\beta(t)$ 是噪声调度。

逆向过程（生成）：

$$dX_t = \left[f(t)X_t - g^2(t)\nabla \log p_t(X_t)\right] dt + g(t)d\bar{W}_t$$

其中 $\bar{W}_t$ 是逆向时间的布朗运动，$\nabla \log p_t(x)$ 是 score 函数（数据分布在对数空间梯度）。

14.15.2 与 Fokker-Planck 方程的联系

前向过程的 Fokker-Planck 方程：

$$\frac{\partial p_t}{\partial t} = -\nabla \cdot (f(t)xp_t) + \frac{1}{2}g^2(t)\Delta p_t$$

逆向过程对应的时间反演：如果前向过程将数据 p_0 变为噪声 $p_T \approx N(0, I)$，则逆向过程将噪声变回数据。

14.15.3 分数匹配与训练

核心是学习 score 函数 $s_\theta(x,t) \approx \nabla \log p_t(x)$。损失函数：

$$\mathcal{L}(\theta) = \mathbb{E}_{t\sim U[0,T],x_0\sim p_0,x_t\sim p_{t|0}(x_t|x_0)} \left[\|s_\theta(x_t,t) - \nabla_{x_t} \log p_{t|0}(x_t|x_0)\|^2\right]$$

其中 $p_{t|0}(x_t|x_0)$ 是前向过程的转移密度，通常为高斯：

$$p_{t|0}(x_t|x_0) = N(x_t; \alpha(t)x_0, \sigma^2(t)I)$$

$\alpha(t), \sigma(t)$ 有解析表达式。

14.15.4 连续时间视角的优势

相比离散时间扩散模型，连续时间 SDE 视角提供：

- **统一框架**：统一 DDPM、SMLD 等变体
- **灵活性**：可设计不同 $f(t), g(t)$
- **理论分析工具**：利用随机分析已有结果
- **高效采样**：可用 SDE 数值方法加速采样

14.16 随机优化与扩散近似

14.16.1 随机梯度下降的扩散极限

考虑随机梯度下降（SGD）：

$$\theta_{k+1} = \theta_k - \eta \nabla \hat{L}(\theta_k)$$

其中 $\nabla \hat{L}$ 是随机梯度，η 是学习率。

当 $\eta \to 0$，SGD 的连续时间极限是一个随机微分方程：

$$d\theta_t = -\nabla L(\theta_t)dt + \sqrt{\eta \Sigma(\theta_t)} dW_t$$

其中 $\Sigma(\theta) = \mathrm{Cov}(\nabla \hat{L}(\theta))$ 是梯度噪声协方差。

这解释了 SGD 的隐式正则化：噪声帮助逃离局部极小值，找到更平坦的最小值（与泛化性相关）。

14.16.2 Langevin 动力学

Langevin Monte Carlo 结合梯度下降和布朗运动：

$$d\theta_t = -\nabla L(\theta_t)dt + \sqrt{2\tau}dW_t$$

其中 τ 是温度参数。

该过程的平稳分布是 Gibbs 分布：

$$p_\infty(\theta) \propto \exp(-L(\theta)/\tau)$$

当 $\tau = 1$ 时，采样 $p(\theta) \propto \exp(-L(\theta))$。

14.16.3 随机梯度 Langevin 动力学（SGLD）

将 SGD 噪声与注入噪声结合：

$$\theta_{k+1} = \theta_k - \eta_k \nabla \hat{L}(\theta_k) + \sqrt{2\eta_k \tau}\xi_k$$

其中 $\xi_k \sim N(0, I)$。

在适当条件下，SGLD 收敛到 Langevin 扩散，可用于贝叶斯推断的大规模后验采样。

14.17 高维 PDE 的随机表示与求解

14.17.1 高维 PDE 的维数灾难

考虑高维抛物型 PDE：

$$\frac{\partial u}{\partial t} + \mu \cdot \nabla u + \frac{1}{2}\mathrm{tr}(\sigma\sigma^T D^2 u) + f(t, x, u, \nabla u\sigma) = 0$$

维数 d 可达数百甚至数千。传统网格方法（有限差分、有限元）复杂度 $O(N^d)$，不可行。

14.17.2 Feynman-Kac 公式与蒙特卡洛

由 Feynman-Kac 公式，PDE 解可表示为：

$$u(t,x) = \mathbb{E}\left[\int_t^T f(s, X_s, u, \nabla u\sigma)ds + g(X_T) \,\middle|\, X_t = x\right]$$

其中 $dX_s = \mu ds + \sigma dW_s$。

这给出了蒙特卡洛方法：模拟 X_s 的路径，近似期望。

但对于非线性 PDE（f 依赖于 u 或 ∇u），这是隐式表示，需要进一步处理。

14.17.3 深度学习求解高维 PDE

深度学习通过参数化 $u_\theta(t,x) \approx u(t,x)$ 求解高维 PDE。

方法 1：基于 Feynman-Kac 的损失

设 $\{X_s^{(i)}\}$ 是模拟路径，定义损失：

$$\mathcal{L}(\theta) = \frac{1}{N}\sum_{i=1}^{N}\left|u_\theta(T, X_T^{(i)}) - g(X_T^{(i)})\right|^2 + \left|\frac{du_\theta}{dt} + \mathcal{L}u_\theta + f\right|^2$$

其中 $\mathcal{L}$ 是生成元。

方法 2：BSDE 方法（Deep BSDE）

将 PDE 转化为 BSDE：

$$\begin{cases} dY_t = -f(t, X_t, Y_t, Z_t)dt + Z_t dW_t \\ Y_T = g(X_T) \end{cases}$$

其中 $Y_t = u(t, X_t)$，$Z_t = \nabla u(t, X_t)\sigma(t, X_t)$。

用两个神经网络近似 $u_\theta(t,x)$ 和 $\nabla u_\phi(t,x)$，通过模拟路径训练。

方法 3：物理信息神经网络（PINN）

直接最小化 PDE 残差：

$$\mathcal{L}(\theta) = \left\| \frac{\partial u_\theta}{\partial t} + \mathcal{L}u_\theta + f \right\|^2 + \|u_\theta(0,\cdot) - u_0\|^2 + \text{边界项}$$

在时空区域采样点计算残差。

14.18 随机过程与图神经网络

14.18.1 图上的随机游走

考虑图 $G = (V, E)$，顶点 V，边 E。连续时间随机游走：

$$dX_t = \text{从当前顶点跳到邻居}$$

是跳跃过程，生成元是图拉普拉斯矩阵 Δ。

热核（heat kernel）$e^{t\Delta}$ 描述随机游走的扩散，可用于图表示学习。

14.18.2 图神经扩散

神经 PDE 在图上的推广：

$$\frac{dH(t)}{dt} = \mathrm{GNN}_\theta(H(t), A)$$

其中 A 是邻接矩阵，GNN 是图神经网络层。

加入随机性得图神经 SDE：

$$dH_t = \mu_\theta(H_t, A)dt + \sigma_\phi(H_t, A)dW_t$$

用于不确定图表示学习。

14.18.3 连续时间图注意力

传统图注意力是离散的。连续时间版本：

$$\alpha_{ij}(t) = \mathrm{softmax}\left(\frac{a^\top[Wh_i(t)\|Wh_j(t)]}{\sqrt{d}}\right)$$

节点特征 $h_i(t)$ 随连续时间演化。

14.19 时间序列的随机建模

14.19.1 神经随机过程

神经过程（Neural Processes）结合神经网络和高斯过程，学习随机过程族。

设 $\{(x_i, y_i)\}_{i=1}^n$ 是上下文点，$\{(x_j^*, y_j^*)\}_{j=1}^m$ 是目标点。神经过程建模：

$$p(y^*|x^*, x_{1:n}, y_{1:n}) = \int p(y^*|x^*, z)p(z|x_{1:n}, y_{1:n})dz$$

其中 z 是潜在变量。

14.19.2 高斯过程的 SDE 表示

平稳高斯过程可用 SDE 的平稳解表示。例如，Ornstein-Uhlenbeck 过程是高斯过程，协方差 $k(t-s) = \frac{\sigma^2}{2\theta}e^{-\theta|t-s|}$。

更一般地，线性时不变 SDE：

$$\frac{d\mathbf{x}(t)}{dt} = F\mathbf{x}(t) + Lw(t)$$

其中 $w(t)$ 是白噪声，输出 $y(t) = H\mathbf{x}(t)$ 是高斯过程。

这提供了高斯过程的高效计算：状态空间模型复杂度 $O(n)$，而不是通常的 $O(n^3)$。

14.19.3 随机波动率模型的深度学习

传统随机波动率模型（如 Heston）参数有限。神经随机波动率模型：

$$\begin{aligned} dS_t &= \mu_\theta(S_t, v_t)S_t dt + \sqrt{v_t}S_t dW_t^1 \\ dv_t &= \kappa_\phi(v_t)dt + \xi_\psi(v_t)dW_t^2 \\ dW_t^1 dW_t^2 &= \rho dt \end{aligned}$$

其中 $\mu_\theta, \kappa_\phi, \xi_\psi$ 是神经网络。

可从市场数据学习，无需假设特定形式。

14.20 强化学习中的随机分析

14.20.1 连续时间强化学习

马尔可夫决策过程（MDP）的连续时间推广：连续时间 MDP。

状态过程 $dX_t = \mu(X_t, a_t)dt + \sigma(X_t, a_t)dW_t$，其中 a_t 是控制。

值函数 $V(x) = \sup_a \mathbb{E}\left[\int_0^\infty e^{-\beta t} r(X_t, a_t)dt \,\middle|\, X_0 = x\right]$

满足 Hamilton-Jacobi-Bellman 方程：

$$\beta V(x) = \sup_a \{r(x, a) + \mathcal{L}^a V(x)\}$$

其中 $\mathcal{L}^a$ 是生成元。

14.20.2 策略梯度与扩散近似

策略梯度定理在连续时间下的形式：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\int_0^T e^{-\beta t} \nabla_\theta \log \pi_\theta(a_t|X_t) Q^\pi(X_t, a_t)dt\right]$$

其中 Q^π 是动作值函数。

14.20.3 探索与开发的权衡

SDE 视角下的探索：在策略中添加噪声

$$a_t = \pi_\theta(X_t) + \sigma_\epsilon \xi_t$$

其中 ξ_t 是噪声。

最优探索策略与随机控制相关。

14.21 概率编程与自动微分

14.21.1 概率编程语言中的 SDE

现代概率编程语言（如 Pyro、TensorFlow Probability）支持 SDE 作为原语。

```
def sde_model():
    # 先验
    mu = pyro.sample("mu", Normal(0, 1))
    sigma = pyro.sample("sigma", LogNormal(0, 1))

    # SDE模型
    def drift(t, x):
        return mu * (1 - x)

    def diffusion(t, x):
        return sigma

    # 模拟SDE路径
    x_path = pyro.sample("x_path",
        StochasticDifferentialEquation(
            drift, diffusion, dt=0.01, steps=1000
        )
    )

    # 观测噪声
    y = pyro.sample("y", Normal(x_path, 0.1))
```

14.21.2 随机计算图与自动微分

SDE 引入随机节点到计算图。需要扩展自动微分以处理随机性:

- **重参数化技巧**: 如果 $X \sim p_\theta$ 可写为 $X = g_\theta(\epsilon)$, $\epsilon \sim q$, 则 $\nabla_\theta \mathbb{E}[f(X)] = \mathbb{E}[\nabla_\theta f(g_\theta(\epsilon))]$
- **得分函数估计**: $\nabla_\theta \mathbb{E}[f(X)] = \mathbb{E}[f(X) \nabla_\theta \log p_\theta(X)]$
- **SDE 的特殊处理**: 需要近似梯度, 如伴随方法

14.21.3 变分推断与 SDE

变分自编码器（VAE）的连续时间推广：使用 SDE 作为编码器或解码器。

编码器：$q_\phi(z|x)$ 由 SDE 定义解码器：$p_\theta(x|z)$ 由逆 SDE 定义

损失函数：证据下界（ELBO）

$$\mathcal{L} = \mathbb{E}_{q_\phi}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x)\|p(z))$$

其中 KL 散度可能涉及 SDE 路径的 KL 散度。

14.22 未来方向与挑战

14.22.1 理论挑战

1. **高维极限**：当 $d \to \infty$，随机分析的经典结果是否仍然成立?
2. **神经网络的泛化**：神经 SDE 的泛化误差分析
3. **优化动力学**：理解 SGD 在非凸景观中的扩散极限
4. **离散-连续对应**：深度神经网络与随机微分方程的精确对应关系

14.22.2 计算挑战

1. **可扩展性**：高维 SDE 的高效数值方法
2. **梯度估计**：随机积分的低方差梯度估计
3. **自适应方法**：自适应步长、自适应基函数
4. **硬件加速**：GPU、TPU 上的大规模并行模拟

14.22.3 应用前沿

1. **科学计算**：量子化学、计算生物中的随机建模
2. **金融科技**：高维衍生品定价、风险管理
3. **医疗健康**：疾病传播模型、个性化治疗
4. **气候科学**：气候模型的不确定性量化

本章总结

本章探讨了随机分析与数据科学的交叉前沿，要点如下：

1. **神经 SDE**：将神经网络与随机微分方程结合，增强表达能力与不确定性量化
2. **扩散模型**：从 SDE 视角统一理解生成建模，score 匹配是关键
3. **随机优化**：SGD 的扩散极限解释隐式正则化，Langevin 动力学连接优化与采样
4. **高维 PDE 求解**：通过随机表示（Feynman-Kac、BSDE）结合深度学习突破维数灾难
5. **图与时间序列**：随机过程在图数据和时间序列建模中的新应用
6. **强化学习**：连续时间强化学习的 SDE 框架
7. **概率编程**：SDE 作为概率建模原语，需要扩展自动微分

这一领域体现了 ** 理论与应用的双向驱动 **：

- 随机分析为数据科学提供理论基础：扩散、测度变换、随机表示
- 数据科学为随机分析提出新问题：高维计算、近似推断、可扩展算法

从三种基本操作的视角，数据科学中的随机方法是：

- **对时间积分**：在动力系统建模、时间序列分析中
- **对样本积分**：在损失函数、期望计算、变分推断中
- **随机积分**：在扩散模型、随机优化、噪声注入中

这些操作以新颖的方式组合，形成处理高维、复杂数据的强大框架。

掌握这一交叉领域不仅需要随机分析的扎实基础，还需要机器学习、优化理论、科学计算等多方面知识。这正体现了现代数学的特点：深度专业化与广泛交叉并存的张力与活力。

随机分析历经 80 年发展，从 Itô 的奠基工作到今日与深度学习的融合，始终保持着理论与应用相互促进的活力。展望未来，这一传统仍将继续，为理解复杂系统、设计智能算法提供数学基础。

历史注记

神经 ODE 由 Chen 等 (2018) 提出。神经 SDE 由 Liu 等 (2019) 系统研究。扩散模型的 SDE 视角由 Song 等 (2021) 建立。高维 PDE 的深度学习求解由 E 等 (2017) 开创。图神经扩散由 Chamberlain 等 (2021) 提出。连续时间强化学习由 Jia 和 Zhou(2022) 综述。这些工作共同推动了随机分析与数据科学的融合，形成活跃的研究前沿。